

目次

第 1 章	モデルの枠組み	7
1.1	確率の数理的構造：Kolmogorov の公理	8
1.1.1	Kolmogorov の公理	8
1.1.2	σ -加法性	9
1.2	有界測度論の確率論的解釈	9
1.2.1	極限の定義	10
1.2.2	連続写像としての測度	11
1.2.3	Borel-Cantelli	12
1.2.4	Hewitt-Savage	13
1.2.5	Bonferroni	13
1.3	確率変数論	13
1.4	分布関数論	13
1.5	確率測度の Fourier 逆変換	14
1.6	確率空間の生息圏：可測空間の圏	15
1.6.1	Meas の特徴	15
1.6.2	Meas での極限構成	15
1.7	線型汎関数	16
1.7.1	1 次元の場合	16
1.7.2	平均の一般化	16
1.7.3	分散の一般化	17
1.7.4	他の測度に関する線型作用素	17
1.7.5	統計的推論	18
1.7.6	積分作用素に関する確率不等式	18
1.7.7	Lebesgue 空間の包含関係	19
1.8	σ -加法族が定める構造（要再考）	19
1.9	分割と情報	20
第 2 章	有界測度論	21
2.1	確率測度の収束	21
2.1.1	測度と積分の双対性	21
2.1.2	測度の収束の定義 4 種	22
2.1.3	確率測度のノルム収束	24
2.1.4	弱収束の定義と特徴付け	24
2.1.5	漠収束の特徴付け	25
2.1.6	一様収束のための十分条件	25
2.1.7	連続写像定理	25
2.2	確率測度の空間	25
2.2.1	可分性と距離付け可能性	25
2.2.2	稠密部分集合の遺伝	26

2.2.3	コンパクト性	26
2.2.4	完備性	26
2.2.5	相対コンパクト集合の特徴付け	26
2.2.6	コンパクト空間上の確率測度	27
2.3	積分の拡張	28
2.4	確率変数列の収束	28
2.4.1	定義	28
2.4.2	収束の間の関係	28
2.4.3	概収束の性質	29
2.4.4	確率収束の性質	29
2.4.5	連続写像定理とデルタ法	30
2.4.6	分布収束の性質	30
2.4.7	安定収束	31
2.4.8	弱収束が定める概収束列	31
2.4.9	一様可積分性の定義と特徴付け	31
2.4.10	収束概念が退化するための十分条件	32
2.5	不等式	33
2.5.1	確率不等式	33
2.5.2	凸不等式	33
2.5.3	Lebesgue 空間のノルム不等式	33
2.5.4	畳み込みと不等式	34
2.6	一般の試行と確率測度	34
2.7	確率測度の拡張定理	34
2.8	確率測度の直積	34
2.9	標準確率空間	35
第 3 章	確率論の基礎概念	36
3.1	確率測度の変換：条件付き確率と Bayes の定理	36
3.2	事象の独立性	37
3.2.1	互いに独立な事象	37
3.2.2	事象族の独立性	38
3.2.3	σ -代数の独立性	38
3.3	確率変数と確率分布	39
3.4	確率変数の独立性	39
3.5	独立な確率変数	39
3.5.1	確率変数の独立性	39
3.5.2	独立な確率変数に対する関手性	40
3.5.3	独立同分布	41
3.5.4	独立確率変数列	42
3.6	確率変数の和・積・商の分布	43
3.7	可分完全確率測度	43
3.8	事象と確率変数	43
3.9	条件付き期待値	44
3.9.1	動機	44
3.9.2	定義	44
3.9.3	性質	45
3.9.4	可測写像を与えたもとの条件付き期待値	46
3.9.5	正則条件付き確率	46

3.10	0-1 法則	47
第 4 章	独立確率変数列の和	48
4.1	確率不等式	48
4.2	独立同分布に関する大数の法則	49
4.2.1	独立同分布での大数の弱法則	49
4.2.2	独立同分布での大数の強法則	50
4.2.3	証明抽出と評価の精緻化	50
4.3	一般の大数の弱法則	51
4.4	一般の大数の強法則	51
4.5	数学における大数の法則的現象	52
4.5.1	Weierstrass の多項式近似	52
4.6	物理学における大数の法則的現象	53
4.6.1	Maxwell 分布	53
4.6.2	熱力学的極限	53
4.7	中心極限定理	54
4.7.1	標準化された部分和についての結果	54
4.7.2	Lindeberg-Feller の一般化	54
4.7.3	ノルム収束についての中心極限定理	55
4.7.4	経験分布に対する拡張	55
4.8	中心極限定理の誤差	55
4.9	Poisson の少数の法則	55
4.10	大偏差原理	56
4.10.1	定義	56
4.10.2	Laplace の原理	56
4.10.3	Cramer の理論	57
4.10.4	Schilder の理論	57
4.10.5	Varadhan の理論	57
第 5 章	漸近理論	58
5.1	歴史	58
第 6 章	高次元確率論	59
6.1	独立確率変数列の集中不等式	59
6.1.1	Chebyshev の不等式	59
6.1.2	Hoeffding の不等式	59
6.1.3	Chernoff の不等式	60
6.1.4	確率グラフ	60
6.1.5	劣 Gauss 分布	61
6.1.6	Orlicz 空間	61
6.1.7	一般化 Hoeffding 不等式	61
6.1.8	劣指数分布	61
6.1.9	Bernstein の不等式	62
第 7 章	分布の扱い	63
7.1	期待値作用素	63
7.1.1	積分の定義	63
7.1.2	期待値の定義	63
7.1.3	期待値不等式	64

7.2	分布の特性値	64
7.2.1	確率密度関数	64
7.2.2	平均値と積率	64
7.2.3	共分散と相関	65
7.2.4	分散共分散行列	66
7.3	分布関数	66
7.3.1	定義と特徴付け	67
7.3.2	分布関数の構成	67
7.3.3	分布の微分としての性質	67
7.3.4	一意性定理	68
7.3.5	弱収束の特徴付け	68
7.3.6	分布関数の弱収束	68
7.4	確率母関数	68
7.4.1	特性関数と確率母関数	68
7.4.2	分位点関数	69
7.4.3	母関数の概念の射程	69
7.5	特性関数	70
7.5.1	特性関数と Fourier 変換	70
7.5.2	特性関数の特徴付け	71
7.5.3	特性関数と分布の収束の対応	71
7.5.4	特性関数の滑らかさと積率の存在	72
7.5.5	特性関数の Taylor 展開	72
7.6	キュムラント関数	73
7.6.1	第 2 キュムラント母関数	73
7.7	積率母関数	73
7.7.1	Laplace 変換	73
7.7.2	積率母関数	74
7.7.3	キュムラント母関数	74
7.7.4	積率問題	75
7.7.5	多次元確率変数の特性関数	75
7.8	確率変数の独立性と期待値	75
7.8.1	独立な確率変数の積の期待値	75
7.8.2	確率変数の独立性と共分散	76
7.8.3	確率変数の独立性と特性関数	76
7.8.4	独立同分布に従う確率変数列	76
7.8.5	独立確率変数の和と畳み込み	76
7.9	多次元分布の扱い	77
7.9.1	多次元確率変数の分布	77
7.9.2	共分散	78
7.9.3	共分散行列	78
7.9.4	積率の定義	79
7.9.5	キュムラントの定義	80
7.10	コピュラ	80
7.10.1	定義と例	80
7.10.2	Sklar の定理	81
7.10.3	Archimedes コピュラ	81

8.1	一次元離散分布の例	82
8.1.1	デルタ分布	82
8.1.2	経験分布	82
8.1.3	Rademacher 分布	83
8.1.4	離散一様分布	83
8.1.5	二項分布	83
8.1.6	Poisson 分布	84
8.1.7	負の二項分布	86
8.1.8	Katz 族	87
8.1.9	超幾何分布	88
8.1.10	負の超幾何分布	88
8.1.11	対数分布	88
8.1.12	Ord 族	88
8.2	多次元離散分布の例	89
8.2.1	確率変数の積	89
8.2.2	多項分布	89
8.2.3	2 変量 Poisson 分布	89
8.2.4	負の多項分布	90
8.3	一次元連続分布の例	90
8.3.1	一様分布	90
8.3.2	Gamma 分布・指数分布・ χ^2 乗分布	91
8.3.3	正規分布	92
8.3.4	Beta 分布	92
8.3.5	Cauchy 分布	93
8.3.6	Weibull 分布	93
8.3.7	対数正規分布	94
8.3.8	logistic 分布	94
8.3.9	Pareto 分布	95
8.3.10	逆正規分布	95
8.3.11	逆 Gamma 分布	96
8.3.12	Laplace 分布	96
8.3.13	Marcenko-Pastur 分布	97
8.3.14	Pearson 系	97
8.3.15	Poisson 分布確率変数の和差	97
8.4	多次元連続分布の例	98
8.4.1	多次元の確率密度関数	98
8.4.2	確率密度関数と独立性	98
8.4.3	畳み込み	98
8.4.4	変数変換と確率密度関数	98
8.4.5	多変量正規分布	99
8.4.6	Dirichlet 分布	100
8.5	指数型分布族	100
8.5.1	定義と例	100
8.5.2	標準指数型分布族	100
8.5.3	共役事前分布	101
8.6	指数分散モデル	101
8.6.1	構成	101

8.6.2 Tweedie 分布族	102
参考文献	103

第 1 章

モデルの枠組み

Probability theory is concerned with mathematical models of phenomena that exhibit randomness, or more generally phenomena about which one has incomplete information. 確率論の概念を数学的な公理に落とし込む段階に於ける形式科学的な議論をまとめる.^{†1} ランダム性・不確定性に関する概念のうち、例えば、独立性以前のエントロピーなどの概念は殆ど数学的に確定する。

試行 とは、類等式の双対のような^{†2}、標本空間の分割で、事象とはそのうちの 1 つである。この分割上の割合の分配なる観念を人類は確率と呼ぶが、これは正規化された測度に他ならない。^{†3}

確率変数 とは標本空間上の実線型空間に入る射で、標本空間上に同値類による分割を定める。 \mathbb{R}^n -値点の考え方を導入することで、数学理論を観測値の概念に持ち込むことができる。その背景には射があり、線型代数・微分積分学の関手がそこまで還元しているのである。こうして、 X は \mathbb{R}^n の元であるとも見るし、射 $X: \Omega \rightarrow \mathbb{R}^n$ とも見る。

確率 とは標本空間上の非負で正規化された加法的集合関数で、**確率分布**とは確率変数によるこの測度の押し出しである。この対応を分布から辿る時「確率変数が分布に従う」という（当該の分布を押し出すような確率変数を 1 つ取る、という条件と同値）。

エントロピー とは、系で考える全ての試行の期待驚愕度の上限である。

これらの類比は Fréchet の研究において初めて完全に示された。

「有限試行によって確率論の考え方を理解したならば、解析学の手法を用いて、現代確率論の対象である無限試行に進むのは容易である。」注意力の質の方が重要である。

統計モデルとしての多様な確率分布族と、それらに対する種々の統計推測法について解説する。多くの例を通じ、受講者が確率統計の基本事項に習熟することを目標とする。確率的な構造の表現からはじめ、確率の性質、確率変数と確率分布、独立性等の用語を準備し、離散確率分布とその例と計算法、連続分布とその例、確率変数の期待値、変数変換の公式、混合分布、指数型分布族、多次元分布の基礎について解説する。前半の確率の基礎概念の導入の後、確率モデルの推定について紹介する。不偏推定が統計推測の数理的構造を理解するための例となる。十分性、因子分解定理、完備性、ラオ・ブラックウェルの定理、レーマン・シェフェの定理、統計的決定理論の枠組み、ベイズ推定について説明する予定である。

^{†1} Notice that in this respect probability theory has a similar status as (other(?!)) theories of physics: there is a mathematical model (measure theory here as the model for probability theory, or for instance symplectic geometry as a model for classical mechanics) which can be studied all in itself, and then there is in addition a more or less concrete idea of how from that model one may deduce statements about the observable world (the average outcome of a dice role using probability theory, or the observability of the next solar eclipse using Hamiltonian mechanics).<https://ncatlab.org/nlab/show/probability+theory>

^{†2} 類等式は群作用による終域の分解だが、試行は可測関数による始域の分解

^{†3} もっと無限な概念が扱えたなら、測度の語もっと細かく分類すべきかもしれない。

1.1 確率の数理的構造：Kolmogorov の公理

測度論的確率論という枠組み

確率空間は測度空間の一種と見る。確率変数は関数空間の元と見て、平均は作用素と見て構成する。^a

^a こうして、量子論と確率論が関数解析を舞台として合流する。

1.1.1 Kolmogorov の公理

記法 1.1.1 (mutually exclusive).

- (1) 集合 A, B が排反であるとは、互いに素であることをいう。この時の和事象を $A + B, A \coprod B$ で表し直和という。^[4] では直和も $\sum_{i=1}^n A_i$ と表す。 $P(A + B) = P(A) + P(B), P(A \cup B) = P(A) + P(B) - P(A \cap B)$ と書き分けられる。
- (2) 族 $(A_i)_{i \in I}$ が排反であるとは、 $\forall i, j \in I, i \neq j \Rightarrow A_i \cap A_j = \emptyset$ であることをいう。
- (3) $A \subset B$ のときの差事象 $A \setminus B$ を固有差といい、 $B - A$ と書く。

定義 1.1.2 (sample space, sample, event, total event).


- (1) 標本空間 Ω の元 $\omega \in \Omega$ を標本（点）という。^{†4}
- (2) σ -加法族 $\mathcal{F} \subset P(\Omega)$ の元を事象と呼ぶ。^{†5} 事象としての $\Omega \in \mathcal{F}$ を全事象という。

定義 1.1.3 (probability). σ -代数 \mathcal{F} に対して、次を満たす測度 $P: \mathcal{F} \rightarrow [0, 1]$ を確率測度または試行 T の確率法則という。

- (1) $P(A) \geq 0$ ($\forall A \in \mathcal{F}$).
- (2) $P(\Omega) = 1$.
- (3) (σ -加法性) $P(\cup_{i \in \mathbb{N}} A_i) = \sum_{i \in \mathbb{N}} P(A_i)$, ただし族 $(A_i): \mathbb{N} \rightarrow \mathcal{F}$ は $\forall i \neq j, A_i \cap A_j = \emptyset$ を満たす。

定義 1.1.4 (random variable, probability distribution / law). 確率空間を (Ω, \mathcal{F}) , $(\mathcal{X}, \mathcal{G})$ を可測空間とする。

- (1) \mathcal{X} -値確率変数とは、可測関数 $X: \Omega \rightarrow \mathcal{X}$ をいう。
- (2) これに沿って引き起こされる像測度 $X_*P = P^X: P(\mathcal{X}) \supset \mathcal{G} \rightarrow [0, 1]$ を $P^X(B) := P(X^{-1}(B))$ で定める。^{†6}



これを X の確率分布または確率法則という。

- (3) 特に、確率 P は、恒等写像 $\text{id}_\Omega: \Omega \rightarrow \Omega$ についての確率分布 P^{id_Ω} である。
- (4) 像 $\text{Im } X$ も同様の記法 Ω^X で表し、これを X の標本空間という。
- (5) Ω^X は混合試行 T_X の標本空間と考える。 X の定める同一視による商空間を考えているために「混合」という。

要諦 1.1.5 (Kolmogorov 1933). すなわち、確率空間から出る射が確率変数で、それにより押し出される測度が確率分布である。

記法 1.1.6. $a \in \mathcal{X}$ として、確率 $P(X^{-1}(a)) \in [0, 1]$ を $P(X = a)$ と表す。 $B \subset \mathcal{X}$ として、確率 $P(X^{-1}(B)) \in [0, 1]$ を $P(X \in B)$ と表す。これは $E[1_B(X)]$ にも等しい。

^{†4} 見本空間、見本点ともいう。

^{†5} 部分集合を条件や関係だけでなく事象と捉えるのは、集合論の初歩でもやるようだ。

^{†6} 逆像写像 X^* により、なんとか反変に見えるから許したが、nLab では $f_*\mu$ で表されている。

定義 1.1.7 (joint distribution, marginal distribution).

- (1) 確率変数の列 X_1, \dots, X_n に対して, 積写像 (X_1, \dots, X_n) を**同時分布**または**結合分布**という.
- (2) 同時分布から一部の確率変数を消去してえる分布を**周辺分布**という.^{†7}

定義 1.1.8 (可積分).

- (1) 実確率変数 $X: \Omega \rightarrow \mathbb{R}$ が可積分であるとは, $E[|X|] = \int_{\Omega} |X(\omega)| dP(\omega) < \infty$ すなわち, $X \in L^1$ であることをいう.
- (2) $L^1(\Omega, \mu) := \left\{ f \in \text{Map}(\Omega, \mathbb{R}) \mid \int_{\Omega} |f(\omega)| \mu(d\omega) < \infty \right\}$ と表す.

定義 1.1.9 (stochastic process). 確率変数の族 $(X_t)_{t \in T}$ を, 特に T が全順序集合のとき, **確率過程**と言う.

補題 1.1.10. 関数の族 $\{X_n\} \subset \text{Map}(\Omega, \mathbb{R})$ について, 次の2条件は同値.

- (1) (X_n) は確率過程である.
- (2) $X: \mathbb{N} \times \Omega \rightarrow \mathbb{R}$ は $\mathcal{B}(\mathbb{N}) \times \mathcal{F}/\mathcal{B}(\mathbb{R})$ -可測である.

1.1.2 σ -加法性

事象とその確率なる概念が数学では σ -加法性に当たることを考察するのにもっとも直感的な例として, コイントスを繰り返す行為を一つの空間内で表現したい場合, 部分集合の族は自然 σ -代数をなす.

例 1.1.11 (確率空間を取り直すのではなく, σ -加法族を発展させる). 素朴に, n 回試行を行ったときの標本空間は $\Omega_n := \text{Map}([n], 2)$ であり, 事象のなす σ -加法族は $P(\Omega_n)$ である.

一方で, $\Omega := \text{Map}(\mathbb{N}, 2)$ を全体集合とすると, n 回試行を行ったときの事象のなす部分集合族は, $\omega^n \in \Omega_n$ に対して, $A(\omega^n) := \{\omega \in \Omega \mid \forall i \in [n] \ \omega_i = \omega_i^n\}$ とすると, 対応 $A_n: P(\Omega_n) \rightarrow P(\Omega); B \mapsto A(B) := \cup_{\omega^n \in B} A(\omega^n)$ を用いて, $\mathcal{F}_n := \text{Im } A_n \subset P(\Omega)$ は, σ -加法族の構造を持つ. 逆に, それ以外の構造は見出し難い.

定義 1.1.12 (cylinder set). この枠組みを一般化する. 可測空間 (S, \mathcal{S}) に値を取る試行を繰り返す試行の標本空間を $\Omega := S^{\mathbb{N}}$ とする. その部分空間 $C \subset \Omega$ であって, ある $n \in \mathbb{N}$ を用いて

$$C = C(t_1, \dots, t_n; A_1, \dots, A_n) := \{\omega \in \Omega \mid \forall i \in [n] \ \omega_{t_i} \in A_i\} \quad \text{ただし, } t_i \in \mathbb{N}, A_i \in \mathcal{S}$$

と表せるとき, これを**柱状集合**という. これは第 t_i 回の試行の結果を指定して得られる事象である. Ω 上の σ -代数としては, 柱状集合をすべて含むものを取る.

1.2 有界測度論の確率論的解釈

有界測度論

測度とは, 部分集合=事象に対して「全体に占める割合」を定める. 類等式ではないが, 全事象をどのように分解するかが特徴量となる (エントロピー). そこで, 有界測度論の枠組みを確率論的に解釈する方法を以下に示す.

^{†7} 表の欄外 (margin) に行や列の和を記載することから周辺 (marginal) と呼ばれるようになった.

1.2.1 極限の定義

事象列には極限なる演算を定義したい

極限とは「十分遠くでは変わらない」ことである。距離空間では点列の極限が距離で定義できたが、 \mathcal{F} には擬距離しか定まらない。しかし、 \mathcal{F} には特別に、列の極限の定義が、論理によって定められる。そしてこれは、 (\mathcal{F}, Δ) が距離を定めるときの「点列」の定義に一致する。「完備」は、ここに於て通じ合っているが、いずれにしろ距離概念が暗黙にあるということを捉える試みがいまだに続いている。

定義 1.2.1 (上極限事象, 下極限事象, 極限事象). 事象列 $(A_n) : \mathbb{N} \rightarrow \mathcal{F}$ に対して, 次の事象が定義できる。

- (1) $\limsup_{n \rightarrow \infty} A_n := \bigcap_{m=1}^{\infty} \bigcup_{m \geq n} A_m$ を上極限事象という。「事象列のうち無限個が起きる」という条件 i.o. を表す。
- (2) $\liminf_{n \rightarrow \infty} A_n := \bigcup_{m=1}^{\infty} \bigcap_{m \geq n} A_m$ を下極限事象という。「事象列のうちある番号から先の事象が全て起きる」という条件 f.e. を表す。
- (3) 2つの集合が一致するとき, 集合列 (A_n) は収束するといい, $\lim_{n \rightarrow \infty} A_n$ を極限集合という。

補題 1.2.2 (事象としての意味論 : infinitely often, with finite exceptions). $\{A_n\}_{n \in \mathbb{N}} \subset P(X)$ を集合列とする。

- (1) $\limsup_{n \rightarrow \infty} A_n = \{x \in X \mid \#\{n \in \mathbb{N} \mid x \in A_n\} = \infty\}$.
- (2) $\liminf_{n \rightarrow \infty} A_n = \{x \in X \mid \#\{n \in \mathbb{N} \mid x \notin A_n\} < \infty\}$.

[証明] .

(1)

$$x \text{ が } \#\{n \in \mathbb{N} \mid x \in A_n\} = \infty \text{ を満たす} \Leftrightarrow \{n \in \mathbb{N} \mid x \in A_n\} \text{ は非有界である} \\ \Leftrightarrow \forall_{n \in \mathbb{N}} \exists_{m \geq n} x \in A_m \Leftrightarrow x \in \bigcap_{n \in \mathbb{N}} \bigcup_{m \geq n} A_m.$$

(2)

$$x \text{ が } \#\{n \in \mathbb{N} \mid x \notin A_n\} < \infty \text{ を満たす} \Leftrightarrow \{n \in \mathbb{N} \mid x \notin A_n\} \text{ は有界である} \\ \Leftrightarrow \exists_{n \in \mathbb{N}} \forall_{m \geq n} x \in A_m \Leftrightarrow x \in \bigcup_{n \in \mathbb{N}} \bigcap_{m \geq n} A_m.$$

■

補題 1.2.3 (σ -代数の構造を求めて). 有限な測度を備えた空間 (X, \mathcal{F}, μ) について,

- (1) 対称差について, $d(A, B) := A \Delta B$ ($A, B \in \mathcal{F}$) と定めると, これは擬距離関数となる。
- (2) \mathcal{F} が σ -代数として完備であるとき, (\mathcal{F}, Δ) の距離等化によって得る距離空間は完備である。

[証明] .

- (1) μ は有限としたから, $\text{Im } d \subset [0, \infty)$ である。対称性と $d(A, A) = 0$ は明らか。三角不等式については, $A, B, C \in \mathcal{F}$ について,

$$A \Delta C = (A \setminus C) \sqcup B \sqcup (A \setminus C) \cap B \sqcup (C \setminus A) \setminus B \sqcup (C \setminus A) \cap B$$

と直和分解できるが, それぞれについて,

$$(A \setminus C) \setminus B \subset A \setminus B, \quad (A \setminus C) \cap B \subset B \setminus C, \quad (C \setminus A) \setminus B \subset C \setminus B, \quad (C \setminus A) \cap B \subset B \setminus A$$

より, $\mu(A \Delta C) \leq \mu(A \Delta B) + \mu(B \Delta C)$.

- (2) 略。

■

要諦 1.2.4. はじめは技術的で煩瑣な手続きに思えた測度空間の完備化であるが, これにより $\mu : \mathcal{F} \rightarrow [0, \infty)$ が完備距離空間の射に, これが定める積分が有界線型作用素 $L^p(X) \rightarrow \mathbb{R}$ となる。

1.2.2 連続写像としての測度

確率の素朴な加法性に対して、その σ -加法性も考えたいとは、数学的には連続性を考えたいということである。 \mathcal{F} 内に定義した極限の構造に対して、これを保存することをいう。

測度 $\mu: \mathcal{F} \rightarrow [0, 1]$ は、 \mathcal{F} 上の擬距離 $d(A, B) := \mu(A \Delta B)$ について連続であることは示せる。しかし、前節で定義した「集合列の極限」が定める位相は、この擬距離が誘導する位相とは異なる。注 1.2.7 のように、 ∞ と 0 は区別できないフィルターとなっている。

命題 1.2.5 (測度の連続性と劣加法性). 可測空間 (Ω, \mathcal{F}) の可測集合の列 $(A_i): \mathbb{N} \rightarrow \mathcal{F}$ について、次が成り立つ。

(1) 次の4条件は同値。

(a) $\mu: \mathcal{F} \rightarrow [0, 1]$ は測度である。

(b) 単調増加列 (A_n) に対して、 $\lim_{n \rightarrow \infty} \mu(A_n) = \mu(\cup_{n=1}^{\infty} A_n)$ 。

(c) 単調減少列 (A_n) に対して、 $\lim_{n \rightarrow \infty} \mu(A_n) = \mu(\cap_{n=1}^{\infty} A_n)$ 。

(d) \emptyset に収束する単調減少列 (A_n) に対して、 $\lim_{n \rightarrow \infty} \mu(A_n) = 0$ 。

(2) (subadditivity) 測度 μ に対して、 $\mu(\cup_{i=1}^n A_i) \leq \sum_{i=1}^n \mu(A_i)$ ($n \in \mathbb{N}$)。

[証明] .

(1) $B_n := A_n - A_{n-1}$ とおくと (ただし $A_0 = \emptyset$ とする), $(B_n)_{n \in \mathbb{N}}$ は排反であり、 $\cup_{n \in \mathbb{N}} A_n = \cup_{n \in \mathbb{N}} B_n$. よって、

$$\begin{aligned} P(\cup_{n=1}^{\infty} A_n) &= \sum_{n=1}^{\infty} P(B_n) \\ &= \lim_{n \rightarrow \infty} \sum_{k=1}^n P(B_k) = \lim_{n \rightarrow \infty} P(A_n) \end{aligned}$$

(2) 族 $(A_n^c)_{n \in \mathbb{N}}$ が単調増加列であることに気をつけて、

$$\begin{aligned} P(\cap_{n=1}^{\infty} A_n) &= 1 - P(\cup_{n=1}^{\infty} A_n^c) \\ &= 1 - \lim_{n \rightarrow \infty} P(A_n^c) = 1 - \left(1 - \lim_{n \rightarrow \infty} P(A_n)\right) = \lim_{n \rightarrow \infty} P(A_n). \end{aligned}$$

(3) $B_n := \cup_{k=1}^n A_k$ とおくと、これは単調列である。極限は不等式を保存するから、

$$P(\cup_{n=1}^{\infty} A_n) = \lim_{n \rightarrow \infty} P(B_n) \leq \lim_{n \rightarrow \infty} \sum_{k=1}^n P(A_k).$$

■

要諦 1.2.6 (連続写像としての測度). 確率測度 $\mu: \mathcal{F} \rightarrow [0, 1]$ は、の射を定める。一方で、一般の測度 $\mu: \mathcal{F} \rightarrow [0, \infty)$ については、条件 $\mu(A_1) < \infty$ が必要となる。

注 1.2.7. (2) で $\mu(A_1) = \infty$ を許すならば、 $A_i := 2^i \mathbb{N}$ とすることで、 $\lim_{n \rightarrow \infty} \mu(A_n) = \infty, \mu(\cap_{n \in \mathbb{N}} A_n) = 0$ を満たす列が作れてしまう。

測度の連続性が実際にどういう位相について連続なのかを考え途中。特に、(1) と (2) で、 $\mu(A_1) < \infty$ の条件が必要になる非対称性がどこから来るのか探していて、おそらく $[0, \infty]$ に入れる位相から。これは収束空間の知識が必要か？2つの「完備」の概念は、フィルターの意味で一緒なのではないか？

1.2.3 Borel-Cantelli

有界測度論の初等的な結論に、確率論的な解釈を与えることが出来る。

$\limsup : \mathcal{F}^{\mathbb{N}} \rightarrow \mathcal{F}$ の性質を考える。

命題 1.2.8 (集合に関する Fatou の補題). $\limsup : \mathcal{F}^{\mathbb{N}} \rightarrow \mathcal{F}$ は次を満たす。

- (1) \mathcal{F} の列 (A_n) について, $\mu\left(\liminf_{n \rightarrow \infty} A_n\right) \leq \liminf_{n \rightarrow \infty} \mu(A_n)$.
- (2) \mathcal{F} の列 (A_n) について, $\mu(\cup_{n \in \mathbb{N}} A_n) < \infty$ ならば, $\limsup_{n \rightarrow \infty} \mu(A_n) \leq \mu\left(\limsup_{n \rightarrow \infty} A_n\right)$.

定理 1.2.9 (Borel-Cantelli lemma).

- (1) 列 $(A_i) : \mathbb{N} \rightarrow \mathcal{F}$ が独立であろうと無かろうと, 一般の測度 μ について,

$$\sum_{n=1}^{\infty} \mu(A_n) < \infty \Rightarrow \mu(\limsup_{n \rightarrow \infty} A_n) = 0, \quad \mu(\liminf_{n \rightarrow \infty} A_n^c) = \mu(X)^{\dagger 8}.$$

- (2) 列 $(A_i) : \mathbb{N} \rightarrow \mathcal{F}$ が独立であるとき, $\sum_{n=1}^{\infty} P(A_n) = \infty \Rightarrow P(\limsup_{n \rightarrow \infty} A_n) = 1, \quad P(\liminf_{n \rightarrow \infty} A_n^c) = 0$.

【証明】.

- (1) $B_m := \cup_{n=m}^{\infty} A_n$ と定めると, これは単調減少列であるから $\mu(\cap_{m=1}^{\infty} B_m) = \lim_{m \rightarrow \infty} \mu(B_m)$. 和が収束する列は 0 に収束する

($\lim_{m \rightarrow \infty} \sum_{n=m}^{\infty} \mu(A_n) = 0$) ことに注意して,

$$\mu(\limsup_{n \rightarrow \infty} A_n) = \mu(\cap_{m=1}^{\infty} B_m) = \lim_{m \rightarrow \infty} \mu(B_m) \quad \text{単調列の積 1.2.5(3)}$$

$$\leq \lim_{m \rightarrow \infty} \sum_{n=m}^{\infty} \mu(A_n) = 0. \quad \text{劣加法性 1.2.5(4)}$$

また, de Morgan の法則より,

$$\begin{aligned} P(\liminf_{n \rightarrow \infty} A_n^c) &= P(\cap_{n \rightarrow \infty} \cap_{m=n}^{\infty} A_m^c) \\ &= 1 - P(\cap_{n \rightarrow \infty} \cup_{m=n}^{\infty} A_m) = 1 - P(\limsup_{n \rightarrow \infty} A_n) = 1. \end{aligned}$$

- (2) (1) と同様にして, $P(\limsup_{n \rightarrow \infty} A_n) = P(\cap_{n=1}^{\infty} \cup_{k \geq n} A_k) = \lim_{n \rightarrow \infty} P(\cup_{k \geq n} A_k)$ である. 最右辺を評価すると,

$$\begin{aligned} 1 - P(\cup_{k \geq n} A_k) &= P(\cap_{k \geq n} A_k^c) \\ &\leq P(\cap_{k \geq n}^p A_k^c) && \cap_{k \geq n} A_k^c \subset \cap_{k \geq n}^p A_k^c \\ &= \prod_{k=n}^p P(A_k^c) && \text{独立性} \\ &= \prod_{k=n}^p (1 - P(A_k)) \leq \exp\left(-\sum_{k=n}^p P(A_k)\right) \xrightarrow{p \rightarrow \infty} e^{-\infty} = 0. && 1 - x \leq e^{-x} \end{aligned}$$

もう一つの結論も de Morgan の定理から従う. ■

要諦 1.2.10 (どうやら洗練された証明はこの一通りである). (2) が極めて非自明であるが, 余事象を自在に使いこなして解析関数を持ち出して不等式評価へ. 複利の式だね.

例 1.2.11. 無限の猿定理はこの補題 (2) の特別な場合である。

^{†8} 確率測度ならば $\mu(X) = 1$ である

系 1.2.12. 事象列 (A_n) が次の (1) と, (2)(a),(2)(b) のいずれかの 2 条件を満たすならば, $P\left(\limsup_{n \rightarrow \infty} A_n\right) = 0, \lim_{n \rightarrow \infty} P(A_n) = 0$ が成り立つ.

- (1) $\liminf_{n \rightarrow \infty} P(A_n) = 0$.
 (2) (a) $\sum_{n \in \mathbb{N}} P(A_n^c \cap A_{n+1}) < \infty$.
 (b) $\sum_{n \in \mathbb{N}} P(A_n \cap A_{n+1}^c) < \infty$.

1.2.4 Hewitt-Savage

定義 1.2.13. $X_1, X_2, \dots \in \text{Meas}(\Omega, \mathbb{R})$ を確率変数列とする. 事象 $\{\omega \in \Omega \mid \forall i \in \mathbb{N} X_i(\omega) \in A\} \in \mathcal{F}$ が交換可能であるとは, 有限個の入れ替えについて

$$\forall n \in \mathbb{N} \forall \sigma \in S_n \{X_1, X_2, \dots \in A\} \subset \{X_{\sigma_1}, X_{\sigma_2}, \dots \in A\}$$

が成り立つことをいう.

補題 1.2.14. $E \in \mathcal{F}$ が i.i.d. 列 (X_n) に関する交換可能な事象であるとき, $P[E] \in \{0, 1\}$ である.

1.2.5 Bonferroni

有界測度論としては初等的でも, 確率論的には非自明で名前がほしい結果は多い

命題 1.2.15 (Bonferroni の不等式).

$$P(\cap_{i=1}^n A_i) \geq \sum_{i=1}^n P(A_i) - (n-1)$$

等号成立条件は, A_1^c, \dots, A_n^c が背反のとき.

【証明】. A_1^c, \dots, A_n^c について, 劣加法性より. ■

1.3 確率変数論

有界測度空間への米田埋め込みが, 確率論の世界への跳躍である. 確率変数とは, $(\mathbb{R}, \mathcal{G}_1(\mathbb{R}))$ への表現に他ならない. この観点から, 合成 $g \circ X_i$ を $g(X_i)$ などと書く上に, 始域 Ω は自由にとって考察することとなる.

また, 測度を無理やり可測関数の押し出しと見る場面は少ないかもしれないが, 確率論においては, たしかに確率変数は確率分布を一般化する.

命題 1.3.1 (確率変数の構成). 確率変数 X_1, \dots, X_n と可測関数 $g: \mathbb{R}^n \rightarrow \mathbb{R}$ に対して, $Y := g(X_1, \dots, X_n)$ は再び可測関数である.

1.4 分布関数論

\mathbb{R} 上の Radon 積分には, Lebesgue-Stieltjes 積分という名のついた古典的構成法があるのであった. これにより, 分布関数とこれが定める積分 (すなわち測度) とは一対一対応する.

定義 1.4.1 (distribution function). 実確率変数 X の定める $(\mathbb{R}, \mathcal{G}_1(\mathbb{R}))$ 上の確率測度 μ について, 関数 $F: \mathbb{R} \rightarrow [0, 1]; x \mapsto \mu((-\infty, x])$ を, X または μ の分布関数という.

注 1.4.2. $F(x) := \mu((-\infty, x))$ と定めると、左半連続なバージョンで同様の議論が展開可能である。

補題 1.4.3 (分布関数の特徴付け). $(\mathbb{R}, \mathcal{B}_1(\mathbb{R}))$ 上の確率測度 μ の分布関数を F とする。

- (1) F は広義単調増加である。
- (2) $\lim_{x \rightarrow -\infty} F(x) = 0, \lim_{x \rightarrow \infty} F(x) = 1$ をみたす有界関数である。
- (3) 右半連続である。
- (4) $F(x-) := \lim_{y \nearrow x} F(y)$ と表すと、 $\mu(\{x\}) = F(x) - F(x-)$ を満たす。

要諦 1.4.4. 右半連続関数 $F: \mathbb{R} \rightarrow [0, 1]$ に対して、Stieltjes 積分 $\int (-)dF: C_c(\mathbb{R}) \rightarrow \mathbb{R}$ 、またその延長として Lebesgue-Stieltjes 積分 $\int (-)dF: \mathcal{L}^1(\mathbb{R}) \rightarrow \mathbb{R}$ が定まる。すなわち、確率分布 μ が一意に定まる。逆に、 \mathbb{R} 上の任意の Radon 積分に対して、これに等しい分布関数とそれが定める Stieltjes 積分が存在するから、確率分布と分布関数は一対一対応する。

定義 1.4.5 (discrete, absolute continuous, density, singular). 分布関数 $F: \mathbb{R} \rightarrow \mathbb{R}$ について、

- (1) F が**不連続**であるとは、Lebesgue-Stieltjes 測度 dF がデルタ測度の可算和も許した凸結合で表せるときをいう。
- (2) F が**絶対連続**であるとは、Lebesgue-Stieltjes 測度 dF が、Lebesgue 測度 dx に対して絶対連続であることをいう： $dF \ll dx$ 。このとき、 F は密度関数 p を定める： $F(x) = \int_{-\infty}^x p(y)dy$ 。
- (3) F が**特異**であるとは、 F は関数として連続であるが、Lebesgue-Stieltjes 測度 dF が Lebesgue 測度 dx と互いに特異であるときをいう： $\exists A \in \mathcal{B}_1(\mathbb{R}) \ dF(A) = 1 \wedge m(A) = 0$ 。

注 1.4.6. F が連続であることと、これが定める Radon 積分が連続であること $\forall x \in X \int [\{x\}] = 0$ は一般に同値になる。

例 1.4.7. Cantor 関数などは、特異型分布関数の例である。

定理 1.4.8 (Lebesgue decomposition). 任意の分布関数 $F: \mathbb{R} \rightarrow \mathbb{R}$ は、不連続分布関数 F_1 、絶対連続分布関数 F_2 、特異分布関数 F_3 が一意的に存在して、これらの線型結合で表せる。

1.5 確率測度の Fourier 逆変換

特性関数の収束は確率分布の弱収束に対応する。これを用いて中心極限定理が証明される。

定義 1.5.1. 確率測度 $\mu \in P(\mathbb{R}, \mathcal{B}(\mathbb{R}))$ の**特性関数** $\varphi: \mathbb{R} \rightarrow \mathbb{R}$ とは、

$$\varphi(\xi) = \varphi_\mu(\xi) := \int_{\mathbb{R}} e^{i\xi x} \mu(dx)$$

をいう。確率変数の特性関数は、これが定める分布の特性関数とする： $\varphi(\xi) = \varphi_X(\xi) := E[e^{i\xi X}]$ 。

定理 1.5.2 (一意性定理). 特性関数の全体と確率測度の全体とに標準的な全単射が存在する。すなわち、任意の $\mu_1, \mu_2 \in \mathcal{P}^d$ について、次は同値。

- (1) $\mu_1 = \mu_2$ 。
- (2) $\varphi_{\mu_1} = \varphi_{\mu_2}$ 。

[証明] . 反転公式 7.5.3 により、任意の開区間の測度は φ が一意に定める。 ■

1.6 確率空間の生息圏：可測空間の圏

Meas は Set 上位相的である。また、完備かつ余完備である。最先端は monad と valuation の理論だと見受けられる。^a

^a There is at least some similarity of the concept of random variables to usage of the function monad (“reader monad”) in the context of monads in computer science.<https://ncatlab.org/nlab/show/random+variable>

1.6.1 Meas の特徴

定義 1.6.1 (topological category). 代数的構造を集合演算などから抽出し、空間的概念を得る構成（数 Ord, 位相空間 Top, 可測空間 Meas, 多様体 Diff）を形式化する。^{†9} 束 $U : C \rightarrow D$ を考える。 C の対象を空間とよび、射を射と呼ぶ。 D の対象を代数とよび、射を準同型と呼ぶ。

C が D 上の位相的な圏であるとは、任意の代数 $X \in D$ と任意の D -射の族 $f_i : X \rightarrow U(S_i) \in D$ に対して、initial lift $(T, m_i : T \rightarrow S_i) \in C$ が存在することをいう。 lift とは、次の条件を満たす C の対象と射の組である：

$$\forall T' \in C \exists g' : U(T') \rightarrow X \exists m'_i : T' \rightarrow S_i \quad g' \circ f_i = U(m'_i) \Rightarrow \exists ! n : T' \rightarrow T \quad U(n) = g' \wedge n \circ m_i = m'_i.$$

C の対象は D の対象と $U : C \rightarrow D$ が定める initial structure / weak structure の組として表せる。

例 1.6.2 (Meas). $D = \text{Alg}_\sigma \subset \text{Set}$ とすると、 $C = \text{Meas}$ である。

定義 1.6.3 (Borel 可測空間). 関手 $\mathcal{B} : \text{Top} \rightarrow \text{Meas}$ に対して、 $\mathcal{B}(S)$ を Borel σ -加法族という。

1.6.2 Meas での極限構成

Meas は cartesian category ではないのは周知の事実である（直積測度の選択はエントロピー最大の公理を必要とする恣意的なものであり、Fubini の定理で議論される）。そこでも出来る直積構成がある。Kolmogorov product は一般の symmetric semicartesian monoidal category^aで定義され、無限次元のテンソル積を構成する方法である。cartesian である場合は、直積の概念と一致する。

^a CMC とは直積によって圏のモノイド構造＝テンソル積が与えられる圏であるが、一般にテンソル積の単位が終対象によって与えられる時、もうすでに十分「直積っぽい」ということで SMC という。

命題 1.6.4 (完備かつ余完備). Meas は完備かつ余完備である。すなわち、全ての図式は極限と余極限をもつ。

定義 1.6.5 (filtered category). filtered category とは、任意の有限な図式が余錐を持つような圏をいう。有向集合の圏化された概念である。

定義 1.6.6 (lattice of projections, lattice of finite projections, Kolmogorov product). $(C, \otimes, 1)$ を symmetric semicartesian monoidal category とする。^{†10}

- (1) C の対象の有限列 $(X_n)_{n \in \mathbb{N}}$ について、射影のなす有限 Boole 代数（を細い圏とみなした圏） B から C への関手 $B \rightarrow C$ が存在する。これを射影の束という。
- (2) C の対象の族 $(X_i)_{i \in I}$ について、任意の有限部分集合 $F, S \subset I$, $S \subset F$ に対して $\bigoplus_{i \in F} X_i \rightarrow \bigoplus_{j \in S} X_j$ の形をした射影のなす束からの関手 $B \rightarrow C$ が存在する。これを有限な射影の束という。
- (3) 有限な射影の束 $B \rightarrow C$ は cofiltered diagram である。この cofiltered limit が存在するとき、これをコルモゴロフ積という。

^{†9} 全て $D = \text{Set}$ の例だが、 $D = \text{Grp}$ として、位相群などを考えても良い。

^{†10} すなわち、 C は終対象 1 をもち、これを単位とするモノイド構造 $\otimes : C \times C \rightarrow C$ を備える。

1.7 線型汎関数

統計的問題では線型汎関数の推定が主眼となる所以である

モデル上の汎関数 $\mathcal{P} \rightarrow \mathbb{R}$ を母数という。標本空間 \mathcal{X}^n 上の関数 $\mathcal{X}^n \rightarrow \mathbb{R}$ をその推定量という。

1.7.1 1次元の場合

確率変数なる枠組みを採用すると、確率測度は $\text{Meas}(\mathcal{X}, \mathbb{R})$ 上の線型作用素を定め、これを E で表す。ここから派生した作用素が重要な特徴量を定める。

定義 1.7.1 ((population) mean / expectation, (population) variance). 線型作用素 $\text{Meas}(\mathcal{X}, \mathbb{R}) \rightarrow \mathbb{R}$ を定める。

- (1) $E[X] := \int_{\Omega} X(\omega)P(d\omega)$ が実数であるとき、特に離散の場合は $\sum_{\omega \in \Omega} X(\omega)P\{\omega\}$ を X の(母)平均という。^{†11} $E(X, A) := E(X1_A)$ と表す。
- (2) $\text{Var}[X] = V[X] := E[(X - EX)^2]$ が有限であるとき、これを分散という。
- (3) $\text{Cov}(X, Y) = V(X, Y) := E[(X - EX)(Y - EY)] = E[XY] - E[X]E[Y]$ を共分散 $\text{Meas}(\mathcal{X}, \mathbb{R}) \times \text{Meas}(\mathcal{X}, \mathbb{R}) \rightarrow \mathbb{R}$ という。
- (4) $\sigma(X) = \sqrt{V(X)}$ を標準偏差という。
- (5) $R(X, Y) := \frac{V(X, Y)}{\sigma(X)\sigma(Y)}$ を相関係数という。

$E : L^1(\Omega) \rightarrow \mathbb{R}$ は

- (1) 正な線型汎関数で、
- (2) 独立確率変数の積に関して分解する $E[X_1 \cdots X_n] = E[X_1] \cdots E[X_n]$ 。

$\text{Var} : L^2(\Omega) \rightarrow \mathbb{R}_+$ は

- (1) 位置変数について不変 $\forall a \in \mathbb{R} \text{ Var}[X + a] = \text{Var}[X]$ で、
- (2) 2次の斉次性 $\forall a \in \mathbb{R} \text{ Var}[aX] = a^2 \text{Var}[X]$ を持ち、
- (3) 独立確率変数の和に対して分解する $\text{Var}[X_1 + \cdots + X_n] = \text{Var}[X_1] + \cdots + \text{Var}[X_n]$ 。

$\text{Cov} : L^2(\Omega) \times L^2(\Omega) \rightarrow \mathbb{R}$ は後述するが、退化した性質は次の通り 7.2.11

- (1) 対称性 : $\text{Cov}[X, Y] = \text{Cov}[Y, X]$ 。
- (2) 双線型性 : $\text{Cov}[aX + bY, Z] = a\text{Cov}[X, Z] + b\text{Cov}[Y, Z]$ 。
- (3) 定数で消える : $\text{Cov}[X, 1] = 0$ 。特に、 $\text{Cov}[aX + b, Y] = a\text{Cov}[X, Y]$ 。
- (4) 共分散公式 : $\text{Cov}[X, Y] = E[XY] - E[X]E[Y]$ 。

1.7.2 平均の一般化

平均とはその確率測度に関する積分である。確率変数が可分な実 Hilbert 空間値になったとき、これは Pettis 積分に対応する。 \mathbb{R}^n の分布は任意の線型汎関数による \mathbb{R} への一次元投影によって特徴付けられる (Cramer-Wold) ことは、弱可測性と Pettis 積分の結果と一致する。

命題 1.7.2 (Pettis integral). H を可分 Hilbert 空間、 $X : \Omega \rightarrow H$ を弱可測関数とする。このとき、 $\|X\| : \Omega \rightarrow \mathbb{R}$ が可積分ならば、

^{†11} 標本平均と区別していう。平均は位置 (location) 母数の例で、分散は尺度 (scale) 母数の例である。

ただ一つの元 $E[X] \in H$ が存在して,

$$\forall x \in H \quad (E[X]|x) = \int_H (X(\omega)|x) \mu(d\omega).$$

定義 1.7.3 (平均). H を可分 Hilbert 空間とし, $\mu \in P(H)$ をその上の Borel 確率測度とする. μ の平均 $m \in H$ とは, 恒等関数 $X = \text{id}_H$ の Pettis 積分とする:

$$\forall x \in H \quad \langle m, x \rangle = \int_H \langle x, y \rangle \mu(dy).$$

要諦 1.7.4. すなわち, 平均の各 x -成分は, x -成分の平均に等しい. 平均の定める線型汎関数 $F(x) = \int_H (x|y) \mu(dy) = (x|m)$ は, ランダムな $y \in H$ と内積を取ったときの期待値は m と内積を取ることと等しい, という可換性を表していると思える.

1.7.3 分散の一般化

\mathbb{R}^n の分散は $n \times n$ 行列になるが, 要は $B(H)$ の元である. 分散公式は $\text{Tr} Q = E[|x|^2] - |m|^2$ という形になる. 共分散は内積とのアナロジーで考えると極めてわかりやすい.

$\text{Cov} : L^2(\Omega; \mathbb{R}^r) \times L^2(\Omega; \mathbb{R}^c) \rightarrow M_{r,c}(\mathbb{R})$ は $\text{Cov}[X, Y] := E[(X - E[X])(Y - E[Y])^\top]$ で定まり, まるで「中心化された, 内積の逆」のようなものである 7.9.10.

- (1) エルミート対称性: $\text{Cov}[X, Y] = \text{Cov}[Y, X]^\top$.
- (2) 双線型性: $\text{Cov}[aX + bY, Z] = a\text{Cov}[X, Z] + b\text{Cov}[Y, Z]$.
- (3) 2つ合わせる: $\text{Cov}[AX, Y] = A\text{Cov}[X, Y]$. よって $\text{Cov}[X, BY] = \text{Cov}[X, Y]B^\top$.
- (4) 定数で消える: $\text{Cov}[X, I] = 0$.
- (5) 共分散公式: $\text{Cov}[X, Y] = E[XY^\top] - E[X]E[Y]^\top$.
- (6) 共分散公式を一般化すると, 一般の確率ベクトルの 2 次形式の平均についての表示を得る:

$$E[X^\top AY] = \text{Tr}(\text{Cov}[X, Y]^\top A) + E[X]^\top AE[Y].$$

$\text{Var}[X] := \text{Cov}[X, X] : L^2(\Omega; \mathbb{R}^r) \rightarrow M_r(\mathbb{R})$ を分散共分散行列という. 半正定値で (非負の固有値をもち), 直交系となる固有ベクトル系を持つ. 固有値は固有ベクトルの Rayleigh 商として表せる: $\lambda_i = \frac{\|Av_i\|^2}{\|v_i\|^2} \geq 0$.

定義 1.7.5. 双線型写像 $G : H \times H \rightarrow \mathbb{R}$ を表現する有界作用素 $Q \in B(H)$ を分散という:

$$G(x, y) = \int_H (x|z - m)(y|z - m) \mu(dz) = (Qx|y).$$

命題 1.7.6. $E[|x|^2] < \infty$ とする.

- (1) 共分散 Q は正作用素 (半正定値) であり, かつ, 対称である: $(Qx|y) = (x|Qy)$.
- (2) 跡が 2 次の中心化モーメントに等しく, $\text{Tr} Q < \infty$ である (普段見る分散とはこれである).
- (3) また 2 次のモーメントは $E[|x|^2] = \text{Tr} Q + |m|^2$ と表わせ, これを共分散公式という.
- (4) Q はコンパクト作用素である.

平均は Pettis 積分に直感的な理解を与え, 分散は跡に直感的な理解を与える.

1.7.4 他の測度に関する線型作用素

定義 1.7.7 (entropy). Shannonn のエントロピーとは自己情報量 $I(p) := -\log_2 p$ ($p \in \mathcal{G}$) が定める積分作用素 $H : \text{Meas}(\mathcal{G}, \mathbb{R}) \rightarrow [0, \log \alpha]$ である.

1.7.5 統計的推論

統計的推論において、確率論の枠組みをどのように用いるかを比較対象とする。

定義 1.7.8 (frequentist probability). 現実の事象の確率とは、仮想的に試行を繰り返したときの、相対頻度の極限として得られる極限分布として想定し、我々が眼前にする現象はこれの実現値であるという仮定をおいて行われる統計的推論である。

想定した真の確率分布の特性量の計算や、真の確率分布に対する標本からの推定などが含まれる。

例 1.7.9 (頻度主義的推論). 偏差値は、統計的な分布が正規分布で近似できることを暗黙裡に認めて算出している。この仮定が数理的に妥当であることは、確率論の結果による。

1.7.6 積分作用素に関する確率不等式

積分作用素に関する測度論的結果に、確率論的な解釈を与える。

定理 1.7.10 (Chebyshev の不等式). $\psi: \mathbb{R} \rightarrow \mathbb{R}_{\geq 0}$ を非負な Borel 可測な関数とする $\psi \geq 0$.

$$\forall A \in \mathcal{B}(\mathbb{R}) \quad P[X \in A] \leq \frac{E[\psi(X)]}{\inf_{x \in A} \psi(x)}.$$

[証明].

$$\forall x \in \mathbb{R} \quad \left(\inf_{x \in A} \psi(x) \right) 1_{\{x \in A\}} \leq \psi(x)$$

が成り立つ。両辺の期待値を取れば良い。 ■

系 1.7.11.

- (1) 特に $\psi(x) = |x|^p$ ($p > 0$), $A := \{|x| \geq \epsilon\}$ とすると, $P[|X| \geq \epsilon] \leq \frac{1}{\epsilon^p} E[|X|^p]$.
- (2) $\forall a > 0 \quad P\{|X(\omega) - EX| > a\sigma(X)\} \leq \frac{1}{a^2}$.
- (3) $f: \mathbb{R} \rightarrow \mathbb{R}_{\geq 0}$ を非負値単調増加関数とし, X を $E[|X|] < \infty, E[f(X)] < \infty$ を満たす確率変数とする. $\forall a \in \mathbb{R} \quad f(a) > 0 \Rightarrow P(X \geq a) \leq \frac{E[f(X)]}{f(a)}$.

[証明].

- (1) $\sigma(X) = 0$ のとき $\sigma(X) = 0 \Leftrightarrow X(\omega) = EX$ a.s. であるから、上の不等式は当然成り立つ。
 $\sigma(X) \neq 0$ のとき 求める事象を $A := \{\omega \in \Omega \mid |X(\omega) - EX| > a\sigma(X)\}$ とおくと、

$$\sigma(X)^2 = E(X - EX)^2 \geq E((X - EX)^2, A) \geq a^2 \sigma(X)^2 P(A)$$

と評価できる。

- (2) f が単調減少であることと, f が非負値であるから $\int_{\{X < a\}} f(X) dP \geq 0$ であることより、

$$\begin{aligned} E[f(X)] &= \int_{\{X \geq a\}} f(X) dP + \int_{\{X < a\}} f(X) dP \\ &\geq f(a) P(X \geq a). \end{aligned}$$

要諦 1.7.12 (平均値から標準偏差の a 倍以上離れる確率は $\frac{1}{a^2}$ 以下である.)。まさかそんなに当然な評価の変形だったのか。

補題 1.7.13. 凸関数 $\psi: \mathbb{R} \rightarrow \mathbb{R}$ について, $X, \psi(X) \in \mathcal{L}^1(X)$ のとき、

$$\psi(E[X]) \leq E[\psi(X)].$$

補題 1.7.14. 共役指数 $p, q \in [1, \infty]$ について, $\|fg\|_1 \leq \|f\|_p \|g\|_q$. 特に $p = q = 2$ のとき $E[XY] \leq \sqrt{E[X^2]E[Y^2]}$ で, さらに $Y = 1$ のとき $(E[X])^2 \leq E[X^2]$.

1.7.7 Lebesgue 空間の包含関係

定理 1.7.15. 確率空間において, $p < q \in [1, \infty]$ のとき, $\mathcal{L}^q(X) \subset \mathcal{L}^p(X)$ かつ $\|\cdot\|_p \leq \|\cdot\|_q$ である.

1.8 σ -加法族が定める構造 (要再考)

実は, 確率論で直積測度を考えるときは, 暗黙にエントロピー最大の原理を仮定している. 確率論の枠組みではエントロピーを厳密に定義でき, これは系の状態を決定するために必要な情報量=乱雑さの小ささを計っている. Entropy is a measure of disorder, given by the amount of information necessary to precisely specify the state of a system.^a

^a <https://ncatlab.org/nlab/show/entropy>

注 1.8.1 (情報としての σ -加法族). σ -代数の細かさによって, 観察の粒度を表現する. 「情報」が追加されるたびに確率測度 P を取り替えるのではなく, P は一つの固定されたものと考えて「情報」の変化は σ -加法族の細分化として表現する. 新たに追加されていくのである. 例えば, 確率変数 X の値がわかれば X^2 の値もわかるが, 逆は成り立たない. すなわち, σ -加法族の引き戻しについて, $(X^2)^*(\mathcal{G}) \subseteq X^*(\mathcal{G}) = (X^3)^*(\mathcal{G})$.^{†12}したがって, 外から観測できる範囲は (Ω, \mathcal{F}, P) の σ -部分代数を自然になるので, これは情報を表すと考えると自然である.^{†13}こうして, 確率変数 X が \mathcal{F}_t 可測である, というと, 時刻 t 時点の情報で値が (確率 1 で) 定まっていることになる.^{†14}そこで, 問題は平均 $E[X_n | \mathcal{F}_m]$ ($m < n$) を求めることとなる. したがって, このモデルでは条件付き確率だけである.

定義 1.8.2 (関数が生成する σ -加法族). 関数 $X_1, \dots, X_n : \Omega \rightarrow \mathcal{X}$ に対して, これら全てを可測とするような Ω 上の最小の σ -加法族を $\sigma(X_1, \dots, X_n)$ で表す.

定義 1.8.3 (principle of maximum entropy).

- (1) $\Omega_1 \times \Omega_2$ が考えている試行 $T_1 \times T_2$ を試行の直結合という.
- (2) 次の図式を可換にする確率測度 \tilde{P} は一般に複数存在するが, $\tilde{P}\{(\omega_1, \omega_2)\} = P_1\{\omega_1\}P_2\{\omega_2\}$ を満たすものは Hahn-Kolmogorov の定理よりただ一つである.
- (3) これを直積測度の公理としても良いし, エントロピー最大の原理からも従う. 確率測度 P のエントロピーとは, $\epsilon(P) := \sum_{i=1}^m P\{a_i\} \log \frac{1}{P\{a_i\}}$ ($\Omega = \{a_i\}_{i \in [m]}$) と定まる.

定義 1.8.4 (surprisal / self-information / information content, expected surprisal, almost partition, entropy). (X, \mathcal{M}, μ) を確率空間とする.

- (1) 可測集合 $A \in \mathcal{M}$ の新鮮さとは, $\sigma_\mu(A) := -\log \mu(A) = \log \frac{1}{\mu(A)} (\geq 0)$ をいう. ただし, $\mu(A) = 0$ の時は $\sigma_\mu(A) = \infty$ とする. これは可測関数 $\sigma_\mu : \mathcal{M} \rightarrow [0, \infty]$ を定める. 「もしその事象 $A \in \mathcal{M}$ が起こったら観測者がどれほど驚くか」をモデリングしていると考えられる. $\mu(A) = 1$ のとき, $\sigma_\mu(A) = 0$ であり, $\mu(A) = 0$ のとき, $\sigma_\mu(A) = \infty$ である.
- (2) $h_\mu(A) := \sigma_\mu(A)\mu(A)$ を期待驚愕度という. このとき $\mu(A) = 0 \Rightarrow h_\mu(A) = 0$ である. これは $\mu(A) = e^{-1}$ のときに最大値 $e^{-1} \log e$ を取り, $h_\mu(\emptyset) = h_\mu(X) = 0$ を満たす上に凸な関数である.
- (3) 合併が full set, 任意の 2 つの共通部分が零集合となるような X の族を概分割という.

^{†12} この考え方を確率変数が定める filtration $\sigma[X_0, \dots, X_n]$ という.

^{†13} 例えば事象 $B \in \mathcal{F}$ の与える情報は σ -加法族 $\{\emptyset, \Omega, B, \Omega \setminus B\}$ で表されると考えられる.

^{†14} サイコロを 2 回振る事象は, 2 回降った時点で値が 0, 1 の 2 値に収束するはずである. 情報 \mathcal{F}_t がどこから来たかは不問とする. この間に σ -代数の構造があるため, 他の確率分布 $\mathcal{X} \rightarrow \mathbb{R}$ からの引き戻しや, 他の事象についての知識からも持って来れるはず.

(4) σ -加法族 \mathcal{M} のエントロピーとは,

$$H_\mu(\mathcal{M}) := \sup \left\{ \sum_{A \in \mathcal{F}} h_\mu(A) \in \mathbb{R}_{\geq 0} \mid \mathcal{F} \subset \mathcal{M}, |\mathcal{F}| < \omega, X = \bigcup \mathcal{F} \right\}$$

のことをいう。 X の可測集合による有限な直和分割の期待驚愕度の和として定められる。^{†15}なお、実際 \mathcal{F} は X の概分割で十分である。

要諦 1.8.5. \log は本質的ではない。 $1 \mapsto 0, 0 \mapsto \infty$ を満たす関数で、 $\frac{1}{x}$ より急激でないものならば良かったのではないかな。また、 \log の底は分野によってさまざまである。Shannon の entropy では2,

1.9 分割と情報

ぼくが数学を始めるきっかけとなった写像の標準分解：写像が定める同値類と写像との関係と全くパラレルである。 X が定める同値関係が Y より細かいこと (正確には $\exists N \in \mathbb{N}(\Omega) \forall \omega_1, \omega_2 \in \Omega \setminus N \ X(\omega_1) = X(\omega_2) \Rightarrow Y(\omega_1) = Y(\omega_2)$) と、 $\mathcal{F}[Y] \subset \mathcal{F}[X]$ は同値である。 X はものの位置でもなんでも、あらゆる物理的観測を表し得る。観測は Ω の分割を定め、分割は σ -代数を生成する。

記法 1.9.1. 確率変数 X に対して、これが Ω 上に定める分割が生成する最小の閉 σ -代数を $\mathcal{F}[X] < \mathcal{D}(P)$ で表すこととしよう。すなわち、 $(\Omega, \mathcal{D}(P), P)$ 上の、 $\mathcal{D}(P)$ の部分 σ -代数であって、すべての P -零集合を含むものを閉 σ -代数といい、 $\Phi = \Phi(\Omega, P) = \{\mathcal{B} \vee 2 < \mathcal{D}(P) \mid \mathcal{B} < \mathcal{D}(P)\}$ でらわす。

定義 1.9.2.

- (1) 可測関数 $X: \Omega \rightarrow S$ について、 $\mathcal{F}[X] := X^{-1}(\mathcal{D}(P^X)) \vee 2$ を、 X で生成される閉 σ -代数という。これは、 X を可測にする閉 σ -代数の中で最小のものである。
- (2) 確率変数の族 $\{X_\lambda\}_{\lambda \in \Lambda}$ については、 $\mathcal{F}[X_\lambda, \lambda \in \Lambda] := \bigvee_{\lambda \in \Lambda} \mathcal{F}[X_\lambda]$ と表す。

定理 1.9.3 (すべての閉 σ -代数はある観測の結果とみなせる). 任意の閉 σ -加法族 \mathcal{F} に対して、ある実確率変数 $X \in \mathcal{L}(\Omega)$ が存在して、 $\mathcal{F} = \mathcal{F}[X]$ が成り立つ。

定理 1.9.4. $X, Y \in \mathcal{L}(\Omega)$ について、 $X < Y$ a.s. $\Leftrightarrow [\exists \varphi \in \text{Map}(\Omega, \Omega) \ X = \varphi \circ Y$ a.s.] と表すと、これは同値類 \sim とその上の順序を定め、

- (1) $Y < X$ a.s. $\Leftrightarrow \mathcal{F}[Y] \subset \mathcal{F}[X]$.
- (2) $Y \sim X$ a.s. $\Leftrightarrow \mathcal{F}[Y] = \mathcal{F}[X]$.

^{†15} こういうものは本当に極限構成になっている。 X の可算な分割は directed で h_μ は concave であるため。

第 2 章

有界測度論

確率分布を測度として定式化したが、まずは、有界な測度（を正規化したもの）としての純粋な性質を調べる。有界な測度は直ちに局所有限でかつ内部正則であるので、Radon 測度である。そして Radon 測度が有限であるとき、(外部) 正則な Borel 測度である。

- (1) 測度の収束には種々の位相が考えられ、修羅の相を呈している。ここで重要になる有界測度特有の概念に緊密性があり、有界測度の列が緊密であるとき、3つの関数のクラス $C_c(X), C_0(X), C_b(X)$ が定める収束概念は一致する。その上、緊密な確率測度列の収束先は再び確率測度となる。
- (2) 確率変数に収束の概念が多様に定義できる。その方法は確率変数の可測性に依らないので、なるべく一般的な形で述べる。
- (3) 次に、確率変数の標準的な構成法を測度論の形で与える。実際に確率測度なる対象が存在することの保証も数学的には肝要である。

2.1 確率測度の収束

Banach 空間論の発展を後押しした消息

確率変数は、確率測度を押し出す。この構造を用いて確率変数の収束「法則収束」を定義するから、まずは測度の収束を論じる。

測度の弱収束の理論は、A. D. Alexandorff と Prohorov による。Cramer-Wold のように、線型汎関数が定める 1 次元周辺分布が確率測度を決定する消息がある。そこで、測度の弱収束は、その上の有界線型汎関数を通じて定義することは自然である。

凸解析と関数解析が肝要となる。Alexandroff 自身も、凸集合の幾何の研究が、自身の抽象測度論の研究の源泉になったと言っている。経験過程は極点の凸結合であると捉えられる。極点の凸結合の極限で真の分布を探そうとする営みが経験過程論であるか！？

2.1.1 測度と積分の双対性

測度の双対空間と前双対空間

測度の空間の位相は、双対空間から入れるから、測度の空間の双対空間と predual とを考察しておく必要がある。

この消息ははじめ Radon 1913^aによって研究され、その位相を「弱収束」と呼んだ。1907 年に Riesz の表現定理が独立に証明され、Hilbert 空間の研究が進んでいた頃からの用語で、Banach が「弱収束」と「*-弱収束」を一般のノルム空間上に定義した 1929 年よりも前の用語である。

^a Radon, J. Theorie und Anwendungen der absolut additiven Mengenfunktionen. Sitz. Akad. Wiss. Wien, Math.-naturwiss. Kl. IIa. 1913. B. 122. S. 1295 – 1438. [245, 246]

記法 2.1.1. X を Hausdorff 空間、 X の Borel 集合体を \mathcal{A} 、Borel σ -集合体を \mathfrak{B} で表し、 \mathcal{A} 上の有限加法的な正則 Borel 符号付

測度の空間を $M_f(X)$, \mathcal{G} 上の σ -加法的な正則 Borel 符号付測度の空間を $M_\sigma(X)$ で表す. これらに全変動ノルムを入れると, 有限な加法的集合関数は有界変動だから, そのままノルム空間となる. 明らかに, $M_f(X) \subset C_b(X)^*$ である.

定義 2.1.2 (Radon measure, Radon charge).

(1) (X, \mathcal{G}) 上の Borel 測度 $\mu : \mathcal{G} \rightarrow [0, \infty]$ が **Radon 測度** であるとは, 次の 2 条件を満たすことをいう:

- (a) locally finite : $\forall x \in X \exists x \in C \subset X \mu(C) < \infty$.
- (b) inner regularity / tightness : $\forall_{B \in \mathcal{G}} \mu(B) = \sup_{K \subset B} \mu(K)$.

実は, Radon 測度は測度確定な可測集合 $B \in \mathcal{M}^1$ について, 外正則でもある.

(2) (X, \mathcal{G}) 上の **Radon 電荷** とは, 複素測度 $\mu : \mathcal{G} \rightarrow \mathbb{C}$ であって, 全変動測度 $|\mu| : \mathcal{G} \rightarrow [0, \infty]$ が Radon 測度であるものをいう. ただし, 複素測度の全変動とは, $|\mu|(E) = \sup \sum_{i=1}^{\infty} |\mu(E_i)|$ として定まる写像をいう. 実は複素測度は必ず有界変動を持ち, 全変動 $|\mu|(X)$ をノルムとして Banach 空間をなす. これを $RM(X)$ で表す.

定理 2.1.3 (Radon 測度と Radon 積分の等価性). X が局所コンパクトでもあるとき, (X, \mathcal{G}) 上の Borel 測度 $\mu : \mathcal{G} \rightarrow [0, \infty]$ について, 次の 2 条件は同値:

- (1) μ は Radon 測度である.
- (2) μ が定める写像 $C_c(X; \mathbb{R}) \ni f \mapsto \int f d\mu$ は正な線型汎関数である.

命題 2.1.4 (Alexandrov (1940): 有限加法的集合関数の表現). X を任意の正規空間とする. 任意の有界汎関数 $\Lambda \in C_b(X)^*$ に対して, ただ一つの $\mu \in M_f(X)$ が存在して, $\forall f \in C_b(X) \Lambda(f) = \int_X f d\mu$ を満たし, $\|\Lambda\| = \|\mu\|$ を満たす. すなわち, Banach 空間として等長同型である $C_b(X)^* \simeq_{\text{Ban}} M_f(X)$.

命題 2.1.5 (Riesz-Markov-Kakutani representation theorem). 局所コンパクトハウスドルフ空間 X について,

- (1) 正な有界線型汎関数のなす正錐と, Radon 測度のなす正錐 $\overline{M(X)_+}$ とは, 位相同型である: $(C_c(X, \mathbb{C})_+)^* \simeq_{\text{Top}} \overline{RM(X)_+}$.
- (2) 等長同型が存在する: $C_0(X, \mathbb{C})^* \simeq_{\text{Ban}} M(X)$.

2.1.2 測度の収束の定義 4 種

w^* -位相と呼んでも確率測度については well-defined であるが, 点列の収束としてはやはり別物

局所コンパクトハウスドルフ空間 X 上の

$$\int f d\mu_n \rightarrow \int f d\mu$$

が定める測度の収束概念 $\mu_n \rightarrow \mu$ は, 確率測度に限れば, $f \in C_b(X)$ としても $f \in C_c(X)$ としても同じ位相を定める. これらはまとめて w^* -位相または弱位相と呼ばれるが, 唯一の違いは $P(X) \subset M(X)$ 自体のコンパクト性である. 一般に $P(X)$ は $\sigma(P(X), C_c(X))$ -コンパクトとは限らないため, 収束先が $P(X)$ に収まらない可能性だけが問題となり, これは一様緊密性の仮定をおくことで解決される (Prohorov). そこで収束としては「弱位相」と「漠収束」と呼び分けることとなる.

$P(X)$ に限らなければ, Alexandrov の結果より $M(X) = (C_0(X))^* \subsetneq M_f(X) = (C_b(X))^*$ であるから, $M(X)$ に $\sigma(M(X), C_b(X))$ -位相を入れると $\sigma(M(X), C_c(X))$ -位相より強くなるはずである.

測度の空間は Banach 空間であるが, それ以上に具体的対象である.

一般に測度の空間は Banach 空間となり, この Banach 空間としての弱収束と, 「測度の弱収束」は相違する. そこで, Banach 空間としての弱収束と同じ文脈で議論したい場合, 有界測度論では Bourbaki の言葉を借りて「狭収束」と呼ばれる. しかし X が局所コンパクト空間であるとき, 測度の空間に対して前節で議論したような表現定理が成り立つ. すると, 測度という概念の性質上, 双対空間の部分空間のクラス $C_c(X) \subset C_0(X) \subset C_b(X) \subset M(X)^*$ に応じて, 特別な位相が入るのである. $C_b(X)$ が定める強い位相を弱収束といい, $C_c(X), C_0(X)$ が定める弱い位相を混同して漠収束という. 3 つとも言うなれば Banach 空間の w^* -位相であり, この表現では区別が出来ない. それぞれ

$\sigma(M(X), C_b(X)), \sigma(M(X), C_c(X)), \sigma(M(X), C_0(X))$ -位相と言うよりほかはない。ここでは、 $\sigma(M(X), C_c(X))$ -位相を漠位相ということとする。

定義 2.1.6 (strong, weak, narrow, wide / vague / weak star). 可測空間 (X, \mathcal{G}) 上の有界変動を持つ符号付き Radon 測度の空間 $M(X)$ ^{†1} は、全変動 $|\mu|$ が定めるノルムについて Banach 空間をなす。ノルム位相と異なる位相で代表的なものは以下の通りである。^{†2}

- (1) まず各可測集合上での収束 (setwise convergence) が考えられる。
- (2) ノルム収束は、変動収束 (convergence in variation) または強収束とも言う。
- (3) 任意の有界線型汎関数 $F \in M_b(X)^*$ について $F(\mu_n) \rightarrow F(\mu)$ を満たすとき、**弱収束**という。
- (4) X が位相空間で、 \mathcal{G} が Borel σ -代数であるとき、任意の有界連続関数 $f \in C_b(X)$ について $\mu_n f \rightarrow \mu f$ を満たすとき、**狭収束** (narrow topology), また確率測度に限っては**弱収束**という。^{†3} X が局所コンパクトハウスドルフ空間であるとき、 μ_n が μ に狭収束するならば、 $\forall A \in \mathcal{G}(X) \quad |\mu|(\partial A) = 0$ が必要であり、これが狭収束を特徴付ける。^{2.1.15}
- (5) X が局所コンパクト空間で、 \mathcal{G} が Borel σ -代数であるとき、更に別の位相が定まる。任意のコンパクト台を持つ連続関数 $f \in C_c(X)$ について $\mu_n f \rightarrow \mu f$ を満たすとき、**広収束** (wide topology) または **w^* -収束**という。一般に狭位相より弱い、 X が Hausdorff のとき、確率測度の空間 $P(X)$ には同じ位相を定める。なお、 $P(X)$ は広位相についてコンパクトとは限らない、すなわち収束先は $\mu(X) = 1$ を満たさないことがある。^{†4}

例 2.1.7 (退化する例：コンパクトハウスドルフ空間). X がコンパクトハウスドルフであるとき、Riesz の表現定理は同型 $M_b(X) = (C(X))^*$ を引き起こす。このとき、 $C(X) = C_c(X) = C_0(X) = C_b(X)$ であるから、狭位相、広位相はいずれも (関数解析の意味で) w^* -位相と一致する。^{†5}

例 2.1.8 (局所コンパクトハウスドルフ空間での例). X が局所コンパクトハウスドルフ空間であるとき、Riesz-Markov-Kakutani の定理より $M_b(X) = (C_0(X))^*$ を得て ^{2.1.5}, 同時に $M(X) = (C_c(X))^*_+$ を満たす^{??}。なお、 $M_b(X)$ は有限 Radon 測度の空間で、 $M(X)$ は Radon 測度全体の空間とした。よって、いずれも (特定の predual に対する) w^* -位相を備えるが、位相としては別物である。 δ_n は 0 に C_c -収束するが、 C_0 では収束しない： $f(x) = \sin(x)/x$ を取ると収束しない。

一方で、 $C_b(X)$ の双対空間の中には、測度として表せないものも存在する ^{2.1.4}。これは $M(X) \subsetneq M_f(X) = (C_b(X))^*$ ^{2.1.4} という意味では、 w^* -位相の相対位相である。

例 2.1.9 (実数上の測度の収束). $X = \mathbb{R}$ のとき、 $1_{[a,b]}$ という形の特整関数が生成する部分空間は、 $C_0(\mathbb{R})$ 上稠密であるから、漠位相は「ある稠密部分集合 $D \subset \mathbb{R}$ が存在して、 $\forall a < b \in D \quad \mu_n((a, b]) \rightarrow \mu((a, b])$ 」を満たすことと同値になる。

要諦 2.1.10 (緊密性とは、この消息によって要求される確率論的概念である)。こうして、 (δ_n) の例などを省くためには、確率測度の列がある種のコンパクト性を満たす必要がある。緊密性を $\forall \epsilon > 0 \quad \exists K_{\epsilon} \subset X \quad \forall n \in \mathbb{N} \quad \mu_n(K_{\epsilon}^c) < \epsilon$ と定めると、意味は the sequence of measures are all almost supported in a compact set, so there is no possibility of mass "escaping at infinity" as it was the case with (δ_n) 。^{†6} 特に、Radon 測度 (μ_n) が緊密ならば μ_n は有限である。

こうして、標準的な設定が出来上がる。有界測度の列が緊密であるとき、3つの関数のクラス $C_c(X), C_0(X), C_b(X)$ が定める収束概念は一致する。

^{†1} 符号付き測度は、有限ならば有界変動を持つ。

^{†2} https://encyclopediaofmath.org/wiki/Convergence_of_measures

^{†3} Bourbaki による造語で、いまでは稀。元々は "convergence étroite"。

^{†4} 例は極点の列 (δ_n) が与える。 X がコンパクトであるとき、 $\mu(X) = 1$ を必ず満たす。

^{†5} なお、一般に $C(X)$ は回帰的でなく、双対空間 $(M_b(X))^*$ は $C(X)$ より広いから、 w^* -位相は弱位相より弱いことは関数解析の結果である。

^{†6} <https://math.stackexchange.com/questions/313986/are-vague-convergence-and-weak-convergence-of-measures-both-weak-convergence>

2.1.3 確率測度のノルム収束

Radon 電荷の Banach 空間 $M(\Omega)$ 上でのノルム収束を、全変動収束という。その双対空間は $C_0(\Omega, \mathbb{C})$ であるが (Riesz-Markov), この元に対する収束が弱収束である。確率測度の空間 $P(X)$ はもちろんノルム閉ではないが、凸である。

補題 2.1.11 (確率測度の全変動距離の特徴付け). $\mu, \nu \in P(\Omega, \mathcal{F}, P)$ について,

$$\|\mu - \nu\| = 2 \sup_{A \in \mathcal{F}} |\mu(A) - \nu(A)|.$$

系 2.1.12 (Scheffe). $\{X_n\}, X \ll \mu$ とする. $p_n \rightarrow p$ μ -a.e. が成り立つならば, X_n は X に全変動ノルムについて収束する: $\|X_n - X\| \rightarrow 0$.

2.1.4 弱収束の定義と特徴付け

定義 2.1.13 (weak convergence of measure, vague convergence). 一般の局所コンパクトハウスドルフ空間 X について, Riesz の表現定理より $P(X) \subset M(X) \simeq C_0(X)^*$ と同一視出来る。この Borel 可測空間 $(X, \mathcal{B}(X))$ 上の確率測度の空間 $P(X) \subset C_0(X)^*$ の列 (μ_n) について,

- (1) $\forall f \in C_b(X) \int_X f d\mu_n \rightarrow \int_X f d\mu$, 平均で表すと $\forall f \in C_b(X) E[f(X_n)] \rightarrow E[f(X)]$ を, **測度の弱収束**と呼ぶ。これを $\mu_n \Rightarrow \mu$ と表す。
- (2) さらに条件を弱めて $\forall f \in C_0(X) \int_X f d\mu_n \rightarrow \int_X f d\mu$ は w^* -位相に対応し, **漠収束**と呼ばれる。^{†7}これは上述の狭位相と広位相が退化して一つになったものである。

要諦 2.1.14. $C_b(X)$ を試験関数とした場合は, 確率変数が無限遠へ飛ぶ場合のすべてを検知するが, $C_c(X) \subset C_b(X)$ を用いた場合は見逃す場合がある。

定理 2.1.15 (Portmanteau 定理: 弱収束の特徴付け (Alexandroff)^{†8}). $\{\mu_n\} \subset P(\mathbb{R}), \mu \in P(\mathbb{R})$ について, 次の 5 条件は同値。これは一般の距離空間 X について成り立つ。

- (1) $\mu_n \Rightarrow \mu$.
- (2) 任意の開集合 $G \subset \mathbb{R}$ について, $\liminf_{n \rightarrow \infty} \mu_n(G) \geq \mu(G)$.
- (3) 任意の閉集合 $C \subset \mathbb{R}$ について, $\limsup_{n \rightarrow \infty} \mu_n(C) \leq \mu(C)$.
- (4) $A \in \mathcal{B}(\mathbb{R})$ について, $\mu(\partial A) = 0 \Rightarrow \lim_{n \rightarrow \infty} \mu_n(A) = \mu(A)$. この条件を満たす集合 A を **P -連続集合**という。^{†9}
- (5) μ_n, μ が定める分布関数 F_n, F について, $\forall x \in \mathbb{R} \lim_{y \nearrow x} F(y) = x \Rightarrow \lim_{n \rightarrow \infty} F_n(x) = F(x)$.

また, 次とも同値。

- (6) 任意の一樣連続な有界関数 f について, $P_n f \rightarrow P f$. なお, 有界性の仮定を外しても同値である。
- (7) 任意の非負有界連続関数 f に関して, $\liminf_{n \rightarrow \infty} P_n f \geq P f$.

定理 2.1.16 (その他の集合族による特徴付け). 距離空間上の測度空間 $(X, \mathcal{B}(X))$ について, $\mathcal{A} \subset \mathcal{B}(X)$ を乗法族とする: $X \in \mathcal{A}, \forall A, B \in \mathcal{A} A \cap B \in \mathcal{A}$. 任意の開集合が \mathcal{A} の元の可算和で表せるとき, $\forall A \in \mathcal{A} P_n(A) \rightarrow P(A)$ は $P_n \Rightarrow P$ を含意する。

定理 2.1.17 (3つ目の特徴付け). 列 (P_n) が P に弱収束するための必要十分条件は, これが相対コンパクトであること, すなわち任意の部分列 (P_{n_i}) が, P に弱収束する部分列を持つことである。

^{†7} これを弱位相と呼ぶこともあるが, $C_0(X)$ はほとんど回帰的である例がないので, 不適切である。

^{†8} I don't know who invented such a nonsensical name for Alexandroff's theorem.[3]

^{†9} このような集合は体/代数をなす。

2.1.5 漠収束の特徴付け

命題 2.1.18 (漠収束の特徴付け). $\{\mu_n\} \subset P(\mathbb{R}), \mu \in M(\mathbb{R})$ について, 次の2条件は同値.

- (1) (μ_n) は μ に漠収束し, $\mu \in P(\mathbb{R})$ を満たす.
- (2) (μ_n) は μ に弱収束する.

2.1.6 一様収束のための十分条件

必要になったらで.

定理 2.1.19 (Ranga Rao (62)). X を可分な距離空間, (μ_n) をその上の確率測度の列とする. このとき, 次の2条件は同値.

- (1) $\mu_n \Rightarrow \mu$.
- (2) 任意の関数族 $\mathcal{F} \subset C_b(X)$ であって, 一様に有界で, 同程度連続であるものについて, $\lim_{n \rightarrow \infty} \sup_{f \in \mathcal{F}} |\mu_n f - \mu f| = 0$ が成り立つ.

2.1.7 連続写像定理

記法 2.1.20. 距離空間 (S_i, d_i) ($i = 1, 2$) と, 確率測度 $\nu, \nu_n \in P(S_1)$ と可測写像 $T: S_1 \rightarrow S_2$ について,

命題 2.1.21. $\nu_n \rightarrow \nu$ かつ T が連続ならば, $\nu_n^T \rightarrow \nu^T$.

補題 2.1.22. 可測写像の列 $\{T_n\} \subset \text{Meas}(S_1, S_2)$ について, 次の条件は同値.

- (C) x に収束する S_1 の任意の点列 (x_n) について, $T_n(x_n) \rightarrow T(x)$ が成り立つ.
- (C') $\forall \epsilon > 0 \exists (n_0, \delta) \in \mathbb{N} \times \mathbb{R}_+ \forall (n, x') \in \mathbb{N} \times S_1 \ n \geq n_0 \wedge d_1(x, x') < \delta \Rightarrow d_2(T(x), T_n(x')) < \epsilon$.

定理 2.1.23. $\nu_n \rightarrow \nu$ とする. ある full set $C \in \mathcal{B}(S_1), \nu(C) = 1$ が存在して, この上で $x \in C$ は条件 (C) を満たすとする. このとき, $\nu_n^T \rightarrow \nu^T$.

系 2.1.24. 可測写像 $T: S_1 \rightarrow S_2$ は, $\nu(C) = 1$ なる可測集合 $C \in \mathcal{B}(S_1)$ 上各点連続であるとする. このとき, $\nu_n \rightarrow \nu$ ならば $\nu_n^T \rightarrow \nu^T$.

2.2 確率測度の空間

$P(X)$ の幾何学的性質が基礎的になってくるので, ここにまとめることとする.

記法 2.2.1. X を距離空間とし, その上の Borel 確率測度のなす空間を $P(X)$ と表す. 距離空間 X 上の Dirac 測度全体の集合を $\Delta \subset P(X) \subset C_b(X)^*$ で表す.

2.2.1 可分性と距離付け可能性

補題 2.2.2. X は, 弱位相における Δ と位相同型である.

補題 2.2.3. Δ は $P(X)$ 内で点列コンパクトである.^{†10}

補題 2.2.4. X を全有界な距離空間とする. X 上の有界な一様連続関数の集合 $U(X) \subset C_b(X)$ は, 一様ノルムの下で可分な Banach 空間となる.

^{†10} 一般に部分集合 $A \subset X$ の閉包 \bar{A} は点列閉包 B を含むが, 点列閉包と一致するのは一般に X が距離空間の場合のみ.

定理 2.2.5 (確率測度の空間の弱位相の距離化可能性). 次の2条件は同値.

- (1) X は可分な距離空間である.
- (2) 弱位相を備えた $P(X)$ は距離付け可能で可分である.

例 2.2.6 (Levy-Prokhorov 距離). $B_\epsilon(E) := \{x \in X \mid \rho(x, E) < \epsilon\}$ と表す.

$$\eta(\mu, \nu) := \inf \{ \epsilon > 0 \mid \forall E \in \mathcal{B}(X) \mu(E) \leq \nu(B_\epsilon(E)) + \epsilon \wedge \nu(E) \leq \mu(B_\epsilon(E)) + \epsilon \}$$

は距離を定め, これが定める位相は $*$ -弱位相に一致する. 対応する分布関数の空間の距離を Levy の距離といい, これが先に提出され, Prokhorov がこの形に一般化した.

例 2.2.7 (1-Wasserstein distance / Kantorovich-Rubinstein distance / Monge-Kantorovich distance). さらに X を完備とする (すべて併せてポーランド空間とする). このとき, 次は $P(X)$ の距離を与える:

$$W_1(\mu, \nu) = \sup \left\{ \int \varphi d\mu - \int \varphi d\nu \in \mathbb{R} \mid \varphi \in \text{Lip}(X; \mathbb{R}), L(\varphi) \leq 1 \right\}.$$

2.2.2 稠密部分集合の遺伝

定理 2.2.8. X を可分距離空間, $E \subset X$ は稠密とする. E に含まれる可測集合上のみに台をもつ確率測度のなす部分空間

$$\{\mu \in P(X) \mid \text{supp } \mu \subset P(E)\}$$

は $P(X)$ 内で稠密である.

2.2.3 コンパクト性

定理 2.2.9 (可算稠密部分集合の構成). X を可分距離空間, D をその可算な稠密部分集合とする. このとき, D の有限部分集合を台とするような確率測度のなす集合 $F(D)$ は, $P(X)$ において稠密である.

系 2.2.10. D が可分である時, Dirac 測度としての標準的な埋め込み $D \hookrightarrow \mathcal{M}(D)$ の像の凸包は稠密である.

定理 2.2.11 (コンパクト性 (Bogoliubov and Krylov)). 距離空間 X について, 次の2条件は同値.

- (1) X はコンパクトである.
- (2) $P(X)$ は弱コンパクトで距離化可能.

2.2.4 完備性

定理 2.2.12 (完備性). 可分な距離空間 X について, 次の2条件は同値.

- (1) X は完備である.
- (2) $P(X)$ は完備である.

定理 2.2.13. D がポーランドである時, $\mathcal{M}(D)$ もポーランドである.

2.2.5 相対コンパクト集合の特徴付け

ここで緊密性の概念が出現する. [2.1.10](#) も参照. 例えば mass が無限遠点に逃げていく列などが省かれる.

定義 2.2.14 (totally bounded / weakly compact). 確率測度の族 $\Gamma \subset P(X)$ が相対コンパクトであるとは, 任意の列について, ある部分列が存在してこれが弱収束することをいう.

要諦 2.2.15. 可分距離空間 X 上の確率測度の空間 $P(X)$ の弱位相は距離化可能で可分である 2.2.5. 距離空間について、可分性と全有界性とは同値である。また、距離空間について、コンパクト性と点列コンパクト性と「完備かつ全有界」であることは同値だから、 S が完備可分距離空間である場合、相対コンパクト性を全有界ともいう（完備距離空間において、コンパクト集合と閉集合とは同値）。

定義 2.2.16 ((uniformly) tight / tendue). 確率測度の族 $\Gamma \subset P(X)$ が(一様に)緊密^{†11}であるとは、 $\forall \epsilon > 0 \exists_{K \subset X}^{\text{cpt}} \forall_{\mu \in \Gamma} \mu(K) \geq 1 - \epsilon$.

定理 2.2.17 (Prokhorov: 緊密性とは、相対コンパクト性の特徴付けである). X を距離空間とする。確率測度の族 $\Gamma \subset P(X)$ について、(1) \Rightarrow (2) が成り立つ。 X が完備かつ可分であるとき、(2) \Rightarrow (1) も成り立つ。

- (1) Γ は(一様に)緊密である。
- (2) Γ は弱(狭)位相について相対コンパクトである。

系 2.2.18 (漠収束の特徴付け). 完備可分距離空間 X 上の確率測度列 (μ_n) について、次の2条件は同値。^{†12}

- (1) μ に弱収束する。
- (2) μ に漠収束し、かつ (μ_n) は一様に緊密である。

[証明] . (1) \Rightarrow (2) は明らかだから、(2) \Rightarrow (1) を示す。漠収束の特徴付け 2.1.18 より、極限測度 μ が $P(X)$ に属することを示せば十分である。略。 ■

2.2.6 コンパクト空間上の確率測度

経験過程は重要な意味を持つ。これを、極点の凸結合として幾何学的に説明できないか？経験過程の有限性は実用性に通じるが、これは組み合わせ論的な本質も備えているのではないか？
 X がコンパクトのとき、その上の弱位相と w^* -位相は一致する。

補題 2.2.19 (ポーランド空間上の確率測度は Radon 測度). S を可分な距離空間とする。 $(S, \mathcal{B}(S))$ 上の Borel 確率測度 P は、

- (1) 正則である：

$$P(B) = \sup_{F \subset B; F: \text{closed}} P(F) = \inf_{B \subset G \subset S}^{\text{open}} P(G).$$

- (2) S が完備ならば、さらに外部正則である：

$$\forall \epsilon > 0 \exists_{K \subset S}^{\text{cpt}} P(K) > 1 - \epsilon.$$

命題 2.2.20. コンパクトハウスドルフ空間 X 上の Banach 代数 $C(X) = C_b(X) = C_0(X) = C_c(X)$ を考える、但しノルムは一様ノルムとした。 $C(X)$ の双対空間を $M(X)$ 、 $P(X) := \{\mu \in M(X) \mid \|\mu\| \leq 1, \mu(1) = 1\}$ を確率測度のなす部分空間とする。

- (1) $P(X)$ は $M(X)$ の凸集合である。
- (2) $P(X)$ は w^* -コンパクトである。
- (3) $P(X)$ の極点は Dirac 測度 δ_x ($x \in X$)、 $\forall_{f \in C(X)} \delta_x(f) = f(x)$ である。

[証明] .

- (1) $\mu_1, \mu_2 \in P(X)$ と $\lambda \in (0, 1)$ を任意にとると、 $\lambda\mu_1 + (1 - \lambda)\mu_2 \in P(X)$ がわかる。
- (2) 線型汎函数 $\text{ev}_1 : M(X) \rightarrow \mathbb{F}; \mu \mapsto \mu(1)$ は w^* -位相について連続である $M(X) = (C(X))^*$ の閉単位球 B^* は w^* -コンパクト^{??}である。

要諦 2.2.21. コンパクトハウスドルフ空間 X 上の確率測度は、 $C(X)$ 上において、有限な台を持つ測度 (= Radon charge が定める積分の空間) によって各点近似 (各点収束の位相で近似) が出来る。

^{†11} 測度が内部正則であることも「緊密」というので、それから見れば「一様に緊密」と言いたくなる。

^{†12} <https://math.stackexchange.com/questions/313986/are-vague-convergence-and-weak-convergence-of-measures-both-weak-convergence>

2.3 積分の拡張

まずは、関数解析の力を借りて、積分を非可測な関数に対しても延長する、Hoffmann-Jorgensen の理論を展開する。この議論は一般の局所コンパクトハウスドルフ空間 X 上の Radon 積分 $\int : C_c(X) \rightarrow \mathbb{R}$ に関して展開できる。

定義 2.3.1 (outer integral). (Ω, \mathcal{A}, P) を確率空間, $T : \Omega \rightarrow \overline{\mathbb{R}}$ を写像とする。

- (1) $E^*[T] := \inf \{E[U] \in \mathbb{R} \mid U \geq T, U \in \text{Meas}(\Omega, \overline{\mathbb{R}}), E[U] \in \mathbb{R}\}$ を、押し出された測度 T_*P に関する $\overline{\mathbb{R}}$ 上の Radon 上積分とする。
- (2) 写像列 $(X_n : \Omega_n \rightarrow \Omega)$ が Borel 可測関数 $X : \Omega_\infty \rightarrow \Omega$ に弱収束するとは、 $\forall f \in C_b(\Omega) \ E^*[f(X_n)] \rightarrow E[f(X)]$ を満たすことをいう。

2.4 確率変数列の収束

次に、測度の収束の一般化として、確率変数列に対して収束を定義する。測度の弱収束は、作用素の w^* -収束と同値で、確率変数列の法則収束と同値。

2.4.1 定義

定義 2.4.1 (almost sure convergence, converge in probability, converge in the mean of order p , converge in law / distribution). (X_n) を確率空間 (Ω, \mathcal{F}, P) 上の実確率変数の列とする。

- (1) (X_n) が X に**概収束**する $X_n \rightarrow X$ a.s. とは、 $P\left(\lim_{n \rightarrow \infty} X_n = X\right) = 1$ が成り立つことをいう。
- (2) (X_n) が X に**確率収束**する $X_n \xrightarrow{P} X$ とは、 $\forall \epsilon > 0 \ \lim_{n \rightarrow \infty} P(|X_n - X| > \epsilon) = 0$ が成り立つことをいう。
- (3) (X_n) が X に p 次**平均収束**するとは、 $\lim_{n \rightarrow \infty} E[|X_n - X|^p] = 0$ ($p \geq 1$) を満たすことをいう。
- (4) (X_n) が X に**法則収束**または**分布収束**する $X_n \xrightarrow{d} X$ とは、 $\forall f \in C_b(\mathbb{R}) \ \lim_{n \rightarrow \infty} E[f(X_n)] = E[f(X)]$ を満たすことをいう。


注 2.4.2 (法則収束の特異性). 概収束, 確率収束, p 次平均収束は X_n と X の間に関係 $=$ や演算 $-$ が定義されていることが必要であるから、列 (X_n) は同一の確率空間上で定義されている必要があるが、法則収束は実はその必要はなく、純粋に実数上に引き起こす測度のみによって決まる概念であるから、始域は抽象化されている。

注 2.4.3. $(\mathcal{X}_n, \mathcal{A}_n, P_n)$ 上の S -値確率変数列 (X_n) とある定点 $c \in S$ に対して、

$$X_n \xrightarrow{P} c \Leftrightarrow \forall \epsilon > 0 \ \lim_{n \rightarrow \infty} P_n[d(X_n, c) > \epsilon] = 0$$

も確率収束と呼ばれるが、この場合は法則収束 $P_n^{X_n} \Rightarrow \delta_c$ と同値になる。

2.4.2 収束の間の関係



補題 2.4.4 (相互関係 1). (X_n) が X に確率収束するならば、法則収束する。

定理 2.4.5 (相互関係 2). $(X_n), X$ について、

- (1) 概収束するならば、確率収束する。
- (2) p 次平均収束するならば、確率収束する。

命題 2.4.6 (確率収束の特徴付け). 可分距離空間 S -値確率変数 X_n, X について、次の3条件は同値。

- (1) (X_n) は X に確率収束する。
- (2) $E[d(X_n, X) \wedge 1] \rightarrow 0$ ($n \rightarrow \infty$).
- (3) $\{X_n\}$ は概収束に関して相対コンパクト。

系 2.4.7 (弱めた逆が成り立つ). X_n は X に確率収束、または p 次平均収束するとする。このときある部分列が存在して、概収束する。

2.4.3 概収束の性質

概収束を定める位相は距離付け不可能で、確率収束を定める位相は距離付け可能である。 p 次平均収束とは、 L^p -ノルムが定める位相についての収束と同値。

法則収束は、分布の空間 $P(\Omega)$ の上で距離付け可能である。

命題 2.4.8. 概収束は距離付け不可能である。

2.4.4 確率収束の性質

命題 2.4.9 (確率収束に関する連続写像定理). (S_i, d_i) ($i = 1, 2$) を可分距離空間とする。 X, X_n を S_1 -値確率変数、 $h : S_1 \rightarrow S_2$ を可測写像とする。 $P[X \in C] = 1$ を満たす可測集合 $C \in \mathcal{G}(S_1)$ 上で h は連続であるとする。このとき、 $X_n \xrightarrow{P} X \Rightarrow h(X_n) \xrightarrow{P} h(X)$ 。

命題 2.4.10 (確率収束の遺伝). X_n, X, Y_n, Y を確率変数とする。

- (1) 定数 $c \in \mathbb{R}$ については、 $X_n \xrightarrow{P} c$ と $X_n \xrightarrow{d} c$ とは同値。
- (2) $X_n \xrightarrow{d} X$ かつ $d(X_n, Y_n) \xrightarrow{P} 0$ ならば、 $Y_n \xrightarrow{X}$ 。
- (3) $X_n \xrightarrow{d} X$ かつ $Y_n \xrightarrow{P} c$ ならば、 $(X_n, Y_n) \xrightarrow{d} (X, c)$ 。
- (4) $X_n \xrightarrow{P} X$ かつ $Y_n \xrightarrow{P} Y$ ならば、 $(X_n, Y_n) \xrightarrow{P} (X, Y)$ 。

注 2.4.11. 一方で、結合分布の弱収束は、各成分の弱収束より強い [2.4.18](#)。これも、各成分の分布だけでは結合分布が定まらないことに起因する。

命題 2.4.12 (確率収束を定める距離 1). $X, Y \in \text{Meas}(\Omega, \mathbb{R})$ について、 $d(X, Y) := E \left[\frac{|X - Y|}{1 + |X - Y|} \right]$ と定める。

- (1) d は距離を定める。
- (2) d について収束することと、確率収束することは同値。ただし、 $X = Y$ a.s. を同一視する。

命題 2.4.13 (確率収束を定める距離 2). 可測関数の全体 $\mathcal{L}(\Omega)$ について。

- (1) 距離 $\rho_0(X, Y) := E[|X - Y| \wedge 1]$ について、完備可分な距離空間となる。
- (2)

$$\forall \epsilon \in (0, 1) \quad \epsilon P[|X - Y| > \epsilon] \leq \rho_0(X, Y) \leq \epsilon + P[|X - Y| > \epsilon].$$

- (3) この距離が定める位相は、確率収束を定める。

2.4.5 連続写像定理とデルタ法

分布収束は、有界測度論の世界が流入した風景が広がっている。分布収束は連続写像で保たれ、平均の周りでの分散については、デルタ法が成り立つ。

2.4.5.1 連続写像定理

命題 2.4.14 (連続写像は弱収束を保つ). $\forall T \in \mathcal{C}(S_1; S_2) \quad \nu_n \rightarrow \nu \Rightarrow \nu_n^T \rightarrow \nu^T$.

定理 2.4.15 (連続写像定理). $T, T_n : S_1 \rightarrow S_2$ を可測写像とし、 $P[X \in C] = 1$ を満たすある可測集合 $C \in \mathcal{G}(S_1)$ が存在して、条件

(C) 任意の $x \in C$ に収束する任意の列 $\{x_n\} \subset S_1$ に対して、 $T_n(x_n) \xrightarrow{n \rightarrow \infty} T(x)$.

が満たされるとする。このとき、 $X_n \xrightarrow{d} X$ ならば、 $T_n(X_n) \xrightarrow{d} T(X)$ 。特に、 $\forall n \in \mathbb{N} \quad T_n = T$ の場合を考えれば、 T が C 上連続ならば、 $T(X_n) \xrightarrow{d} T(X)$ が成り立つ。

2.4.5.2 デルタ法

パラメータ $\theta \in \mathbb{R}^k$ の推定量 $T_n : \mathcal{X}^n \rightarrow \mathbb{R}^k$ と、関数 $\varphi : \mathbb{R}^k \rightarrow \mathbb{R}$ を考える。 $T_n \xrightarrow{P} \theta$ が成り立つとき、 φ が θ で連続ならば $\varphi(T_n) \xrightarrow{P} \varphi(\theta)$ も成り立つ。では、 $\sqrt{n}(T_n - \theta) \xrightarrow{d} \varphi'(\theta)\sqrt{n}(T_n - \theta)$ も成り立つのであろうか？

定理 2.4.16 (デルタ法). 関数 $f : \mathbb{R}^{d_1} \supset A \rightarrow \mathbb{R}^{d_2}$ は $c \in A$ で微分可能であるとする。 $\forall n \in \mathbb{N} \quad P[X_n \in A] = 1$ を満たす d_1 次元確率変数列 $\{X_n\} \subset \mathbb{R}^{d_1}$ に対して、 ∞ に発散する係数列 $\{b_n\} \subset \mathbb{R}$ が定める線型変換は $b_n(X_n - c) \xrightarrow{d} Z \in \mathbb{R}^{d_1}$ を満たすとする。このとき、

$$b_n[f(X_n) - f(c)] - \partial_x f(c)b_n(X_n - c) \xrightarrow{P} 0 \quad (n \rightarrow \infty).$$

特に、 $b_n[f(X_n) - f(c)] \xrightarrow{d} \partial_x f(c)Z$ ($n \rightarrow \infty$) である。 $\partial_x f(c)$ は $d_2 \times d_1$ -行列であることに注意。

要諦 2.4.17. 列 $(b_n[f(X_n) - f(c)])$ は $(b_n \partial_x f(c)(X_n - c))$ に漸近同等であることがわかった。これは 1 次の Taylor 展開に拠ると思えることが名前の由来である。これを Banach 空間上で行う技法を関数デルタ法という。

2.4.6 分布収束の性質

連続写像定理を用いて、分布収束の遺伝法則が求まる。さらに、同じ分布に収束するためには、差 $X_n - Y_n$ が 0 に確率収束することが必要である。これを漸近同等といい、さらに一様緊密性と併せて $O_p(1), o_p(1)$ の概念が先に定まる。 $O_p(1)$ の概念はタイトともいうが、 \mathbb{R} に限れば、確率収束の意味で有界であるための条件に読める。

2.4.6.1 分布収束の遺伝

定理 2.4.18 (Slutsky). X, X_n, Y_n を確率ベクトルまたは確率行列とする。 c を定数ベクトルまたは定数行列とする。 $X_n \xrightarrow{d} X, Y_n \xrightarrow{P} c$ のとき、次が成り立つ。

- (1) $(X_n, Y_n) \xrightarrow{d} (X, c)$.
- (2) $X_n + Y_n \xrightarrow{d} X + c$.
- (3) $Y_n X_n \xrightarrow{d} cX$.
- (4) c が正則行列のとき、 $Y_n^{-1} X_n \xrightarrow{d} c^{-1}X$.

注 2.4.19. 定値関数ではない Y に対して $Y_n \xrightarrow{P} Y$ であっても、結合ベクトルの収束 $(X_n, Y_n) \xrightarrow{d} (X, Y)$ は一般には成り立たない。

系 2.4.20. X, X_n, Y_n が d 次元確率変数で、 $X_n \xrightarrow{d} X$ かつ $X_n - Y_n \xrightarrow{P} 0$ を満たすならば、 $Y_n \xrightarrow{d} X$ が成り立つ。

2.4.6.2 漸近同等性

定義 2.4.21 (asymptotically equivalent, bounded in probability / tight).

- (1) 条件 $X_n - Y_n \xrightarrow{P} 0$ なる条件を, $(X_n), (Y_n)$ は**漸近同等**であるといい, $X_n \equiv^a Y_n$ と表すこととする.
 (2) $X_n = o_p(1) := X_n \xrightarrow{P} 0$ とし, (一様に)緊密または**確率有界**であることを $X_n = O_p(1) := \forall \epsilon > 0 \exists M > 0 \sup_{n \in \mathbb{N}} P[|X_n| \geq M] < \epsilon$ と表す.

補題 2.4.22. $X_n \xrightarrow{d} X$ ならば, $X_n = O_p(1)$ である. 特に, $X_n = o_p(1)$ ならば $X_n = O_p(1)$ である.

[証明]. 漠収束の特徴付け 2.1.18 より. ■

補題 2.4.23. $(X_n), (Y_n)$ を確率変数列とする.

- (1) $X_n = O_p(1), Y_n = O_p(1)$ ならば, $X_n Y_n = O_p(1), X_n + Y_n = O_p(1)$.
 (2) $X_n = O_p(1), Y_n = o_p(1)$ ならば, $X_n Y_n = o_p(1), X_n + Y_n = O_p(1)$.

定義 2.4.24. 正数列 $\{r_n\} \subset \mathbb{R}_{>0}$ に対して, $X_n = o_p(r_n) := \frac{X_n}{r_n} = o_p(1)$ とし, $X_n = O_p(r_n) := \frac{X_n}{r_n} = O_p(1)$.

2.4.7 安定収束

定義 2.4.25. 任意の確率収束する確率変数列 $Y_n \xrightarrow{P} Y$ に対して $(X_n, Y_n) \xrightarrow{d} (X, Y)$ が成り立つとき, $X_n \xrightarrow{d} X$ (*stably*) と表し, **安定収束**するという.

例 2.4.26. 独立確率変数列 (X_n) , マルチンゲール (X_n) など, 中心極限定理が従う多くの場合, これが法則収束するとき, 安定収束する.

注 2.4.27. 安定収束の概念は非エルゴード的統計において最も基本的な役割を演じる. 非エルゴード統計とは, 条件付き Fisher 情報量の極限にランダム性が残る場合をいう.

2.4.8 弱収束が定める概収束列

定理 2.4.28 (Skorokhod representation theorem). 距離空間 (S, S) 上の確率測度の列 (P_n) は, 可分な台をもつ P に弱収束するとする. このとき, 確率空間 (Ω, \mathcal{F}, P) とその上の S -値確率要素の列 (X_n) が存在して, 確率測度 (P_n) をそれぞれ誘導し, P に概収束する. また, $S = \mathbb{R}$ のとき, $\Omega = (0, 1)$, $X_n(y) = \inf \{z \in \mathbb{R} \mid P_n(-\infty, z] \geq y\}$ と取れる.

要諦 2.4.29. あくまで測度の *-弱収束が主軸である, とも捉えられる.

2.4.9 一様可積分性の定義と特徴付け

平均作用素はノルム連続であるが, 各収束概念を保存することとの関係は込み入っている. そこで, E が収束を保つための十分条件を調べると同時に, 概収束と p -次平均収束の関係を精査する.

定義 2.4.30 (uniformly integrable).

- (1) 列 (X_n) が**一様可積分**であるとは,

$$\lim_{\lambda \rightarrow \infty} \sup_{n \in \mathbb{N}} E[|X_n| \mathbf{1}_{|X_n| \geq \lambda}] = 0$$

が成り立つことをいう.

- (2) 族 $(X_\lambda)_{\lambda \in \Lambda}$ が**一様可積分**であるとは,

$$\lim_{A \rightarrow \infty} \sup_{\lambda \in \Lambda} E_\lambda[|X_\lambda| \mathbf{1}_{|X_\lambda| \geq A}] = 0$$

が成り立つことをいう. ただし, 確率変数 X_λ の定義域を確率空間 $(\Omega_\lambda, \mathcal{F}_\lambda, P_\lambda)$ とし, これが定める積分を E_λ とした.

要諦 2.4.31. 列 $(|X_n|)$ の末尾の積分が、一様に 0 に近づくことをいう。また定義から、 $\{X_n\}$ が一様可積分であることと $\{|X_n|\}$ が一様可積分であることは同値で、このとき $\sup_{\lambda \in \Lambda} E_\lambda[|X_\lambda|] < \infty$ が成り立つ（これは一部特徴付ける）。つまり、分布族 $\{P_\lambda^{X_\lambda}\}$ の性質であって、例えば列 $X_n(x) := x1_{[0,n]}(x)$ は、 P が正規分布のとき一様可積分であるが、Cauchy 分布であるときはそうではない。

補題 2.4.32 (一様可積分性の十分条件). Y を可積分な確率変数とする。

- (1) $\lim_{\lambda \rightarrow \infty} E[|Y||Y| \geq \lambda] = 0$.
- (2) 列 (X_n) が $\forall n \in \mathbb{N} \ |X_n| \leq Y$ を満たすならば、 (X_n) は一様可積分である。

補題 2.4.33 (一様可積分性の特徴付け). 列 (X_n) について、次の 2 条件は同値。

- (1) (X_n) は一様可積分である。
- (2) ある Borel 可測関数 $\psi: \mathbb{R} \rightarrow \mathbb{R}_+$ が存在して、 $\lim_{|x| \rightarrow \infty} \frac{|x|}{\psi(x)} = 0, \sup_{n \in \mathbb{N}} E[\psi(X_n)] < \infty$ を満たす。

特に、 $p > 1$ が存在して $\sup_{n \in \mathbb{N}} E[|X_n|^p] < \infty$ を満たすならば、 (X_n) は一様可積分である。

系 2.4.34. $0 < p < q$ とするとき、 $\sup_{\lambda \in \Lambda} E_\lambda[|X_\lambda|^q] < \infty$ ならば、 $\{|X_\lambda|^p\}_{\lambda \in \Lambda}$ は一様可積分である。

補題 2.4.35 (一様可積分性の特徴付け). 列 (X_n) が一様可積分であることは、次の 2 条件が成り立つことと同値：

- (1) $\sup_{n \in \mathbb{N}} E[|X_n|] < \infty$.
- (2) 測度としての E は絶対連続： $\forall \epsilon > 0 \ \exists \delta > 0 \ \forall A \in \mathcal{F} \ P[A] < \delta \Rightarrow \sup_{n \in \mathbb{N}} E[|X_n|, A] < \epsilon$.

2.4.10 収束概念が退化するための十分条件

一様可積分性が、次の系のような形で、 p -次平均収束が他の収束概念と一致するための必要十分条件になる。

定理 2.4.36 (一般化された Lebesgue の優収束定理). (X_n) は一様可積分とする。

- (1) X_n が X に概収束するならば、1 次平均収束する： $\lim_{n \rightarrow \infty} E[|X_n - X|] = 0$ 。特に、極限 X は可積分で、 $\lim_{n \rightarrow \infty} E[X_n] = E[X]$ 。
- (2) X_n が X に確率収束することと、1 次平均収束することとは同値。

系 2.4.37 (一様可積分性の特徴付け). 可積分な確率変数の列 (X_n) は X に概収束するとする。このとき次の 3 条件は同値：

- (1) (X_n) は一様可積分である。
- (2) (X_n) は X に 1 次平均収束する： $\lim_{n \rightarrow \infty} E[|X_n - X|] = 0$ 。
- (3) $E[|X_n|] \rightarrow E[|X|]$ かつ $E[|X|] < \infty$ 。

系 2.4.38 (さらに一般化). 任意の $q \geq 1$ について、 $E[|X_n|^q] < \infty$ かつ $X_n \xrightarrow{P} X$ のとき、次の 3 条件は同値。

- (1) $\{|X_n|^q\}_{n \in \mathbb{N}}$ は一様可積分である。
- (2) $E[|X_n - X|^q] \rightarrow 0$ 。
- (3) $E[|X_n|^q] \rightarrow E[|X|^q] < \infty$ 。

定理 2.4.39 (Dunford-Pettis). 列 (X_n) について、次の 2 条件は同値。

- (1) (X_n) は一様可積分である。
- (2) $\{X_n\} \subset L^1(\Omega)$ は弱相対コンパクトである： $\forall Y \in L^\infty(\Omega) \ \lim_{n \rightarrow \infty} E[X_n Y] = E[XY]$ 。

2.5 不等式

2.5.1 確率不等式

$E[X] = \int X dP$ とみなせば、一般の測度 P について成り立つ。

記法 2.5.1. (Ω, \mathcal{F}, P) を確率空間とする。

命題 2.5.2 (Markov (1884), Chebyshev / Bienayme (1876)). (Ω, \mathcal{F}, P) 上の確率変数 X について、

- (1) (Markov) $\forall a > 0 \quad P[|X| \geq a] \leq \frac{1}{a} E[|X|]$.
 (2) (Chebyshev) 単調増加関数 $g: \mathbb{R}_+ \rightarrow \mathbb{R}_+$ に対して、

$$\forall a \geq 0 \quad P[|X| \geq a] \leq \frac{1}{g(a)} E[g(|X|)]$$

[証明] .

- (1) 事象 $\{|X| \geq a\}$ 上で $\frac{|X|}{a} \geq 1$ より、

$$P[|X| \geq a] = E[1_{\{|X| \geq a\}}] \leq E\left[\frac{|X|}{a} 1_{\{|X| \geq a\}}\right] \leq \frac{1}{a} E[|X|].$$

- (2) $a \leq |X| \Rightarrow g(a) \leq g(|X|)$ より、

$$P[|X| \geq a] \leq P[g(|X|) \geq g(a)] \leq \frac{1}{g(a)} E[g(|X|)].$$

■

2.5.2 凸不等式

確率測度に関する期待値は、凸結合の一般化にもなっているため、凸解析の道具も流入する。

命題 2.5.3 (Jensen の不等式). 確率変数 X と凸関数 $g: \mathbb{R} \rightarrow \mathbb{R}$ に対して、 $X, g(X) \in \mathcal{L}^1(\Omega)$ ならば、

$$g(E[X]) \leq E[g(X)].$$

2.5.3 Lebesgue 空間のノルム不等式

$L^p(\mathbb{R}^d)$ ($p \in [1, \infty]$) はノルムに関して完備であるという事実は、Riesz-Fisher の定理と呼ばれている。

命題 2.5.4 (Holder). $p, q, r \in [1, \infty]$ は $p^{-1} + q^{-1} = r^{-1}$ を満たすとする。このとき、 $X \in L^p \wedge Y \in L^q$ ならば $XY \in L^r$ であって、

$$\|XY\|_r \leq \|p\| \|q\|.$$

系 2.5.5.

- (1) Cauchy-Schwarz $\|XY\|_1 \leq \|X\|_2 \|Y\|_2$.
 (2) Lyapunov $0 < a < b$ かつ $\mu(\Omega) = 1$ のとき、 $X \in L^b$ ならば $\|X\|_a \leq \|X\|_b$.

命題 2.5.6 (Minkowski). $p \in [1, \infty)$, $X, Y \in L^p$ について、

$$\|X + Y\|_p \leq \|X\|_p + \|Y\|_p$$

2.5.4 畳み込みと不等式

記法 2.5.7. 一般に、局所コンパクトで単模である群 G の両側不変 Haar 測度 μ に対して、 G 上の関数の畳み込みが考えられ、同じ結果が成り立つ。

定義 2.5.8.

$$f * g(x) := \int_{\mathbb{R}^d} f(x-y)g(y)dy$$

によって、 $\text{Meas}(\mathbb{R}^d, \mathbb{R})^2 \rightarrow \text{Meas}(\mathbb{R}^d, \mathbb{R})$ を定める。Young の不等式より、 $L^p(\mathbb{R}^d) \times L^q(\mathbb{R}^d)$ 上に制限すると、積を定める。

命題 2.5.9 (Young). $p, q, r \in [1, \infty], p^{-1} + q^{-1} = r^{-1} + 1$ とする。 $f \in L^p(\mathbb{R}^d), g \in L^q(\mathbb{R}^d)$ のとき、 $f * g$ は殆ど至るところ存在し、 $f * g \in L^r(\mathbb{R}^d)$ を満たし、

$$\|f * g\|_r \leq \|f\|_p \|g\|_q.$$

2.6 一般の試行と確率測度

定義 2.6.1 (null set, complete).

- (1) $P(N) = 0$ を満たす P -可測集合 N を、 P -零集合という。
- (2) 任意の P -零集合の、任意の部分集合も全て P -可測（したがって零）である時、 P を完備確率測度という。

命題 2.6.2 (Lebesgue expansion). 任意の確率測度 P に対し、完備拡張は必ず存在し、最小のものが一意に定まる。これを P の Lebesgue 拡大という。

2.7 確率測度の拡張定理

定義 2.7.1 (regular probability measure). 位相空間上の確率測度を考える。

- (1) 定義域が Borel class と一致するものを、**Borel 確率測度**という。
- (2) Borel 確率測度の Lebesgue 拡大を**正則確率測度**という。

2.8 確率測度の直積

独立性は P の集合積に対する関手性だから、数学的には直積と関係が深い。

定義 2.8.1. $(\Omega_n, \mathcal{F}_n, P_n)$ を確率空間の列とする。 $\Omega := \prod_{n \in \mathbb{N}} \Omega_n$ とし、 $\text{pr}_n : \Omega \rightarrow \Omega_n$ を射影とする。射影が Ω 上に定める σ -加法族を、積 σ -加法族という。これを Kolmogorov の σ -加法族ともいう。この上の確率測度を、直積確率測度という。

注 2.8.2. 射影 $q_n := (\text{pr}_1, \dots, \text{pr}_n)$ による σ -加法族 $S_1 \times \dots \times S_n$ の引き戻し $q_i^*(A_i)$ ($A_i \in S_i$)

$$C_A^{(n)} = \{\omega \in \Omega \mid (\omega_1, \dots, \omega_n) \in A\} \quad A \in S_1 \times \dots \times S_n$$

を**柱状集合**という。柱状集合の全体 \mathcal{G} は有限加法族で、これが生成する σ -加法族が Kolmogorov σ -加法族である。

補題 2.8.3.

- (1) 直積確率測度は一意的である。
- (2) 直積確率測度は存在する。

定理 2.8.4. Ω_n はいずれも Poland 空間で、 \mathcal{F}_n が Borel 集合族であるとき、コルモゴロフの σ -加法族 \mathcal{F} は、 Ω の直積位相が生成する Borel 集合族に一致する。

2.9 標準確率空間

多様体に対する Euclid 空間のように，標準的な空間を用意するために，同型の理論を整備し， (\mathbb{R}, μ) の同型類を特徴づける。

定義 2.9.1 (canonical measure). P を Ω 上の完備な確率測度とする. (Ω, P) が, 正則確率測度を備えた実数空間 (\mathbb{R}, μ) に同型である時, (Ω, P) を **標準確率空間**と呼ぶ.

定義 2.9.2 (pushforward measure). S 上の測度 P の, 可測関数 $f: S \rightarrow T$ による像測度を, Pf^{-1} または f_*P で表す.

補題 2.9.3. P が完備ならば Q も完備である.

第 3 章

確率論の基礎概念

単なる可測関数と測度としての範囲を超える確率変数・確率分布特有の概念と、その極限の取り扱いを議論する。大事な概念は独立性と収束である。

- (1) 古典的な確率論を特徴付けてきたところの数学的な概念は、試行の独立性和確率変数の独立性の概念である。確率変数列の独立性は、確率測度が定める関係である。Laplace, Poisson, Chebyshev, Markov, von Mises, Bernstein の古典的研究は、独立な確率変数列についての基礎的な研究であり、Markov, Bernstein による現代的な研究は、完全な独立性よりも弱めた Markov 性の条件を課して考察している。このようにして、独立性の概念に、確率論固有の問題意識、少なくともその萌芽が見られる [13]。なお事象の独立性とは、測度 $P: \mathcal{F} \rightarrow [0, 1]$ が、積 \cap なる演算に対して可換（準同型）であること： $P(A \cap B) = P(A) \cdot P(B)$ と理解できる。
- (2) 独立性は、事象に対する定義から、 σ -加法族・確率変数族へと一般化され、独立な確率変数列なる対象が構成される。
- (3)

3.1 確率測度の変換：条件付き確率と Bayes の定理

確率空間の万華鏡による拡大

離散の場合を考えると明らかであるが、確率空間とは「事象をどのように分割するか」が肝要になり、情報を得ることとはそれについての知識の更新だと言える。その基本的な言葉は、「条件付き確率」にある。部分代数を取り出しているようなもので、再帰的な構造がある。分母の $P(A)$ は規格化条件で、再び確率測度を与えるため、これは確率測度の変換の一種である。ここでは可算な分割のみを考える（一般には条件付き期待値の議論になる）。

さらに進んだものだと、重点サンプリングや Girsanov 変換が、ファイナンスやフィルタリング問題で用いられる測度変換の例である。

定義 3.1.1 (conditional probability).

- (1) $A, B \in \mathcal{F}, P(A) > 0$ とする。

$$P(B | A) := \frac{P(A \cap B)}{P(A)}$$

を、事象 A の下での B の条件付き確率という。 $P_A(B)$ とも表す。^{†1} $P(A) = 0$ の時はこの値は任意に定めることで、2変数測度 $P(\cdot | \cdot): \mathcal{F} \times \mathcal{F} \rightarrow [0, 1]$ が定まる。

- (2) $P(\cdot | A)$ は再び Ω 上の確率測度となる。
- (3) $P_X(B) := P(B | X = \cdot)$ は X 上の可測関数となる。

注 3.1.2 (conditional expectation). 新たな確率空間 $(A, \mathcal{F} \cap P(A), P_A)$ における積分作用素を、条件付き期待値という。これらの定義は、事象 $A \in \mathcal{F}$ を指定している裏で暗黙に指定されている σ -代数 $\mathcal{F} \cap P(A)$ について一般的に定義できる。

^{†1} $i: A \hookrightarrow \Omega$ についての引き戻し測度である？

命題 3.1.3 (law of total probability : 全確率の分解). $(H_i)_{i \in I}$ を互いに背反で $\Omega = \coprod_{i \in I} H_i$ を満たす事象の族とする.

$$\forall A \in \mathcal{F} \quad P(A) = \sum_{i \in I} P(A | H_i) \cdot P(H_i).$$

[証明] . $A = A \cap (\cup_{i \in I} H_i) = \cup_{i \in I} A \cap H_i$ より,

$$\begin{aligned} P(A) &= P(\cup_{i \in I} A \cap H_i) \\ &= \sum_{i \in I} P(A \cap H_i) && \text{加法性} \\ &= \sum_{i \in I} P(A | H_i) P(H_i) && \text{定義 3.1.1} \end{aligned}$$

■

要諦 3.1.4. こうして 1.2 節で確認したとおり, 分割 $\sum H_i$ の取り方が測度の取り替えについて肝要になる.

定理 3.1.5 (Bayes). $(H_i)_{i \in I}$ を互いに背反で $\Omega = \coprod_{i \in I} H_i$ を満たす事象の族とする. $P(A) > 0$ ならば,

$$P(H_i | A) = \frac{P(A | H_i) P(H_i)}{\sum_{j \in I} P(A | H_j) P(H_j)}.$$

[証明] .

$$\begin{aligned} P(H_i | A) &= \frac{P(H_i \cap A)}{P(A)} && \text{条件付き確率の定義 3.1.1} \\ &= \frac{P(A | H_i) P(H_i)}{\sum_{j \in I} P(A | H_j) P(H_j)} && \text{分母は定義 3.1.1, 分子は全確率の分解則 3.1.3} \end{aligned}$$

■

要諦 3.1.6. 条件付き確率の第一引数・第二引数の入れ替え法則という意味で, 何かの変換則に見える. 情報の更新規則.^{†2} $I = 1$ の場合は,

$$P(H | E) = \frac{P(E | H) P(H)}{P(E)} \quad \Leftrightarrow \quad P(H | E) P(E) = P(E | H) P(H) = P(E \cap H)$$

となる.

3.2 事象の独立性

積への関手性

測度は純粋的に加法的な集合関数であって, 積との相互関係は一切考えなかった. ここで, 積への関手性は, 確率論的に重要な意味論を持つことをみる. 独立性は確率測度 \mathcal{P} の構造のみに依存する, 純粋に確率論的な概念である.

3.2.1 互いに独立な事象

定義 3.2.1 (independent). 事象 $A, B \in \mathcal{F}$ について,

- (1) 可測空間 (Ω, \mathcal{F}) で事象 $A, B \in \mathcal{F}$ が背反であるとは, $A \cap B = \emptyset$ であることをいう.
- (2) 測度空間 $(\Omega, \mathcal{F}, \mathcal{P})$ で事象 $A, B \in \mathcal{F}$ が独立であるとは, $\mathcal{P}(A \cap B) = \mathcal{P}(A)\mathcal{P}(B)$ であることをいう. $P(A) > 0$ のとき, $P(B | A) = P(B)$ に同値.

注 3.2.2. $P(A), P(B) > 0$ のとき, A, B が背反であることと独立であることは両立し得ない (背反である). これは, 「同時には起こらない」というのは従属関係であって, 無関係たり得ないとも捉えられる.

^{†2} In quantum mechanics, the collapse of the wavefunction may be seen as a generalization of Bayes's Rule to quantum probability theory. This is key to the Bayesian interpretation of quantum mechanics.

補題 3.2.3 (補集合演算に関する関手性). $A, B \in \mathcal{F}$ について, 次の4条件は同値.

- (1) A, B は独立.
- (2) A^c, B は独立.
- (3) A, B^c は独立.
- (4) A^c, B^c は独立.

定理 3.2.4 (独立性の特徴付け). 2つの事象 $X, Y \in \mathcal{F}$ について, 次の3条件は同値.

- (1) X, Y は独立である.
- (2) $N := \{x \in \Omega^X \mid \exists y \in \Omega^Y P(Y = y | X = x) \neq P(Y = y)\}$ について, $P^X(N) = 0$.
- (3) 殆ど至る所 $P_X(Y = y) = P(Y = y)$.

[証明] .

(1) \Rightarrow (2) 任意の $x \in N$ について, X, Y の独立性より $P(X = x) > 0$ ならば $P_{X=x}\{Y = y\} = P\{Y = y\}$ が必要だから, $P\{X = x\} = 0$. よって, $P^X(N) = P\{X \in N\} = \sum_{x \in N} P\{X = x\} = 0$. ■

3.2.2 事象族の独立性

定義 3.2.5 (事象族の独立性, pairwise independent).

- (1) 列 $(A_i)_{i \in \mathbb{N}} : \mathbb{N} \rightarrow \mathcal{F}$ が独立であるとは, $\forall 2 \leq k \leq n \quad \forall 1 \leq i_1 < \dots < i_k \leq n \quad P(A_{i_1} \cap \dots \cap A_{i_k}) = P(A_{i_1}) \cdots P(A_{i_k})$.
- (2) 族 $(A_i)_{i \in I}$ が独立であるとは, 任意の有限部分集合について $\forall n \geq 2 \quad A_1, \dots, A_n$ が独立 であることとする.
- (3) 族 $(A_i)_{i \in I}$ が対独立であるとは, $\forall i \neq j \in I \quad A_i \cap A_j = \emptyset$.

例 3.2.6. 対独立であるが独立ではない例がある.

補題 3.2.7 (独立性の遺伝). 事象 A_1, \dots, A_n が独立であるとする.

- (1) 事象 A_1^c, \dots, A_n^c も独立である.
- (2) $A_1 \cup A_2, A_3 \cap A_4, A_5$ は独立である.

補題 3.2.8 (独立事象に対する確率の関手性). 列 $(A_i)_{i \in \mathbb{N}}$ が独立ならば,

$$P(\cap_{n=1}^{\infty} A_n) = \prod_{n=1}^{\infty} P(A_n).$$

[証明] . $B_n := \cup_{k=1}^n A_k$ と定めると, これは単調列であるから,

$$\begin{aligned} P(\cap_{n=1}^{\infty} A_n) &= \lim_{n \rightarrow \infty} P(B_n) \\ &= \lim_{n \rightarrow \infty} \prod_{k=1}^n P(A_k) = \prod_{n=1}^{\infty} P(A_n). \end{aligned}$$
■

3.2.3 σ -代数の独立性

定義 3.2.9 (σ -代数の独立性).

- (1) \mathcal{F} の部分 σ -代数 $\mathcal{F}_1, \mathcal{F}_2$ が独立であるとは, $\forall C_1 \in \mathcal{F}_1, C_2 \in \mathcal{F}_2 \quad P(C_1 \cap C_2) = P(C_1) \cdot P(C_2)$ を満たすことをいう.
- (2) 部分代数の有限列 $(\mathcal{F}_k)_{k \in [n]}$ が独立であるとは, $\forall k \in [n] \quad \forall C_k \in \mathcal{F}_k \quad P(\cap_{k \in [n]} C_k) = \prod_{k \in [n]} P(C_k)$ を満たすことをいう.
- (3) 部分代数族が独立であるとは, 任意の有限部分集合が独立であることをいう.
- (4) 部分代数族が対独立であるとは, 任意の2つの部分代数 $\mathcal{F}_i, \mathcal{F}_j$ が互いに独立であることをいう.

3.3 確率変数と確率分布

前節で確率測度の変換を初等的な言葉で捉えた。ここで確率変数とは、確率測度の変換を引き起こす射であると考えられる。人間は、主に実数値のものを考える。ℝ は数理モデルにおいて特別なのだ。

顕著な特徴として、統計推測などにおいて、確率変数 $X: \Omega \rightarrow \mathcal{G}$ が誘導する測度 P^X を観測することが問題となり、 (Ω, \mathcal{F}, P) の特定の構造には執着しない。特に、経験過程論のように、 (Ω, \mathcal{F}, P) を拡大して考えることがしばしばである。

3.4 確率変数の独立性

確率空間とは「分割」の定め方である。確率変数が独立であるとは、これらが定める分割 (σ -加法族) が独立になることをいう。これは明らかに、一般化された概念である。

独立性は P の集合積に対する関手性だから、数学的には直積によって構成する。

定義 3.4.1 (independent). 確率変数 $X_1, \dots, X_n: \Omega \rightarrow \mathcal{G}_i$ が独立であるとは、次を満たすことをいう：

$$\forall B_1 \in \mathcal{B}_1, \dots, B_n \in \mathcal{B}_n \quad \mathcal{P}^X(X_1 \in B_1, \dots, X_n \in B_n) = \mathcal{P}^X(X_1 \in B_1) \times \dots \times \mathcal{P}^X(X_n \in B_n).$$

ただし、 $X := (X_1, \dots, X_n)$ を同時分布、 P^X は直積測度 $P^{X_1} \times \dots \times P^{X_n}$ とした。とした。事象 (A_i) の独立性は、 $X_i = \chi_{A_i}$ の場合に当たる。

命題 3.4.2 (可測関数は独立性を保つ). 可測空間 $(\mathcal{Y}_i, \mathcal{G}_i)$ への射 $f_i: \mathcal{G}_i \rightarrow \mathcal{Y}_i$ について、確率変数 X_1, \dots, X_n が独立ならば、 $f_1(X_1), \dots, f_n(X_n)$ も独立である。

【証明】. 合成 $f_i \circ X_i$ も可測だから、確かに $f_i(X_i)$ も確率変数である。任意の $C_i \in \mathcal{G}_i$ について、 $P^Y(f_i(X_i) \in C_i) = P^X(X_i \in f_i^{-1}(C_i))$ であるから、

$$\begin{aligned} P^Y(f_1(X_1) \in C_1, \dots, f_n(X_n) \in C_n) &= P^X(X_1 \in f_1^{-1}(C_1)) \times \dots \times P^X(X_n \in f_n^{-1}(C_n)) \\ &= P^Y(f_1(X_1) \in C_1) \times \dots \times P^Y(f_n(X_n) \in C_n). \end{aligned}$$

■

命題 3.4.3. 確率変数 $A_1, \dots, A_n: \Omega \rightarrow \mathcal{G}$ が独立であるとする。任意の $I := [n] \supset J$ について、 $\{A_j^c, A_k \mid j \in J, k \in I \setminus J\}$ は独立である。

【証明】. 写像 $f: \mathcal{G} \rightarrow \mathcal{G}$ を、 A_j を A_j^c に写し、 A_i を変えない $f(A_i) = A_i$ 写像として定義できたなら、この像変数も独立であることから従う。

■

3.5 独立な確率変数

確率変数が独立のとき、作用素に種々の関手性が生じる

関数の積分と確率変数の期待値との間にある類似点が明らかになってきた。こうした類推はさらに拡張され、独立な確率変数のさまざまな性質は、対応する直交関数の性質と完全に類似しているものとみなされるようになった [13].

3.5.1 確率変数の独立性

定義 3.5.1. S_k 値確率変数列 $(X_k)_{k \in [n]}$ が独立とは、

$$\forall A_1 \in S_1, \dots, A_n \in S_n \quad P[X_k \in A_k, k \in [n]] = \prod_{k=1}^n P[X_k \in A_k]$$

補題 3.5.2 (well-definedness). 次の2条件は同値.

- (1) (X_n) は独立.
- (2) $(\sigma(X_n))$ は独立.

3.5.2 独立な確率変数に対する関手性

命題 3.5.3 (実空間の議論への持ち上げ). 実確率変数の族 $X := (X_1, \dots, X_n) : \Omega \rightarrow \mathbb{R}^n$ と任意の可測関数 $f : \mathbb{R}^n \rightarrow \mathbb{R}$ に対して,

- (1) $h := f \circ X : \Omega \rightarrow \mathbb{R}^n \rightarrow \mathbb{R}$ は実確率変数である.
- (2) $E[h] = \int_{\mathbb{R}^n} f(x_1, \dots, x_n) P^X(dx_1, \dots, dx_n)$.

[証明]. 可測関数の合成は可測だから, h は当然実確率変数である.

f が特性関数の場合 $f = \chi_A$ ($A \in \mathcal{G}(\mathbb{R}^n)$) とする.

$$\begin{aligned} E[\chi_A \circ X] &= E[\chi_{X^{-1}(A)}] = 1 \cdot P(X^{-1}(A)) \\ &= P^X(A) = \int_{\mathbb{R}^n} \chi_A(x_1, \dots, x_n) P^X(dx). \end{aligned}$$

f が単関数の場合 積分の線形性より成り立つ.

f が一般の可測関数の場合 $f = f^+ - f^-$ について, それぞれの非負値単関数近似から, Lebesgue の優収束定理より.

■

系 3.5.4 (期待値が積を保つ条件). 実確率変数の族 $(X_i)_{i \in [n]}$ が独立である時, 任意の可積分な可測関数列 $(f_i)_{i \in [n]}$ に対して, $h := (f_1 \circ X_1) \cdot (f_2 \circ X_2) \cdots (f_n \circ X_n)$ とすると, h も可積分で次が成り立つ: $E[h] = \prod_{i=1}^n E[f_i \circ X_i]$.

[証明]. 命題 3.5.3 より

$$E[h] = \int_{\mathbb{R}^n} f_1(x_1) \cdots f_n(x_n) P^X(dx_1, \dots, dx_n)$$

であるが, P^X は直積測度 $P^{X_1} \times \cdots \times P^{X_n}$ であり 3.4.1, 測度空間 \mathbb{R}^n は σ -有限であるから, Fubini の定理より, $\prod_{i \in [n]} E[f_i(X_i)]$ に等しい.

■

系 3.5.5 (分散が和を保つ条件). $(X_i)_{i \in [n]}$ を二乗可積分で: $E[|X_i|^2] < \infty$ ($i = 1, \dots, n$), 対独立な確率変数の列とする. この時, 次が成り立つ: $\text{Var} \left[\sum_{i=1}^n X_i \right] = \sum_{i=1}^n \text{Var}[X_i]$.

[証明]. 2変数の場合,

$$\begin{aligned} V[X + Y] &= E[X + Y - E[X + Y]]^2 = E[(X - EX) + (Y - EY)]^2 \\ &= V[X] + V[Y] + V(X, Y). \end{aligned}$$

であるから, 互いに独立な2変数の共分散は0であることを示せば良いが,

$$V(X, Y) = E[(X - EX)(Y - EY)] = E[XY] - E[X]E[Y] = 0.$$

■

要諦 3.5.6. ものすごく余弦定理っぽく, 内積の構造がある. 実際 Hilbert 空間の内積である. だから二乗可積分の条件があるのだ.

3.5.3 独立同分布

さらに理想的なクラスを定義する。確率変数は分布を定めるが、分布からそれを定める確率変数が存在するかはある種の逆問題で、必ずしも自明でない。

定義 3.5.7 (independent and identically distributed). 実確率変数の列 $(X_i)_{i \in \mathbb{N}}$ が互いに独立であるだけでなく、任意の分布 P^{X_i} ($i \in \mathbb{N}$) が等しい時、 $(X_i)_{i \in \mathbb{N}}$ は**独立同分布**を持つという。

定理 3.5.8 (Kolmogorov extension theorem). 確率空間の列 $(\mathbb{R}^n, \mathcal{B}(\mathbb{R}^n), P_n)$ が次の条件を満たすとする：

$$(\text{consistency}) \quad \forall A \in \mathcal{B}(\mathbb{R}^n) \quad P_n(A) = P_{n+k}(A \times \mathbb{R}^k).$$

この時、 $(\mathbb{R}^\infty, \mathcal{B}(\mathbb{R}^\infty))$ 上の確率測度 P で、 $\forall A \in \mathcal{B}(\mathbb{R}^n) \quad P(\pi_n^{-1}(A)) = P_n(A)$ を満たすものが唯一存在する。ただし、 $\pi_n := (\text{pr}_1, \dots, \text{pr}_n)$ と定めた。

[証明] .

方針 任意の $A_n \in \mathcal{B}(\mathbb{R}^n)$ に対して、 $\Lambda := \pi_n^{-1}(A_n)$ での値を $Q(\Lambda) := P_n(A_n)$ とする有限加法的な確率測度 $Q : \mathcal{B}(\mathbb{R}^\infty) \rightarrow [0, 1]$ を考える。有限加法性の確認は、族 $(A_n)_{n \in \mathbb{N}}$ に対して $m := \max_{n \in \mathbb{N}} \dim(A_n)$ として \mathbb{R}^m 上での P_n の有限加法性を考えれば良い。なお、この Q は well-defined である： $A_n \in \mathcal{B}(\mathbb{R}^n), A_m \in \mathcal{B}(\mathbb{R}^m)$ を用いて $\Lambda = \pi_n^{-1}(A_n) = \pi_m^{-1}(A_m)$ と2通りで表せる場合でも、一貫性の条件より $Q(\Lambda) = P_n(A_n) = P_m(A_m)$ である。 $\mathcal{A} := \{\pi_n^{-1}(A_n) \in \mathbb{R}^\infty \mid A_n \in \mathcal{B}(\mathbb{R}^n), n \in \mathbb{N}\}$ は集合体であることは同様にして明らか。すると、 Q が \mathcal{A} 上で σ -加法的であることを示せば、 \mathbb{R}^∞ は σ -有限であるから、 $\sigma(\mathcal{A}) = \mathcal{B}(\mathbb{R}^\infty)$ 上への一意的な延長が存在し、 Q の定め方よりこれが条件を満たす (Hopf-Kolmogorov の拡張定理)。すると、補題より、任意の単調減少列 $(A_n)_{n \in \mathbb{N}}$ について、 $\alpha := \lim_{n \rightarrow \infty} Q(A_n) > 0 \Rightarrow \cap_{n \in \mathbb{N}} A_n \neq \emptyset$ を示せば良い。

証明 単調減少列 (Λ_n) を任意にとると、 $\Lambda_n = \pi_{n_i}^{-1}(A_{n_i})$ と表せる。 $\max_{n \in \mathbb{N}} n_i$ が存在するならば同様にして自明だから、 $\{n_i\}_{i \in \mathbb{N}} \subset \mathbb{N}$ は非有界とする。すると、部分列をとって添字を打ち直すことより、 $\Lambda_n = \pi_n^{-1}(A_n)$ として良い。

Borel 集合の位相的正則性より、 $C_n \subset A_n, P_n(A_n \setminus C_n) < \frac{\alpha}{2^{n+1}}$ を満たすコンパクト集合の列 $(C_n \subset \mathbb{R}^n)_{n \in \mathbb{N}}$ が取れる。 $D_n := \pi_n^{-1}(C_n)$ と定めると、 $D_n \subset \Lambda_n, Q(\Lambda_n \setminus D_n) < \frac{\alpha}{2^{n+1}}$ を満たす。 $\bar{D}_n := \cap_{k=1}^n D_k$ とおくと、

$$\begin{aligned} Q(\bar{D}_n) &= Q(\Lambda_n) - Q(\Lambda_n \setminus \bar{D}_n) \\ &\geq Q(\Lambda_n) - \sum_{k=1}^n Q(\Lambda_k \setminus D_k) \geq \frac{\alpha}{2} \end{aligned}$$

より、 $\bar{D}_n \neq \emptyset$ である。よって、空でない閉集合の単調減少列の極限は空ではなく、 $\cap_{k=1}^\infty D_k \neq \emptyset$ 。

こうして、 $D_k \subset \Lambda_k$ であって、 $\emptyset \subsetneq \cap_{k=1}^\infty D_k \subset \cap_{k=1}^\infty \Lambda_k$ が従う。

■

注 3.5.9. これは Hopf の拡張定理の一般化に当たる。一般の完備可分距離空間上の確率空間の列について成り立つ。さらに一般的な空間上については、 σ -加法族の表現が変わる 2.8.4.

補題 3.5.10 (有限加法的確率空間の完全加法性の単調族による特徴付け). Q を有限加法的な確率測度、 \mathcal{A} を集合体とする。この時、 Q についての次の2条件は同値。

(1) \mathcal{A} 上 σ -加法的である。すなわち、 $A \in \mathcal{A}$ に収束する互いに素な \mathcal{A} -列 $\{A_n\}_{n \in \mathbb{N}} \subset \mathcal{A}$ について、 $Q(A) = \sum_{n \in \mathbb{N}} Q(A_n)$ 。

(2) 任意の \mathcal{A} の単調減少列 (A_n) に対して、 $Q\left(\lim_{n \rightarrow \infty} A_n\right) = Q\left(\bigcap_{n \in \mathbb{N}} A_n\right) = \lim_{n \rightarrow \infty} Q(A_n)$ 。

(3) 任意の \mathcal{A} の単調減少列 (A_n) に対して、 $\lim_{n \rightarrow \infty} Q(A_n) > 0 \Rightarrow \cap_{n \in \mathbb{N}} A_n \neq \emptyset$ である。

[証明] .

(1) \Rightarrow (2) \mathcal{A} 上の有限加法的測度 μ が \mathcal{A} 上 σ -加法的であることは、任意の単調増加列 (A_n) について $\mu\left(\lim_{n \rightarrow \infty} A_n\right) = \mu\left(\bigcup_{n \in \mathbb{N}} A_n\right) =$

$\lim_{n \rightarrow \infty} A_n$ を満たすことと同値. 任意の単調減少列 (A_n) に対して, その補集合の定める単調増加列を考えると,

$$Q(\lim_{n \rightarrow \infty} A_n) = Q(\cap_{n \in \mathbb{N}} A_n) = 1 - Q(\cup_{n \in \mathbb{N}} \overline{A_n}) = 1 - \lim_{n \rightarrow \infty} Q(\overline{A_n}) = \lim_{n \rightarrow \infty} Q(A_n).$$

最後の等号は Q の有限加法性 $\forall_{n \in \mathbb{N}} Q(A_n + \overline{A_n}) = Q(A_n) + Q(\overline{A_n}) = 1$ による.

(2) \Rightarrow (3) 自明.

(3) \Rightarrow (1) \mathcal{A} 内に収束する互いに素な列 (A_n) を任意に取り, $A := \cup_{n \in \mathbb{N}} A_n$ と定める. $B_1 := A, B_n := A \setminus (\cup_{i=1}^{n-1} A_i)$ と帰納的に定めると, これは \emptyset に収束する単調減少列である. よって,

$$\begin{aligned} \lim_{n \rightarrow \infty} Q(B_n) = 0 &\Leftrightarrow \lim_{n \rightarrow \infty} Q(A \setminus (\cup_{i=1}^{n-1} A_i)) = 0 \\ &\Leftrightarrow \lim_{n \rightarrow \infty} (Q(A) - Q(\cup_{i=1}^{n-1} A_i)) = 0 && \because Q \text{ の有限加法性} \\ &\Leftrightarrow Q(A) = \lim_{n \rightarrow \infty} Q(\cup_{i=1}^{n-1} A_i) = \sum_{n=1}^{\infty} Q(A_n). && \because Q \text{ の有限加法性} \end{aligned}$$

定理 3.5.11 (独立同分布をもつ確率変数の族の存在). \mathbb{R} 上の確率測度 μ を分布にもつ \mathbb{R}^∞ 上の独立同分布 $(X_i)_{i \in \mathbb{N}}$ が存在する.

[証明].

構成 確率空間の列 $((\mathbb{R}^l, \mathcal{B}(\mathbb{R}^l), P_l))_{l \in \mathbb{N}}$ を $P_l := \otimes_{i=1}^l \mu$ と定めると, 一貫性条件を満たすから Kolmogorov の拡張定理 3.5.8 より, \mathbb{R}^∞ 上の確率測度 P で $\forall_{A \in \mathcal{B}(\mathbb{R}^n)} P(\text{pr}_n^{-1}(A)) = P_n(A)$ を満たすものが定まる. これに対して, $X_n := \text{pr}_n : \mathbb{R}^\infty \rightarrow \mathbb{R}$ と定めれば良い.

確認 実際,

(1) (同分布) 任意の $i \in \mathbb{N}$ と $E_i \in \mathcal{B}(\mathbb{R})$ に対して, P の定め方より,

$$\begin{aligned} P^{X_i}(E_i) &= P(\{X_i \in E_i\}) = P(\cap_{j < i} \{X_j \in \mathbb{R}\} \cap \{X_i \in E_i\}) \\ &= P(\pi^{-1}(\mathbb{R}^{i-1} \times E_i)) = P_i(\mathbb{R}^{i-1} \times E_i) && P \text{ の定め方 (一貫性条件)} \\ &= 1 \cdot \mu(E_i). && P_i \text{ の定義} \end{aligned}$$

よって $\forall_{i \in \mathbb{N}} P^{X_i} = \mu$ であるから, $(X_i)_{i \in \mathbb{N}}$ は同分布.

(2) 任意の $i \in \mathbb{N}$ に対して, $\tilde{X} := (X_1, \dots, X_n)$ を同時分布とすると, 任意の $E = E_1 \times \dots \times E_n \in \mathcal{B}(\mathbb{R}^n)$ に対して,

$$\begin{aligned} P^{\tilde{X}}(E) &= P(\cap_{i=1}^n \{X_i \in E_i\}) = P(\pi_n^{-1}(E)) \\ &= P_n(E) = \prod_{i=1}^n \mu(E_i) = \prod_{i=1}^n P^{X_i}(E_i) \end{aligned}$$

より, 独立性も従う.

例 3.5.12 (Bernoulli sequence / process). 特に確率空間 $\mathbb{2}$ を介する射は, ヤヌス対象や 2 進法や TV ではないが, 特殊なクラス of 確率変数である. $P(\{X_i = 0\}) = p, P(\{X_i = 1\}) = 1 - p$ ($0 \leq p \leq 1$) なる分布 $P^X : \{0, 1\} \rightarrow [0, 1]$ に従う 2 値確率変数の列 $(X_i)_{i \in \mathbb{N}}$ を **Bernoulli 過程** という. その存在は独立同分布を持つ確率変数の族の存在 3.5.11 により保証される. 最初の n 回のうちの成功数は二項分布に従い, r 回成功するのに必要な回数は負の二項分布に従う. $r = 1$ を幾何分布という.

3.5.4 独立確率変数列

定理 3.5.13. (μ_n) を $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$ 上の確率測度の列とする. このとき, ある確率空間 (Ω, \mathcal{F}, P) とその上の独立な確率変数列 (X_n) が存在して, $\forall_{n \in \mathbb{N}} X_n \sim \mu_n$ を満たす.

3.6 確率変数の和・積・商の分布

確率変数の積 $(X_1, \dots, X_n) : \Omega_1 \times \dots \times \Omega_n \rightarrow \mathcal{X}_1 \times \dots \times \mathcal{X}_n$ が引き起こす分布を**同時・結合分布**という。これは単に標準的な構成であるが、では、確率変数の演算は、測度の演算にどのように対応するのであろうか？独立な確率変数の和が引き起こす分布は、測度の畳み込みである。

定義 3.6.1 (convolution of measures). $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$ 上の測度 μ, ν の**畳み込み**とは、確率測度

$$\mu * \nu(E) := \int_{\mathbb{R}} \nu(E - y) \mu(dy) = \iint_{\mathbb{R}} \chi_E(x + y) \nu(dx) \mu(dy)$$

を指す。ただし、 $E - y := \{x - y \in \mathbb{R} \mid x \in E\}$ を E を平行移動した集合とした。^{†3}

命題 3.6.2. 2つの確率変数 X_1, X_2 は像測度 μ, ν を定め、互いに独立であるとする。この時、確率変数 $X_1 + X_2$ の像測度は畳み込み $\mu * \nu$ である。

[証明] . 同時分布を $X := (X_1, X_2)$ とおくと、 X_1, X_2 は互いに独立であるから、像測度は直積測度に一致する： $P^X = P^{X_1} \otimes P^{X_2}$ 。よって、任意の事象 $E \in \mathcal{B}(\mathbb{R})$ について、

$$\begin{aligned} \mu * \nu(E) &= \iint_{\mathbb{R}} \chi_E(x + y) P^{X_1}(dx) P^{X_2}(dy) \\ &= \iint_{\mathbb{R}} \chi_E(x + y) P^X(dxdy) \\ &= P(X_1 + X_2 \in E) = P^X(E). \end{aligned}$$

■

3.7 可分完全確率測度

Kolmogorov は晩年完全性を追加した。伊藤清の教科書では可分性も追加した。完全性は像測度に遺伝する。可分性はどこで効いてくるかはわからない。

定義 3.7.1 (perfect (Kolmogorov)). 完備な確率空間 (S, μ) 上の任意の μ -可測関数 $f : S \rightarrow \mathbb{R}$ に対し、像測度 $\mu_* f$ が正則になる時、確率測度 μ を**完全**という。

定義 3.7.2 (separating family, separable).

- (1) S 上の集合族 \mathcal{A} が分離族であるとは、 $\forall s_1 \neq s_2 \in S \exists A \in \mathcal{A} \mathbf{1}_A(s_1) \neq \mathbf{1}_A(s_2)$ を満たすことをいう。
- (2) 完備確率測度 μ について、 $\text{Dom}(\mu)$ が可算分離族を含むとき、 μ を**可分**という。

定理 3.7.3. μ を S 上の確率測度、 $f : S \rightarrow T$ を可測関数とする。像測度 $\nu := \mu f^{-1}$ は完全である。

3.8 事象と確率変数

記法 3.8.1 (extension). 条件 $\alpha \subset \Omega$ について、 α を成立させるような元からなる集合 $\{\alpha\} := \{\omega \in \Omega \mid \alpha(\omega)\}$ を α の外延という。すると、 $\{X(\omega) \leq a\} = X^{-1}((-\infty, a])$ などと表せる。

^{†3} 集合 E を平行移動しながら、元の位置から移動させた時の測度の変化を足し上げていく。

3.9 条件付き期待値

条件付き期待値は素朴には、部分代数 $\mathcal{G} \subset \mathcal{F}$ について、各 $B \in \mathcal{G}$ 上で、 \mathcal{F} が定める測度を積分する演算である。構成論は Lebesgue 積分論で終わらせて居るため、定義は性質のみによって行い、零関数の差に目を瞑る。

3.9.1 動機

議論 3.9.1 (事象の条件付き確率が定める条件付き期待値). ある事象 $B \in \mathcal{F}$ が定める条件付き確率 $P(-|B)$ は、 (Ω, \mathcal{F}) 上の確率測度である。これが定める積分を、条件付き期待値と呼べる。

$$E[X|B] := \frac{E[X, B]}{P(B)}.$$

ただし、 $E[X, B] = E[1_B X]$ とした。これは、積分範囲の制限と規格化に他ならない。これだけでは、概念の射程が限られる。

議論 3.9.2 (条件付き確率の一般化). そこで、条件付き確率の概念を一般の σ -代数に一般化することで、条件付き期待値を一般化することを考える。まずは、有限な直和分割が生成する σ -代数を考える。

(B_i) を事象による Ω の有限な直和分割でいずれも零集合でないとする。 $P[A|(B_i)] := \sum_{i=1}^n P(A|B_i)1_{B_i}$ と定め、条件付き期待値は

$$E[X|(B_i)] := \sum_{i=1}^n E[X|B_i]1_{B_i}$$

と定めると、これは先程の定義の凸結合が与える単関数となっている。 (B_i) の生成する σ -代数を \mathcal{G} で表すと、それぞれを $P[A|\mathcal{G}], E[A|\mathcal{G}]$ と表す。

議論 3.9.3 (測度論的議論). 有限生成とは限らない一般の σ -代数 \mathcal{G} に対する条件付き期待値を定義したい。単関数の無限和とは、積分に他ならない。実は裏技が存在して、満たすべき性質を指定するのみで、Radon-Nykodym の定理により、平均は一意的に定まる。

3.9.2 定義

$E[-|\mathcal{G}] : \text{Meas}_{\mathcal{F}}(\Omega, \mathbb{R}) \rightarrow L^1(\Omega, \mathcal{G})$ は、 \mathcal{F} -可測な確率変数に対して、ある \mathcal{G} -可測な確率変数の同値類を与える。しかし、 $E[X, B] = E[Y, B]$ を満たすため、確率変数としての本質は変わらない。すなわち、 \mathcal{G} に応じて、解像度を粗くするのである。

定義 3.9.4 (conditional expectation). 次の条件を満足する確率変数 $Y : \Omega \rightarrow \mathbb{R}$ を、 \mathcal{G} に関する X の**条件付き期待値**と呼ぶ。

- (1) Y は \mathcal{G} -可測で P -可積分。
- (2) 任意の $B \in \mathcal{G}$ に対して $E[X, B] = E[Y, B]$ すなわち $\int_B X(\omega)P(d\omega) = \int_B Y(\omega)P(d\omega)$ を満たす。

この Y を $E[X|\mathcal{G}]$ で表す。 X が可測関数の特性関数である場合、 $P(A|\mathcal{G}) := E[1_A|\mathcal{G}]$ ($A \in \mathcal{F}$) を**条件付き確率**という。

例 3.9.5 (自明な例).

- (1) $\mathcal{G} = \mathcal{F}$ のとき、 $E[X|\mathcal{F}] = X$ a.s. である。
- (2) $\mathcal{G} = \{\emptyset, \Omega\}$ のとき、 $E[X|\mathcal{G}] = E[X]$ で、定数関数である。

補題 3.9.6 (well-definedness).

- (1) $E[X|\mathcal{G}]$ は存在する。
- (2) $E[X|\mathcal{G}]$ は P -零集合を除いて一意である。

【証明】. $Q(B) := E[X, B] = E1_B X$ ($B \in \mathcal{G}$) をおくことで, Q は (Ω, \mathcal{G}) 上の確率測度を定める. いま, $P|_{\mathcal{G}}$ に関して Q は絶対連続: $\forall B \in \mathcal{G} \quad P(B) = 0 \Rightarrow Q(B) = 0$ が成り立つから, Radon-Nikodym の定理より, ある \mathcal{G} -可測で P -可積分な関数 $Y: \Omega \rightarrow \mathbb{R}$ が存在して, $\forall B \in \mathcal{G} \quad Q(B) = \int_B Y(d\omega)P(d\omega)$ が成り立つ. よって, (1),(2) が成り立つ. ■

例 3.9.7 (条件付き確率). $(\Omega_j)_{j \in \mathbb{N}}$ を Ω の分割で, $P[\Omega_j] > 0$ とする. $\mathcal{G} := \sigma[\Omega_j | j \in \mathbb{N}]$ と定めると, 可積分確率変数 X に関して,

$$E[X|\mathcal{G}] = \sum_{j \in \mathbb{N}} \frac{E[X1_{\Omega_j}]}{P(\Omega_j)} 1_{\Omega_j} \quad \text{a.s.}$$

が成り立つ.

3.9.3 性質

$E[-|\mathcal{G}]: \mathcal{L}^1(\Omega, \mathcal{F}) \rightarrow L^1(\Omega, \mathcal{G})$ は関数空間上の正な線型作用素である. 1 次平均収束を保つという意味で, $\mathcal{L}^1(\Omega, \mathcal{F})$ 上ノルム連続, すなわち有界である.

また, Hilbert 空間 $L^2(\Omega, \mathcal{F})$ 上で見ると, $E[-|\mathcal{G}]$ は, \mathcal{G} -可測関数がなす閉部分空間への直交射影となる.

補題 3.9.8. $X, Y \in \mathcal{L}^1(\Omega, \mathcal{F})$ とする.

- (1) 線形性: $\forall a, b \in \mathbb{R} \quad E[aX + bY|\mathcal{G}] = aE[X|\mathcal{G}] + bE[Y|\mathcal{G}] \quad \text{a.s.}$ ^{†4}
- (2) 正: $X \geq 0 \text{ a.s.} \Rightarrow E[X|\mathcal{G}] \geq 0 \text{ a.s.}$ 特に, $X \leq Y \text{ a.s.} \Rightarrow E[X|\mathcal{G}] \leq E[Y|\mathcal{G}] \text{ a.s.}$
- (3) $X \in \text{Meas}_{\mathcal{G}}(\Omega, \mathbb{R})$, $XY \in \mathcal{L}^1(\Omega, \mathcal{F})$ のとき, $E[XY|\mathcal{G}] = XE[Y|\mathcal{G}] \text{ a.s.}$ 特に, $E[X|\mathcal{G}] = X \text{ a.s.}$
- (4) $\mathcal{H} \subset \mathcal{G}$ を部分 σ -代数とする. $E[E[X|\mathcal{G}]|\mathcal{H}] = E[X|\mathcal{H}] \text{ a.s.}$ 特に, $E[E[X|\mathcal{G}]] = E[X]$.
- (5) $\sigma(X)$ と \mathcal{G} とが独立ならば, $E[X|\mathcal{G}] = E[X] \text{ a.s.}$ したがって, $f: \mathbb{R} \rightarrow \mathbb{R}$ を Borel 可測関数とすると, $f(X) \in \mathcal{L}^1(\Omega, \mathcal{F}) \Rightarrow E[f(X)|\mathcal{G}] = E[f(X)] \text{ a.s.}$

【証明】.

- (1) 右辺 $Z := aE[X|\mathcal{G}] + bE[Y|\mathcal{G}]$ は定義より, \mathcal{G} -可測関数で P -可積分である. 任意の $B \in \mathcal{G}$ について,

$$\begin{aligned} E[aX + bY, B] &= aE[X, B] + bE[Y, B] \\ &= aE[E[X|\mathcal{G}], B] + bE[E[Y|\mathcal{G}], B] \\ &= E[aE[X|\mathcal{G}] + bE[Y|\mathcal{G}], B] = E[Z, B] \end{aligned}$$

が成り立つ. よって, 条件付き期待値の一意性より, $E[aX + bY|\mathcal{G}] = Z \text{ a.s.}$

- (2) $Z := E[X|\mathcal{G}]$ は $\forall B \in \mathcal{G} \quad E[Z, B] = E[X, B] \geq 0 \text{ a.s.}$ を満たす. これは $Z \geq 0 \text{ a.s.}$ を含意する.
- (3) 右辺は \mathcal{G} -可測で P -可積分だから, 任意の $B \in \mathcal{G}$ について $E[XY, B] = E[XE[Y|\mathcal{G}], B]$ を示せば, 条件付き期待値の一意性から従う. 単関数の場合から示す.
- (4) 両辺とも \mathcal{H} -可測で P -可積分だから, 任意の $B \in \mathcal{H}$ について

$$E[E[E[X|\mathcal{G}], \mathcal{H}], B] = E[X, B]$$

を示せば, 条件付き期待値の一意性から従う. この左辺はまず $E[E[X|\mathcal{G}], B]$ に一致する必要があるが, $B \in \mathcal{G}$ でもあるから, これらはさらに $E[X, B]$ なる右辺に一致する必要がある.

- (5) 独立性は, $\forall B \in \mathcal{G} \quad E[X, B] = E[1_B X] = E[X]P(B) = E[E[X], B]$ を含意する 3.5.4. これは $E[X|\mathcal{G}] = E[X] \text{ a.s.}$ を意味する. また, $f(X)$ と \mathcal{G} も独立である 3.4.2. ■

命題 3.9.9 (Jensen の不等式). $\psi: \mathbb{R} \rightarrow \mathbb{R}$ を凸関数とする. $X, \psi(X) \in \mathcal{L}^1(\Omega)$ のとき,

$$\psi(E[X|\mathcal{G}]) \leq E[\psi(X)|\mathcal{G}] \text{ a.s.}$$

^{†4} 除外集合 $N_{a,b}$ は任意の $a, b \in \mathbb{R}$ について一様には取ることが一般には出来ない.

特に, $X \in \mathcal{L}^p(\Omega)$ のとき, $|E[X|\mathcal{G}]|^p \leq E[|X|^p|\mathcal{G}]$ a.s..

命題 3.9.10 (条件付き期待値の連続性). $\mathcal{L}^1(\Omega)$ の列 (X_n) が X に 1 次平均収束するとき, $E[X_n|\mathcal{G}]$ も $E[X|\mathcal{G}]$ に 1 次平均収束する.

定理 3.9.11 (直交射影としての条件付き期待値). $L^2_{\mathcal{G}}$ を, $L^2(\Omega, \mathcal{F})$ 内の \mathcal{G} -可測関数がなす閉部分空間とする. $Y \in L^2(\Omega, \mathcal{F})$ について,

$$E[(Y - E[Y|\mathcal{G}])^2] = \min_{Z \in L^2_{\mathcal{G}}} E[(Y - Z)^2].$$

3.9.4 可測写像を与えたもとの条件付き期待値

部分 σ -代数 $i: (\Omega, \mathcal{G}) \hookrightarrow (\Omega, \mathcal{F})$ から, 一般の可測写像へさらに一般化する.

記法 3.9.12. (Ω, \mathcal{F}, P) 上の可積分確率変数 $X \in \mathcal{L}^1(\Omega)$ と, 可測空間 $(\mathcal{T}, \mathcal{G})$ への可測写像 $T: \Omega \rightarrow \mathcal{T}$ を考える.

定義 3.9.13. 次の 2 条件を満たす関数 $g: \mathcal{T} \rightarrow \mathbb{R}$ を, $T = t$ の下での X の条件付き期待値という:

- (1) g は \mathcal{G} -可測かつ P^T 可積分.
- (2) $\forall B \in \mathcal{G} \quad \int_{T^{-1}(B)} X(\omega) P(d\omega) = \int_B g(t) P^T(dt).$

g は P^T -零集合を除いて一意であり, これを $E[X|T = t]$ で表す. すなわち,

$$\forall B \in \mathcal{G} \quad \int_{T^{-1}(B)} X(\omega) P(d\omega) = \int_B E[X|T = t] P^T(dt).$$

補題 3.9.14 (well-definedness).

$$E[X|\sigma(T)] = E[X|T] \text{ } P\text{-a.s.}$$

ただし, $\sigma[T] := \{T^{-1}(B) \in \mathcal{P}(\Omega) \mid B \in \mathcal{G}\}$ で, $E[X|T](\omega) := E[X|T = t]|_{t=T(\omega)}$ とした.

定義 3.9.15 (条件付き確率).

- (1) 部分 σ -加法族 $\mathcal{G} \subset \mathcal{F}$ に関する事象 $A \in \mathcal{F}$ の条件付き確率を, $P[A|\mathcal{G}] := E[1_A|\mathcal{G}]$ で定める.
- (2) $T = t$ の下での事象 $A \in \mathcal{F}$ の条件付き確率を, $P[A|T = t] := E[1_A|T = t]$ で定める.

注 3.9.16. これは規格化しておらず, 実際に A 上に確率測度を定めるかどうかは問うていない.

3.9.5 正則条件付き確率

定義 3.9.17 (regular conditional probability). 族 $(p(\omega, A))_{\omega \in \Omega, A \in \mathcal{F}}$ が次の 3 条件を満たすとき, 部分 σ -代数 \mathcal{G} が与えられたときの正則条件付き確率であるという:

- (1) $\forall \omega \in \Omega \quad p(\omega, -): \mathcal{F} \rightarrow [0, 1]$ は確率測度を定める.
- (2) $\forall A \in \mathcal{F} \quad p(-, A): \Omega \rightarrow [0, 1]$ は \mathcal{G} -可測.
- (3) $\forall A \in \mathcal{F} \quad \forall B \in \mathcal{G} \quad P(A \cap B) = \int_B p(\omega, A) P(d\omega).$

定義 3.9.18. 可測空間 (Ω, \mathcal{F}) が条件 (S) を満たすとは,

- (1) [6] では, ある距離 d によって完備可分距離空間となり, \mathcal{F} はその Borel σ -加法族となること.
- (2) [4] では, 可分完全確率空間とする.
- (3) Ikeda-Watanabe では, 標準確率空間とする.

応用上 (1) で十分らしいので, これでいこう.

定理 3.9.19 (存在と一意性). 条件 (S) を満たす可測空間 (Ω, \mathcal{F}) 上の, 任意の確率測度 P と任意の部分 σ -代数 \mathcal{G} に対して, \mathcal{G} が与えられたときの正則条件付き確率 $(p(\omega, A))_{\omega \in \Omega, A \in \mathcal{F}}$ は存在し, 零集合の差を除いて一意である.

定義 3.9.20. $T : (\Omega, \mathcal{F}, P) \rightarrow (\mathcal{T}, \mathcal{B}), X : (\Omega, \mathcal{F}, P) \rightarrow (\mathcal{X}, \mathcal{A})$ を可測とする. $(p(t, A))_{t \in \mathcal{T}, A \in \mathcal{A}}$ が, $T = t$ の下での X の条件付き確率分布であるとは, 次の3条件を満たすことをいう:

- (1) $\forall t \in \mathcal{T} \ p(t, -) : \mathcal{A} \rightarrow [0, 1]$ は $(\mathcal{X}, \mathcal{A})$ 上の確率測度である.
- (2) $\forall A \in \mathcal{A} \ p(-, A) : \mathcal{T} \rightarrow [0, 1]$ は \mathcal{B} -可測関数である.
- (3) $\forall A \in \mathcal{A} \ \forall B \in \mathcal{B} \ P[X \in A, T \in B] = \int_B p(t, A) P^T(dt).$

定理 3.9.21 (存在と一意性). 条件 (S) を満たす可測空間 $(\mathcal{X}, \mathcal{A})$ 上の, $T = t$ の下での X の条件付き確率分布は存在し, 零集合の差を除いて一意である.

命題 3.9.22 (Fubini の類似). $f : \mathcal{T} \times \mathcal{X} \rightarrow \mathbb{R}$ は $\mathcal{B} \times \mathcal{A}$ -可測で, $P^{(T, X)}$ -可積分であるとする. このとき,

$$\int_{\mathcal{T} \times \mathcal{X}} f(t, x) dP^{(T, X)}(t, x) = \int_{\mathcal{T}} \left[\int_{\mathcal{X}} f(t, x) p(t, dx) \right] dP^T(t).$$

特に, 可積分実確率変数 X に対して,

$$E[X|T = t] = \int_{\mathbb{R}} x p(t, dx) \ P^T\text{-a.s.}$$

命題 3.9.23 (多変量正規分布の条件付き分布は再び多変量正規分布となる). d_1 次元確率変数 X_1 と d_2 次元確率変数 X_2 の結合分布は $d_1 + d_2$ 変量正規分布で, $E[X_i] = \mu_i, \text{Cov}[X_i, X_j] = \Sigma_{ij}$ とおく. $\Sigma_{11} \in M_{d_1}(\mathbb{R})$ が正則ならば, $X_1 = x_1$ の下での X_2 の正則条件付き分布は, 多変量正規分布 $N_{d_2}(\mu_2 + \Sigma_{21}\Sigma_{11}^{-1}(x_1 - \mu_1), \Sigma_{22} - \Sigma_{21}\Sigma_{11}^{-1}\Sigma_{12})$ である.

注 3.9.24. Σ_{11} が退化しているときも, Σ_{11}^{-1} を一般化逆行列とすれば, 同様の結果が成り立つ.

3.10 0-1 法則

末尾事象は, \mathcal{F} の部分 σ -代数の列 (\mathcal{G}_k) のうち, 無限個によって指定される事象 (各有限部分列と独立な事象) をいう. 例えば, 級数 $\sum_{n=0}^{\infty} X_n$ が収束するという事象は末尾事象である.

これにより, 「情報」的な概念を完全に σ -加法族に翻訳しつつある. Borel-Cantelli の補題の一般化であることは明らかである.

定義 3.10.1 (tail field). (\mathcal{G}_k) を, \mathcal{F} の部分 σ -代数の列とする. このとき,

$$\mathcal{G}_k := \sigma\left(\bigcup_{j=k}^{\infty} \mathcal{G}_j\right), \quad \mathcal{T} := \bigcap_{k=1}^{\infty} \mathcal{G}_k$$

と定まる \mathcal{T} を, 末尾加法族という.

定理 3.10.2 (Kolmogorov 0-1). $\forall A \in \mathcal{T} \ P(A) \in \{0, 1\}$.

系 3.10.3. (X_n) を独立な確率変数列とする. 見本平均の概収束極限 $Y := \lim_{n \rightarrow \infty} \frac{1}{n} \sum_{k=1}^n X_k$ が存在するとする. このとき, Y は殆ど確実に定数である.

第 4 章

独立確率変数列の和

確率過程論への入門として、独立確率変数列の和に関して成り立つ極限定理を調べる。実際、大数の法則の一般化・精緻化が喫緊の問題であった 1930 年代の確率論では最重要分野であった。この理論の一般化が martingale である。

- (1) 見本平均は、和を規格化したものである（新たな測度を考えているとも捉えられる）。この極限が収束することは末尾事象で、概収束か概発散かが起こる。実は確率 1 で収束する。
- (2) 弱法則は、対独立性と分散の一樣有界性を必要とする。強法則は独立性に関しては強い条件を要求するが、分散の有界性については弱められる。
- (3) 実は応用上もっとも中心的な興味は、大数の法則の収束の速度に関する情報である。実は、速度は $O(1/\sqrt{n})$ であり、1 次の項の形も標準的に得られるが、収束の強さは法則収束までである。

大偏差原理を見ると、確率論は関数解析と結びついて、現代の物理学を生んだような、とてつもない表現力を持ち得る可能性を感じる。

4.1 確率不等式

Markov の不等式 2.5.2 より

$$\forall_{k \in [n]} P[|S_k| \geq a] \leq \frac{1}{a^2} E[|S_k|^2] = \frac{1}{a^2} \sum_{i=1}^k V_i \leq \frac{1}{a^2} \sum_{i=1}^n V_i$$

同様の事実が、 $\max_{k \in [n]} |S_n|$ についても同じ評価が出来る。そこで、マルチンゲールへの視点変更が起こった。劣マルチンゲールであるから、最後の時点 S_n にだけ注目すれば良いのである。

定理 4.1.1 (Kolmogorov). 実確率変数列 $\{X_n\} \subset L^2(\Omega, \mathcal{F}, P)$ は独立で、 $E[X_n] = 0, V_n := \text{Var}[X_n] < \infty$ を満たすとする。このとき、 $S_k := \sum_{i=1}^k X_k$ とおくと、

$$\forall_{a>0} P[\max_{k \in [n]} |S_k| \geq a] \leq \frac{1}{a^2} \sum_{i=1}^n V_i.$$

[証明] .

$$A^* := \left\{ \omega \in \Omega \mid \max_{k \in [n]} |S_k| \geq a \right\} \quad A_k^* := \left\{ \omega \in \Omega \mid \forall_{i \in [k-1]} |S_i| < a \wedge |S_k| \geq a \right\}$$

とおくと、 $A^* = \sum_{k \in [n]} A_k^*$ が成り立ち、 $A_k^* \in \sigma[X_1, \dots, X_k]$. いま、 (S_n^2) は劣マルチンゲールで、特に $\forall_{k \in [n-1]} E[Z_n^2, A_k^*] \geq E[Z_k^2, A_k^*]$ より、

$$\begin{aligned} P[A^*] &= \sum_{k \in [n]} P[A_k^*] \leq \sum_{k \in [n]} \frac{1}{a^2} E[S_k^2, A_k^*] && \because A_k^* \text{ 上では } a^2 \leq S_k^2 \\ &\leq \frac{1}{a^2} \sum_{k \in [n]} E[S_n^2, A_k^*] = \frac{1}{a^2} E[S_n^2, A^*] \end{aligned}$$

$$\leq \frac{1}{a^2} E[S_n^2] = \frac{1}{a^2} \sum_{i=1}^n V_i.$$

4.2 独立同分布に関する大数の法則

大数の法則は物理学実験でも扱ったある種の自然現象であるが、これが定理として導けるような公理系を、我々は用意できたのである。実際は、いずれの大数の法則も、仮定は可積分性 $E[|X_1|] < \infty$ で十分。

定義 4.2.1 (convergence in probability, almost sure convergence).

- (1) 確率変数の族 $(Y_i)_{i \in \mathbb{N}}$ と確率変数 X について、次が成り立つ時、 (Y_n) は X に**確率収束**するという： $\forall \epsilon > 0 \lim_{n \rightarrow \infty} P(|Y_n - X| \geq \epsilon) = 0$.
- (2) 確率変数の族 $(Y_i)_{i \in \mathbb{N}}$ と確率変数 X について、次が成り立つ時、 (Y_n) は X に**概収束**するという： $P\left(\lim_{n \rightarrow \infty} Y_n = X\right) = 1$.

それぞれを形式化すると、

- (1) $\forall \epsilon_1 > 0 \forall \epsilon_2 > 0 \exists N > 0 \forall n \geq N P(|Y_n - X| \geq \epsilon_1) < \epsilon_2$.
- (2) $\forall \epsilon > 0 \exists N > 0 \forall n \geq N P(Y_n = X) = 1 - \epsilon$.

すると、(2) \Rightarrow (1) であるが、(1) \Rightarrow (2) は反例が構成できる。^{†1}

独立同分布の場合は期待値について

$$E\left[\left|\sum_{i=1}^n (X_i - \mu)\right|^{2k}\right] = \sum_{i_1, \dots, i_{2k}} E[(X_{i_1} - \mu) \cdots (X_{i_{2k}} - \mu)] \leq C n^k \quad \exists C \in \mathbb{R}$$

という評価が使えるので議論が簡単になる。

4.2.1 独立同分布での大数の弱法則

まず収束とは何かが問題になる。収束とは基本的に距離空間で定義される概念であるが、測度を用いて一般化することが出来るのであった。確率収束は概収束より弱いので、

記法 4.2.2. 確率空間 (Ω, \mathcal{F}, P) 上の独立同分布 $(X_i)_{i \in \mathbb{N}}$ に対して、 $S_n := \sum_{i=1}^n$ と定める。

定理 4.2.3 (weak law of large numbers). 独立同分布を持つ確率変数の族 $(X_i)_{i \in \mathbb{N}}$ が二乗可積分であるとする： $E[(X_1)^2] < \infty$. この時、次が成り立つ：

$$\forall \epsilon > 0 \lim_{n \rightarrow \infty} P\left(\left|\frac{S_n}{n} - E[X_1]\right| \geq \epsilon\right) = 0.$$

【証明】 . Schwarz の不等式より、 $E[|X_1|] \leq \sqrt{E[(X_1)^2]} < \infty$ であるから、特に可積分である。任意の $\epsilon > 0$ と $n \in \mathbb{N}_{>0}$ に対して、 $X := |S_n - nE[X_1]|, f(a) = a^2$ とすると、Chebyshev の不等式 1.7.10 より、

$$P(|S_n - nE[X_1]| \geq n\epsilon) \leq \frac{E[|S_n - nE[X_1]|^2]}{(n\epsilon)^2} = \frac{nE[|X_1 - E[X_1]|^2]}{(n\epsilon)^2}$$

より結論を得る。なお、最右辺の変形は、独立な確率変数に対する分散の線型性 3.5.5 による。

^{†1} Y_n がかさばりながら X に近づくとき、 ϵ 範囲には必ず入るが、 $\epsilon/2$ 範囲には半分しか入らない、というような収束の仕方もあるはずである。

4.2.2 独立同分布での大数の強法則

確率収束は位相を定め、また距離化可能でもあるが、

定理 4.2.4 (strong law of large numbers). 独立同分布を持つ確率変数の族 $(X_i)_{i \in \mathbb{N}}$ が4乗可積分であるとする： $E[(X_1)^4] < \infty$. この時、次が成り立つ：

$$P\left(\lim_{n \rightarrow \infty} \frac{S_n}{n} = E[X_1]\right) = 1.$$

[証明] . 以下のことに注意する.

- (1) Schwarz の不等式より $E[|X_1|] \leq (E[(X_1)^2])^{1/2} \leq (E[(X_1)^4])^{1/4} < \infty$ であるから特に可積分.
- (2) 2次と4次の中心積率は

$$E[(X_1 - \mu)^4] \leq 8(E[(X_1)^4] + \mu^4) < \infty, \quad E[(X_1 - \mu)^2] \leq 2(E[(X_1)^2] + \mu^2) < \infty,$$

と評価できる.

Chebyshev の不等式で期待値へ還元 $A_n^\epsilon := \left\{ \omega \in \Omega \mid \left| \frac{S_n(\omega)}{n} - m \right| > \epsilon \right\}$ と置くと, $f(a) = a^4$ についての Chebyshev の不等式 1.7.10 より,

$$P(A_n^\epsilon) = P\left(\left|\sum_{i=1}^n (X_i - \mu)\right| > \epsilon n\right) \leq \frac{E\left[\left(\sum_{i=1}^n (X_i - \mu)\right)^4\right]}{(\epsilon n)^4}$$

と評価できる.

期待値を抑える 4次の中心積率の和は

$$\begin{aligned} E\left[\left(\sum_{i=1}^n (X_i - \mu)^4\right)\right] &= \sum_{i_1, i_2, i_3, i_4=1}^n E[(X_{i_1} - \mu)(X_{i_2} - \mu)(X_{i_3} - \mu)(X_{i_4} - \mu)] \\ &= nE[(X_1 - \mu)^4] + 3n(n-1)(E[(X_1 - \mu)^2])^2 \quad \because \text{独立な変数の共分散は0} \\ &\leq Cn^2 \quad \exists C \in \mathbb{R} \end{aligned}$$

と評価できるから,

$$\sum_{n=1}^{\infty} P(A_n^\epsilon) \leq \sum_{n=1}^{\infty} \frac{C}{(\epsilon n)^4} n^2 = \frac{C}{\epsilon^4} \sum_{n=1}^{\infty} \frac{1}{n^2} < \infty$$

である.

Borel-Cantelli の補題 $B_\epsilon := \limsup_{n \rightarrow \infty} A_n^\epsilon = \left\{ \omega \in \Omega \mid \limsup_{n \rightarrow \infty} \left| \frac{S_n(\omega)}{n} - \mu \right| > \epsilon \right\}$ とすると, Borel-Cantelli の補題 1.2.9(1) より, $P(B_\epsilon) = 0$.

結論 以上より, 補集合が

$$\begin{aligned} P\left(\left\{ \omega \in \Omega \mid \lim_{n \rightarrow \infty} \left| \frac{S_n(\omega)}{n} - \mu \right| = 0 \right\}^c\right) &= P\left(\lim_{\epsilon \rightarrow 0} \left\{ \omega \in \Omega \mid \limsup_{n \rightarrow \infty} \left| \frac{S_n(\omega)}{n} - \mu \right| > \epsilon \right\}\right) \\ &\leq P(\lim_{n \rightarrow \infty} B_\epsilon) = \lim_{\epsilon \rightarrow 0} P(B_\epsilon) \because (B_\epsilon)_{\epsilon > 0} \text{は単調減少族より.} \\ &= 0. \end{aligned}$$

■

4.2.3 証明抽出と評価の精緻化

次の定理は Hausdorff が Bernoulli 列の場合について最初に証明した.

定理 4.2.5. $\forall_{k \in \mathbb{N}} E[|X_1|^k] < \infty$ のとき, 任意の $\epsilon' > 0$ に対して, $P\left(\lim_{n \rightarrow \infty} \frac{S_n - n\mu}{n^{1/2+\epsilon'}} = 0\right) = 1$. $\epsilon' = 1/2$ のときを大数の強法則という.

定理 4.2.6 (収束のオーダー : law of iterated logarithm (Khinchin)). $E[(X_1)^2] < \infty$ のとき, X_1 の分散を σ^2 とすると,

$$P\left(\limsup_{n \rightarrow \infty} \frac{|S_n| - n\mu}{\sqrt{2n \log \log n}} = \sigma\right) = 1$$

4.3 一般の大数の弱法則

定義 4.3.1. 一般の $\mathcal{L}^1(\Omega, \mathcal{F}, P)$ の列 (X_n) に対して, $Y_n := \frac{1}{n} \sum_{k=1}^n X_k, \bar{m}_n := \frac{1}{n} \sum_{k=1}^n m_k$ とおく.

(1) $\lim_{n \rightarrow \infty} P(|Y_n - \bar{m}_n| > \epsilon) = 0$ が成り立つとき, 大数の弱法則を満たすという.

(2) $P\left(\lim_{n \rightarrow \infty} |Y_n - \bar{m}_n| = 0\right) = 0$ が成り立つとき, 大数の強法則を満たすという.

定理 4.3.2. $\{X_n\} \subset \mathcal{L}^1(\Omega, \mathcal{F}, P)$ が次の 2 条件を満たすとき, 大数の弱法則を満たす:

(1) (X_n) は対独立である.

(2) $\sup_{n \in \mathbb{N}} \text{Var}[X_n] < \infty$. 特に, $\{X_n\} \subset \mathcal{L}^2(\Omega, \mathcal{F}, P)$ である.

なお, 確率収束するだけでなく, 特に 2 次平均収束する.

[証明]. 任意の $\epsilon > 0$ を取る.

$$\begin{aligned} P[|\widetilde{Y}_n| > \epsilon] &\leq \frac{E[\widetilde{Y}_n^2]}{\inf_{|x| > \epsilon} x^2} && \because \text{Chebyshev の不等式 1.7.10} \\ &= \frac{E[\hat{Y}_n^2]}{\epsilon^2} = \frac{1}{\epsilon^2} E[(Y_n - \bar{m}_n)^2] \\ &= \frac{1}{\epsilon^2} E\left[\frac{1}{n^2} \left(\sum_{k=1}^n X_k - \sum_{k=1}^n m_k\right)^2\right] \\ &= \frac{1}{\epsilon^2 n^2} \sum_{j,k=1}^n E[(X_j - m_j)(X_k - m_k)] \\ &= \frac{1}{\epsilon^2 n^2} \sum_{k=1}^n E[(X_k - m_k)^2] && \because \text{対独立} \\ &= \frac{1}{\epsilon^2 n^2} \sum_{k=1}^n \text{Var}[X_k] \\ &\leq \frac{1}{\epsilon^2 n} \sup_{n \in \mathbb{N}} \text{Var}[X_n] \xrightarrow{n \rightarrow \infty} 0. \end{aligned}$$

結局証明では, $E[|Y_n - \bar{m}_n|^2] \xrightarrow{n \rightarrow \infty} 0$ を示しているので, 2 次平均収束する. ■

4.4 一般の大数の強法則

定理 4.4.1 (Kolmogorov 1). $\{X_n\} \subset \mathcal{L}^1(\Omega, \mathcal{F}, P)$ が次の 2 条件を満たすとき, 大数の強法則を満たす:

(1) (X_n) は独立である.

(2) $\sum_{n=1}^{\infty} \frac{1}{n^2} \text{Var}[X_n] < \infty$.

定理 4.4.2 (Kolmogorov 2). 独立同分布に従う確率変数の族 $\{X_n\} \subset \mathcal{L}^1(\Omega, \mathcal{F}, P)$ は, 大数の強法則を満たす.

4.5 数学における大数の法則的現象

4.5.1 Weierstrass の多項式近似

Bernstein の基底関数 $b_{k,b}$ を Bernolli 試行 $B(n, x)$ の確率 $b(k; n, x)$ を表していると見ると, Weierstrass の多項式近似の議論は大数の法則の議論と同じ構造をしている. すなわち, 各サンプル $k/n \in [0, 1]$ で重み付きに近似していけば, $k/n \rightarrow x$ に概収束するから, $f(x)$ は $P_n(x)$ で近似できる. すると, 全ての関数は確率変数の退化 (特殊化) なのかもしれない. となると, 物理学理論が確率論化したのは自然で, いずれ全ての理論がそうなるであろうという新たな自然法則に向き合いつつあるのかもしれない. 2項展開の各項を Bernolli 過程の確率を表す項 $b(k; n, x)$ と見る, という見方は, 確率論を形式化した恩恵なのかもしれない.

定義 4.5.1 (Bernstein polynomial). $b_{k,b}(x) := \binom{n}{k} x^k (1-x)^{n-k}$ ($k \in n+1$) の形で表される多項式を, n 次の **Bernstein の (基底) 関数** という. これらは n 次以下の多項式がなす実線型空間の基底をなし, 1 の分割をなす: $\sum_{k=0}^n b_{k,n} = 1$.

これに対して, $B_n : C([0, 1]) \rightarrow \mathbb{R}[x]$ を $B_n(f) := \sum_{k=0}^n f\left(\frac{k}{n}\right) b_{k,n}$ とおくと, 一様位相において $\lim_{n \rightarrow \infty} B_n(f) = f$.

定理 4.5.2 (Weierstrass の多項式近似). 任意の連続関数 $f \in C([0, 1])$ について, 多項式の列 $(P_n)_{n \in \mathbb{N}}$ ($\deg P_n = n$) が存在して, $\lim_{n \rightarrow \infty} \max_{x \in [0, 1]} |P_n(x) - f(x)| = 0$.

[証明].

構成 任意の $x \in [0, 1]$ について, これを成功確率とする Bernoulli 試行 $B(n, x)$ に従う Bernoulli 列 $(X_i^x)_{i \in \mathbb{N}}$ を取る (独立同分布に従う確率変数の列の存在定理 3.5.11). これが定める確率変数を $S_n^x := \sum_{i=1}^n X_i^x$ とすると, この Bernoulli 試行

$B(n, x)$ の期待値の f による押し出しの期待値を $P_n(x) := E\left[f\left(\frac{S_n^x}{n}\right)\right]$ とすると, $k \in n+1$ 回成功する確率はそれぞれ

$$P(S_n = k) = \binom{n}{k} x^k (1-x)^{n-k} \text{ と表せるため,}$$

$$P_n(x) = \sum_{k=1}^n f\left(\frac{k}{n}\right) \cdot \binom{n}{k} x^k (1-x)^{n-k}$$

とも表せる.

検証 いま, $\delta : \mathbb{R}_{\geq 0} \rightarrow \mathbb{R}_{\geq 0}$ を $\delta(\epsilon) := \sup \{|f(x) - f(y)| \in \mathbb{R}_{\geq 0} \mid x, y \in [0, 1], |x - y| \leq \epsilon\}$ と定めると, $[0, 1]$ 上の関数は連続ならば一様連続だから, $\epsilon \rightarrow 0$ のとき $\delta(\epsilon) \rightarrow 0$. また, $M := \max_{x \in [0, 1]} |f(x)|$ とおくと, 任意の $\epsilon > 0$ に対して,

$$\begin{aligned} \max_{x \in [0, 1]} |f(x) - P_n(x)| &= \max_{x \in [0, 1]} \left| E\left[f(x) - f\left(\frac{S_n}{n}\right)\right] \right| & P_n(x) &= E\left[f\left(\frac{S_n}{n}\right)\right] \\ &\leq \max_{x \in [0, 1]} E\left[\left|f(x) - f\left(\frac{S_n}{n}\right)\right|\right] \\ &= \max_{x \in [0, 1]} \left\{ \int_{\{\omega \in \Omega \mid \left|\frac{S_n(\omega)}{n} - x\right| \geq \epsilon\}} \left|f(x) - f\left(\frac{S_n}{n}\right)\right| dP \right. \\ &\quad \left. + \int_{\{\omega \in \Omega \mid \left|\frac{S_n(\omega)}{n} - x\right| < \epsilon\}} \left|f(x) - f\left(\frac{S_n}{n}\right)\right| dP \right\} \\ &\leq \max_{x \in [0, 1]} 2MP(|S_n(\omega)n - x| \geq \epsilon) + \delta(\epsilon) & \text{第一項は } M \text{ の } 2 \text{ 倍で, 第二項は } \delta(\epsilon) \text{ で抑えられる} \\ &\leq \max_{x \in [0, 1]} \frac{2Me[|X_1^x - x|^2]}{n\epsilon^2} + \delta(\epsilon) & \text{大数の弱法則 4.2.3 と同様 Chebyshev の不等式} \\ &\leq \frac{2M}{n\epsilon^2} + \delta(\epsilon) & B(1, x) \text{ の分散 } \leq x(1-x) \leq 1 \end{aligned}$$

と評価できる. すると, $\forall \epsilon > 0 \exists N > 0 \forall n \geq N \max_{x \in [0,1]} |f(x) - P_n(x)| < \epsilon$ を得た.

■

要諦 4.5.3. $f \in C([0,1])$ を, 確率空間 $([0,1], \mathcal{B}([0,1]), P)$ 上の実確率変数だと思えば, 少し難しすぎる. そこで, 離散的な確率空間へと引き戻して考え, これらの離散空間からの実確率変数の列 $\lim_{n \rightarrow \infty} (n^{-1})^* f$ の極限だと考える:

$$\begin{array}{ccccc} n+1 & \xrightarrow{\times \frac{1}{n}} & [0,1] & \xrightarrow{f} & \mathbb{R} \\ \omega & & \omega & & \omega \\ k & \longmapsto & \frac{k}{n} & \longmapsto & f\left(\frac{k}{n}\right). \end{array}$$

すると, $f(x)$ の値は, 大数の法則より, 確率 $x \in [0,1]$ で成功する Bernoulli 試行 $B(n, x)$ の期待値という確率変数 S_n/n の f による押し出しで, 近似できる.

4.6 物理学における大数の法則的現象

4.6.1 Maxwell 分布

n -粒子系の速度の分布を考えたい. 熱力学的平衡状態についていくつかの仮定をおくと, 正規分布のクラスとして, Maxwell-Boltzmann 分布を得る.

記法 4.6.1. 半径 \sqrt{n} の球面 $\sqrt{n}S^{n-1} \subset \mathbb{R}^n$ 上の一様確率測度を $\sigma_n(dx)$ とする. $k \leq n$ について, (x_1, \dots, x_k) 上の周辺分布を k 次周辺分布といい, $\sigma_n^k \in \mathcal{P}(\mathbb{R}^k)$ で表す. $\mu := \mu_{0,1} \in \mathcal{P}(\mathbb{R})$ を平均 0, 分散 1 の標準正規分布とする. $\mu^k \in \mathcal{P}(\mathbb{R}^k)$ を k 重直積とすると, 平均 $0 \in \mathbb{R}^k$, 共分散行列 $I_k \in M_k(\mathbb{R})$ を持つ \mathbb{R}^k 上の正規分布となる.

要諦 4.6.2. この条件は, n -粒子系の速度を x_i とし, 条件 $\sum_{i=1}^n x_i^2 = n$ を規格化されたエネルギー保存則とする. そして, 一様確率測度は, 等重率の原理なる作業仮説によって置かれる仮定であり, これらの条件の下で起こり得るすべての事象は等しい確率を持つとする. なお, このような仮定によって条件付けられた分布を微視的正準 Gibbs 分布 (microcanonical Gibbs distribution) という.

定理 4.6.3. $\forall k \in \mathbb{N} \sigma_n^k \Rightarrow \mu^k (n \rightarrow \infty)$.

4.6.2 熱力学的極限

記法 4.6.4. $\Lambda_L := [-L, L]^d \subset \mathbb{R}^d$ に閉じ込められた N -粒子系を考える. 単位体積あたりの粒子数 $\frac{N}{(2L)^d}$ は一定であるとして, $L, N \rightarrow \infty$ の極限を考えたい. これを熱力学的極限という. このときの \mathbb{R}^d 上の N -粒子の分布を, 強さ λ の Poisson 点過程という.

$S := \Lambda_L, p(A) := \frac{m(A)}{(2L)^d} (A \in \mathcal{B}(\mathbb{R}^d) \cap P(\Lambda_L))$ が定める確率空間 $(\Omega := S^N, P := \prod_{i=1}^N p)$ を考えると, P は正準 Gibbs 分布である.

定理 4.6.5. 部分空間 $D \subset \Lambda_L$ に対して, その範囲で発見される粒子数を表す確率変数 $n(D, -) : \Omega \rightarrow \mathbb{Z}$ を

$$n(D, \omega) := |\{k \in [N] \mid \omega_k \in D\}|$$

と定めると,

$$\forall l \in \mathbb{N} \lim_{L, N \rightarrow \infty, \frac{N}{(2L)^d} \rightarrow \lambda} P(n(D) = l) = e^{-\lambda m(D)} \frac{(\lambda m(D))^l}{l!}$$

4.7 中心極限定理

偏差値は、統計的な分布が正規分布で近似できることを暗黙裡に認めて算出している。どう考えても「極限分布の標準分解」とか呼ぶべきだと思うが、Pólya が 1920 年の論文で「確率論において中心的な役割を果たすであろう」ということから命名した。

標準化された確率変数の 2 次までの積率は確定しており、漸近的に 3 次以上のキュムラントも消えるための十分条件が i.i.d. である。

4.7.1 標準化された部分和についての結果

定理 4.7.1 (Lindeberg-Levy). 独立同分布を持つ確率変数列 $\{X_n\} \subset \mathcal{L}^1(\Omega, \mathcal{F}, P)$ は $E[X_n] = \mu \in \mathbb{R}, \text{Var}[X_n] = \sigma^2 \in \mathbb{R}_+$ を満たすとする。このとき、確率変数 $Z_n := \frac{1}{\sqrt{n}} \sum_{k=1}^n (X_k - \mu)$ は、正規分布 $N(0, \sigma^2)$ に法則収束する。特に、

$$\forall a < b \in \mathbb{R} \quad \lim_{n \rightarrow \infty} P(a \leq Z_n \leq b) = \frac{1}{\sqrt{2\pi\sigma^2}} \int_a^b e^{-\frac{x^2}{2\sigma^2}} dx.$$

4.7.2 Lindeberg-Feller の一般化

独立同分布に従う確率変数の分散が有限な場合、それらの和の確率分布は正規分布に収束する。これを種々の作業仮説を以て示すことが出来る。一方で、確率変数が従う分布の裾が重く ($|x|^{-a-1}$ ($0 < a < 2$) の冪乗)、分散が発散する場合、正規分布には収束せず、特性指数 a の安定分布に収束する。

定理 4.7.2. $(k_n)_{n \in \mathbb{N}} : \mathbb{N} \rightarrow \mathbb{N}$ に対して、 $(\xi_{n,j})_{j \in [k_n]} = \xi_{n,1}, \dots, \xi_{n,k_n} \in \mathbb{R}^d$ を各 $n \in \mathbb{N}$ が定める独立な d 次元確率変数の k_n -組とし、次の 2 条件が成り立つとする。

(A1) $\xi_{n,j} \in \mathcal{L}^2(\mathbb{R}^d)$ は 2 乗可積分で、期待値ベクトルは零とする： $E[\xi_{n,j}] = 0$ 。

(A2) $\Sigma_n := \sum_{j=1}^{k_n} \text{Var}[\xi_{n,j}] \in M_d(\mathbb{R})$ は極限 $\Sigma := \lim_{n \rightarrow \infty} \Sigma_n$ を持ち、さらに次が成り立つ： $\forall \epsilon > 0 \quad \sum_{j=1}^{k_n} E[|\xi_{n,j}|^2 1_{\{|\xi_{n,j}| \geq \epsilon\}}] \xrightarrow{n \rightarrow \infty} 0$ 。

このとき、

$$\sum_{j=1}^{k_n} \xi_{n,j} \xrightarrow{d} N_d(0, \Sigma) \quad (n \rightarrow \infty)$$

要諦 4.7.3. 通常は $(k_n)_{n \in \mathbb{N}} : \mathbb{N} \rightarrow \mathbb{N}$ を恒等写像として、 $\xi_{n,j} := \frac{X_j}{\sqrt{n}}$ として Lindeberg 条件を満たすものを構成している。

例 4.7.4. $X_j = (Y_j, Z_j)$ は独立に同一の 2 変量正規分布 $N_2(\mu, \Sigma)$ に従うとする。 $\rho := \rho(Y_j, Z_j)$ とする。標本相関係数 $\hat{\rho}_n$ の漸近分布を求めたい。中心極限定理とデルタ法 2.4.16 を組み合わせることで、 $\sqrt{n}(\hat{\rho}_n - \rho) \xrightarrow{d} N(0, (1 - \rho^2)^2)$ とわかる。

さらに良い結果を引き出すために、関数

$$g(\rho) := \frac{1}{2} \log \left(\frac{1 + \rho}{1 - \rho} \right)$$

による変換 $g(\hat{\rho}_n)$ を考える。これを **Z 変換** という。これについても一度デルタ法を用いると、 $\sqrt{n}(g(\hat{\rho}_n) - g(\rho)) \xrightarrow{d} N(0, 1)$ となり、漸近分散はパラメータ ρ に依存しなくなる。このような変換を **分散安定化変換** という。

4.7.3 ノルム収束についての中心極限定理

定理 4.7.5. (μ, σ^2) に従う 2 乗可積分な独立同分布列 $\{Y_i\} \subset L^2(\Omega, \mathcal{F}, P)$ について、特性関数がある $\nu \geq 1$ について ν 乗可積分 $\int_{\mathbb{C}} |\varphi(t)|^\nu dt < \infty$ ならば、和 $S_n := \sum_{i=1}^n Y_i$ は $N(n\mu, \sqrt{n}\sigma^2)$ にノルム収束する：

$$\sup_{B \in \mathcal{B}(\mathbb{R})} \left| P[S_n \in B] - \int_B \frac{1}{\sqrt{2\pi n\sigma^2}} \exp\left(-\frac{1}{2} \frac{(x - n\mu)^2}{n\sigma^2}\right) dx \right| \rightarrow 0.$$

4.7.4 経験分布に対する拡張

定理 4.7.6 (Glivenko-Cantelli). F_n を経験分布関数、 F を真の分布関数とする。経験分布関数は、分布関数の一致推定量である：
 $P[\lim_{n \rightarrow \infty} \sup_{x \in \mathbb{R}} |F_n(x) - F(x)| = 0] = 1.$

議論 4.7.7. F_n の推定量としての誤差分布を考えたい。各点 $x \in \mathbb{R}$ 毎に見ると、 $\sqrt{n}(F_n(x) - F(x))$ は、 \mathcal{G}^n 上に定まり、 \mathbb{R} 上に値を取る確率変数で、 $N(0, F(x)(1 - F(x)))$ に分布収束する。結合分布は多変量正規分布に収束する。では、 $\sqrt{n}(F_n - F)$ 自体はどうか？これは、標本が与えられる毎に分布関数を確定させる $\mathcal{G}^n \rightarrow l^\infty(\mathbb{R})$ なる確率変数で、 F -ブラウニアン橋と呼ばれる関数 $\mathbb{G}_F : \mathcal{G}^\infty \rightarrow l^\infty(\mathbb{R})$ が定める分布に弱収束する。Banach 空間値確率変数の共分散は定義していないが（いわば無限の成分を持つ行列 $\mathbb{R}^2 \rightarrow \mathbb{R}$ ）、各組 $(x_k, x_l) \in \mathbb{R}^2$ に対して $\text{Cov}[\mathbb{G}_F(x_k), \mathbb{G}_F(x_l)] = F(x_k \wedge x_l) - F(x_k)F(x_l)$ が成り立つ。

4.8 中心極限定理の誤差

極限分布として正規分布を持つ確率変数を、その極限分布によって近似したときの近似誤差は、 $1/\sqrt{N}$ のオーダーを持つ。これはあまりにも遅い、収束が線型よりも遅い。そのために、別の方法で目標の分布が「裾が軽い」ことを示す必要が応用上出てくる、これが集中不等式である。

定理 4.8.1 (Berry-Esseen central limit theorem). 独立同分布を持つ確率変数列 $\{X_n\} \subset \mathcal{L}^1(\Omega, \mathcal{F}, P)$ は $E[X_n] = \mu \in \mathbb{R}, \text{Var}[X_n] = \sigma^2 \in \mathbb{R}_+$ を満たすとする。 $S_N := X_1 + \dots + X_N$ について、

$$Z_N := \frac{S_N + E[S_N]}{\sqrt{\text{Var}[S_N]}} = \frac{1}{\sigma\sqrt{N}} \sum_{i=1}^N (X_i - \mu) \xrightarrow{d} N(0, 1)$$

であるが、 $\rho := \frac{E[|X_1 - \mu|^3]}{\sigma^3}$ と $g \sim N(0, 1)$ について、

$$\forall N \in \mathbb{N} \quad \forall t \in \mathbb{R} \quad |P[Z_N \geq t] - P[g \geq t]| \leq \frac{\rho}{\sqrt{N}}$$

4.9 Poisson の少数の法則

記法 4.9.1. これより、単位時間内に電話がかかってくる回数や事故が起こる回数などは、Poisson 分布によって近似するのが筋が良いことがわかる。

記法 4.9.2. 点列 $\{p_n\} \subset (0, 1)$ は $\lim_{n \rightarrow \infty} np_n = \lambda > 0$ を満たすとし、これが定める n 回の独立同試行 ($S^n := 2^n, \mathcal{F}, P$), $(\text{pr}_n)_* P(\{1\}) = p_n$ の列を考える。これは、 n が増加するにつれて、1 が出る確率は小さくなっていくが、 n 回が終わって見たときに 1 が出る回数の平均は λ で変わらないようになっている。

定理 4.9.3. $Z_n : S^n \rightarrow \mathbb{Z}$ を S^n 上の 1-ノルムとする (1 が出る回数)。このとき、 Z_n は $\text{Pois}(\lambda)$ に法則収束する： $\forall l \in \mathbb{N} \quad \lim_{n \rightarrow \infty} P(Z_n = l) = e^{-\lambda} \frac{\lambda^l}{l!}.$

4.10 大偏差原理

無限次元空間における Laplace 原理

分布を近似するにあたって、偏差が大きい部分の挙動を捉える。大数の法則から漏れた部分 a (=偏差 $|a - m|$ の大きいもの) の確率は 0 に収束し $P(X_n = a) \xrightarrow{n \rightarrow \infty} 0$, 中心極限定理により指数減衰 $P(X_n \geq a) = \int_{z \geq a} p_n^{X_n}(z) e^{-nI(z)} dz = e^{-I(a)}$ (第2項あやしい) をするのであるが, そのときの係数 $I(z)$ は, 「大数の法則が指定する集中点に一番近い事象」すなわち「起こりにくい事象の中で最も起こりやすい事象」が支配するという原理である。これは Laplace の原理の無限次元版だともなすと筋が良い。

歴史 4.10.1.

- (1) 1929 に Khinchin が Bernoulli 列について扱う。
- (2) 1938 に Cramer が $\exists t > 0 \ E[e^{t|X_1|}] < \infty$ の条件の下で一般化。
- (3) 1966 に Schilder が確率過程＝汎関数型の大偏差原理を定立。
- (4) 1970s に Donsker-Varadhan の理論が生まれる。

4.10.1 定義

記法 4.10.2. X を可分完備距離空間とし, 同時にある σ -代数 \mathcal{F} により可測空間でもあるとする。

定義 4.10.3 (large deviations technique). (X, \mathcal{F}) 上の確率測度の列 $(\mu_n)_{n \in \mathbb{N}}$ が大偏差原理をみたすとは, ある下半連続関数 $I: X \rightarrow \mathbb{R}_+$ が存在して, 任意の可測集合 $\Gamma \in \mathcal{F}$ に対して

$$-\inf_{x \in \Gamma^\circ} I(x) \leq \liminf_{n \rightarrow \infty} \frac{1}{n} \log \mu_n(\Gamma) \leq \limsup_{n \rightarrow \infty} \frac{1}{n} \log \mu_n(\Gamma) \leq -\inf_{x \in \bar{\Gamma}} I(x)$$

が成り立つことをいう。このとき, I を **rate 関数** という。

定義 4.10.4 (good rate function). I が **良いレート関数** であるとは, 任意の $l \geq 0$ に対して, 等位集合 $I^{-1}((-\infty, l]) = \{x \in X \mid I(x) \leq l\}$ がコンパクトであることをいう。

4.10.2 Laplace の原理

「大きなパラメータを持つ指数関数の積分の漸近挙動は, 被積分関数の最大値付近からの寄与だけで決まる」という経験則である。

例 4.10.5. 有界閉区間 $[a, b]$ 上の連続関数 $f, g > 0$ について,

$$\int_a^b e^{nf(x)} g(x) dx \approx e^{n \max_{x \in [a, b]} f(x)} \quad (n \rightarrow \infty)$$

が成り立つ。ただし, $F(n) \approx G(n) \Leftrightarrow \frac{\log F(n)}{\log G(n)} \xrightarrow{n \rightarrow \infty} 1$ と定めた。

注 4.10.6. この結果を非有界な区間に一般化しようとすると, 種々の技術的問題が生じる。が, 同様の結果は成り立つことが多い。そこで「原理」と呼ばれている。

例 4.10.7. (対数の比を考えることで) 定数倍を無視した弱い形の Stirling の公式 $n! = \int_0^\infty x^n e^{-x} dx \approx n^n e^{-n} \ (n \rightarrow \infty)$ を Laplace の原理から説明する。積分変換によって

$$n^n \int_0^\infty y^n e^{-ny} dy = n^n \int_0^\infty n e^{n \log y - y} dy$$

と書き直せる. すると, $\max_{y \in \mathbb{R}_+} (\log y - y) = -1$ と $\log y - y \xrightarrow{y \rightarrow 0} -\infty, \log y - y \xrightarrow{y \rightarrow \infty} -\infty$ より, 最大値 e^{-1} だけが積分に寄与することが予想される.

4.10.3 Cramer の理論

$m := E[X_1] < \infty$ に対して, $A \in \mathcal{F}$ が $d(m, A) > 0$ を満たせば, $\lim_{n \rightarrow \infty} P(Y_n \in A) = 0$ であるが, このときの収束の速さは指数的に減衰する.

定理 4.10.8. 独立同分布を持つ確率変数列 (X_i) の積率母関数の定義域 $D_M := \{t \in \mathbb{R} \mid M(t) := E[e^{tX_1}] < \infty\}$ は, 0 を内点として持つとする. このとき, $S_n := \sum_{i=1}^n X_i$ とおく.

- (1) $\forall a > E[X_1] \lim_{n \rightarrow \infty} \frac{1}{n} \log P(S_n \geq an) = -I(a)$. ただし, $I(z) := \sup_{t \in \mathbb{R}} (zt - \log M(t))$ をキュムラント母関数 $\log M$ の Legendre 変換とした.
- (2) I は \mathbb{R} 上下半連続な凸関数であり, $\lim_{z \rightarrow \pm\infty} I(z) = \infty, \forall z \in \mathbb{R} \ I(z) \geq 0 = I(E[X_1])$ を満たす.

要諦 4.10.9. $E[X_1] < a$ について $A := [a, \infty)$ とおくと,

$$\lim_{n \rightarrow \infty} \frac{1}{n} \log P\left(\frac{1}{n} S_n \in A\right) = -\inf_{z \in A} I(z)$$

と書き換えられる. すなわち, 事象 $\frac{S_n}{n} \in [a, \infty)$ が成り立つとき, $n \rightarrow \infty$ の目で見ると, 殆ど a の近くの値を取るような事象によって実現されている」ということである.

4.10.4 Schilder の理論

確率過程に関する大偏差原理

$I(\phi)$ を, 連続関数 ϕ の持つエネルギーだとすると, 「起こりにくい事象の中では最も起こりやすい事象 = エネルギーが最小になる事象が起こる」という大偏差原理は, 物理現象としても極めて自然な現象であることがわかる.

4.10.5 Varadhan の理論

大偏差原理は, Laplace の原理が有界線型汎関数の列に対しても成り立つための十分条件を与えると捉えれば, その指数関数への注目と, 位相のことはを用いた定義が自然に思える.

補題 4.10.10. (X, \mathcal{F}) 上の確率測度の列 (μ_n) が, I を良いレート関数として大偏差原理を満たすとする. このとき, X 上の有界連続関数 $f \in C_b(X)$ について,

$$\int e^{nf(x)} \mu_n(dx) \approx \exp\left(n \sup_{x \in X} |f(x) - I(x)|\right) \quad (n \rightarrow \infty)$$

第 5 章

漸近理論

Kolmogorov[13]

5.1 歴史

物理学者も解析学者も参入した対象であり、中心極限定理とはやはり夢のテーマであった。ロシアが強いことに疑問もない。正規分布には、算術平均が最尤推定量になるということと、微小分布へ無限分解可能な分布としての 2 つの普遍性がある。

歴史 5.1.1 (Stirling の公式と de Moivre-Laplace の定理). Fermat と Pascal の往復書簡 (1654) ののちに、Huygens が *De Ratiociniis in Ludo Aleae* (1657) を書き、これを James Bernoulli が、まとめて *Ars Conjectandi* (1713) が死後に出版された。この時点で第四部では推論に応用することを考えたのである。復元抽出の標本数 n をどこまで大きくすれば、確率 p を一定の誤差以下で評価できるかを考えた。これは多項分布の問題であるから、二項分布や Bernoulli 数の技法が第二部でまとめられている。この問題を乗り越えたのが De Moivre (1733) で、多項分布の確率が正規曲線 e^{-x^2} の積分で近似できることを発見した。この自分の論文を英訳し、*The Doctrine of Chances*, 2nd Ed. (1738) に収録して、友人に配った。さらに $n!$ の近似の問題を解いて精緻化したのが Stirling である (De Moivre の友人)。この点で本質的に解析学化したのが de Moivre であったが、本格的に微積分学の言葉で書き直したのが Laplace であった。こうして、de Moivre-Laplace の定理が示された。解析学とは極限の技法で、極限とは近似の基礎である。二項分布とは、二点分布に従う独立同分布列の和の分布でもあることに注意すれば、これは中心極限定理の系である。

歴史 5.1.2 (誤差分布と天文学). Simpson (1775) の London 王立学会に当てた手紙に、天文学者は算術平均を推定量として使うが、注意深く測定した 1 回の方が信頼できるという意見の知識人も多いという現状を書いている。そこで Simpson, Lagrange らは誤差分布として考え得る分布たち (裾が軽く、対称な分布) の算術平均の分布が調べられた。

回帰分析だが、方程式の形をパラメトリックに仮定し、観測値を集めると、解析的には解無しになるが、実際は仮定も正しくなく、観測誤差もあるので、損失関数を最小にする係数を推定量とすることになる (決定問題)。Gauss が最終的にこれを解決し、標本平均が位置母数の最尤推定量になるのは誤差法則が正規分布の場合に限ることを解析的に示し、このとき最小二乗法が必然的に最良になることを示した。算術平均を信じるなら、誤差分布は正規性を仮定することになるのだ。

歴史 5.1.3 (誤差とは何か). Young は誤差という概念の安定性に疑問を持ち、「誤差とは、根元誤差の独立和に分解できるのはいか」「そして独立和は、元々の誤差分布に依らずに特定の分布に従うのでは？」と、裏の数理構造に目を向けた。これは数学的には新規性はないが、無限可分分布という概念に目を向けさせる。こうして Gauss とは独立に、もう一度誤差分布に正規分布を用いる妥当性が導かれる。つまり、3 次以上の積率が無視できるほど小さいような根元誤差の話の分布は、正規分布に従うことになる。「微小分布の和」としての普遍性があるわけだ。

歴史 5.1.4. Chebyshev, Markov の順に十分条件が厳密に見つかっていき、Lyapunov が特性関数の方法で数学的に正しいものをひとまず 1 つ確定させた。Lindeberg, Levy, Feller, Kolmogorov が引き継ぎ、現代論になる。

第 6 章

高次元確率論

ここではこれ以上具体論に深入りせず、高次元確率論と確率過程論を深掘りする。これらはいずれも $\Omega \rightarrow \text{Meas}(\mathbb{R}_+, \mathbb{R})$ とみると、Banach 空間値確率変数として統一的に見れる。また、平均や分散などの母数も Banach 空間の点となる。実際、確率分布族を Banach 空間で添字付ける見方は有効な手法である。

6.1 独立確率変数列の集中不等式

集中不等式は、確率分布の偏差 $|X - \mu|$ を捉える。極限分布が Gauss であるとき、これを用いて近似することがまず考えられるが、近似誤差が大きい 4.8.1。そこで、極限定理に依らずに、「裾が軽い」ことを示す方法論が必要となる。その一つが集中不等式である。（極限定理では特性関数が活躍したが、）ここでは、積率母関数に注目することとなる。

6.1.1 Chebyshev の不等式

最も即時的で古典的な上界を与え、多くの場合線型に過ぎない。

定理 6.1.1. $X \sim (\mu, \sigma^2)$ を実確率変数とする。

- (1) (Markov) $X \geq 0$ ならば、 $\forall t > 0 \ P[X \geq t] \leq \frac{E[X]}{t}$.
- (2) (Chebyshev) $\forall t > 0 \ P[|X - \mu| \geq t] \leq \frac{\sigma^2}{t^2}$.

6.1.2 Hoeffding の不等式

Rademacher 確率変数の線型和の尾部について、Gauss 分布と全く同様な収束レート $e^{-t^2/2}$ による評価を与えるのが Hoeffding の不等式である。これは理想的な形で、中心極限定理の代替となっている。証明はモーメント母関数により、これは一般の有界な確率変数に一般化出来るが、鋭さは落ちる。

定理 6.1.2. X_1, \dots, X_N を独立な Rademacher 確率変数とし、 $a = (a_1, \dots, a_N) \in \mathbb{R}^N$ とする。このとき、

$$\forall t \in \mathbb{R}_+ \quad P \left[\sum_{i=1}^N a_i X_i \geq t \right] \leq \exp \left(-\frac{t^2}{2\|a\|_2^2} \right).$$

系 6.1.3.

$$P \left[\left| \sum_{i=1}^N a_i X_i \right| \geq t \right] \leq 2 \exp \left(-\frac{t^2}{2\|a\|_2^2} \right).$$

定理 6.1.4 (Hoeffding's inequality for general bounded random variable). X_1, \dots, X_N を独立な有界確率変数とする：

$\forall i \in [N] \exists m_i, M_i \in \mathbb{R} \text{ Im } X_i \subset [m_i, M_i]$. このとき,

$$\forall t > 0 \quad P \left[\sum_{i=1}^N (X_i - E[X_i]) \geq t \right] \leq \exp \left(- \frac{2t^2}{\sum_{i=1}^N (M_i - m_i)^2} \right)$$

応用例 6.1.5 (平均の頑健推定). 独立な観測 $X_1, \dots, X_N \sim (\mu, \sigma^2)$ から平均 μ を, 誤差 ϵ 以内で推定したい.

- (1) $N = O(\sigma^2/\epsilon^2)$ 個の標本が存在すれば, 確率 $3/4$ 以上で $(\mu - \epsilon, \mu + \epsilon)$ に入る推定量が構成できる.
- (2) 任意の $\delta \in (0, 1)$ について, $N = O(\log(\delta^{-1})\sigma^2/\epsilon^2)$ 個の標本が存在すれば, 確率 $1 - \delta$ 以上で $(\mu - \epsilon, \mu + \epsilon)$ に入る推定量が構成できる.

6.1.3 Chernoff の不等式

Bernoulli 変数について, 母数 p_i が小さすぎるとき (Poisson の少数の法則的な現象のとき), Hoeffding の不等式は見当違いの結果を与える.

定理 6.1.6. $X_i \sim B(p_i)$ を Bernoulli 確率変数とする. 和 $S_N := \sum_{i=1}^N X_i$ の平均を $\mu := E[S_N]$ で表すと,

$$\forall t > \mu \quad P[S_N \geq t] \leq e^{-\mu} \left(\frac{e\mu}{t} \right)^t.$$

要諦 6.1.7. これは Poisson 分布的な結果である. 実際 $X \sim \text{Pois}(\lambda)$ ならば,

$$\forall t > \lambda \quad P[X \geq t] \leq e^{-\lambda} \left(\frac{e\lambda}{t} \right)^t.$$

これを, 各第 i 回での成功確率 p_i がバラバラな場合でも行っている.

注 6.1.8 (Poisson 尾部の観察). $k!$ を Stirling の公式で近似すると

$$P[X = k] \sim \frac{1}{\sqrt{2\pi k}} e^{-\lambda} \left(\frac{e\lambda}{k} \right)^k$$

を得るから, Poisson 分布の尾部と言っても, 一番小さい部分が殆どすべてを占めてしまう. 大偏差原理的な現象である.

定理 6.1.9 (小偏差の場合). $X_i \sim B(p_i)$ を Bernoulli 確率変数とする. 和 $S_N := \sum_{i=1}^N X_i$ の平均を $\mu := E[S_N]$ で表すと,

$$\exists c > 0 \quad \forall \delta \in (0, 1] \quad P[|S_N - \mu| \geq \delta\mu] \leq 2e^{-c\mu\delta^2}$$

要諦 6.1.10. これは Poisson 分布の

$$\forall t \in (0, \lambda] \quad P[|X - \lambda| \geq t] \leq 2 \exp \left(- \frac{ct^2}{\lambda} \right)$$

に対応する. $\text{Pois}(\lambda)$ は平均 λ 近くでは $N(\lambda, \lambda)$ にすごく似ているが, 大偏差部分では裾は重い: $(\lambda/t)^t$.

6.1.4 確率グラフ

ネットワークの確率モデルとなる. p が十分大きく, 平均して $O(\log n)$ の次数を持つとき, どの頂点の次数も $[0.9d, 1.1d]$ の間にあって, 他と結ばれ過ぎていたり, 孤立していたりすることは殆どない.

定義 6.1.11. Erdos-Renyi model $G(n, p)$ ($n \in \mathbb{N}, p \in [0, 1]$) とは, n 個の頂点と, その任意の 2 頂点の間を確率 p で辺が存在するグラフである.

補題 6.1.12. 任意の頂点の次数の期待値は $d := (n-1)p$ となる.

定理 6.1.13 (dense graphs are almost regular). ある $C > 0$ が存在して, 任意の $d \geq C \log n$ を満たすランダムグラフ $G \sim G(n, p)$ は, 十分大きな確率 (0.9 以上) で, 任意の頂点の次数が $[0.9d, 1.1d]$ の間に入る.

6.1.5 劣 Gauss 分布

Bernoulli 確率変数 X_i について集中不等式を示したが、どこまで一般の確率変数に適用できるのか？

命題 6.1.14. 確率変数 X について、次の 4 条件は同値で、 $E[X] = 0$ ならば (5) も同値。また、ある定数 $C > 0$ が存在して、パラメータ $K_i > 0$ はそれぞれ互いの C 倍を超えない。

- (1) X の尾部は $\forall t \in \mathbb{R}_+ \quad P[|X| \geq t] \leq 2 \exp\left(-\frac{t^2}{K_1^2}\right)$ を満たす。
- (2) X のモーメントは $\forall p \geq 1 \quad \|X\|_{L^p} \leq K_2 \sqrt{p}$ を満たす。
- (3) X^2 の積率母関数は $\forall |\lambda| \leq 1/K_3 \quad E[e^{\lambda^2 X^2}] \leq \exp(K_3^2 \lambda^2)$ を満たす。
- (4) X^2 の積率母関数は $E[e^{X^2/K_4^2}] \leq 2$ 。
- (5) X の積率母関数は $\forall \lambda \in \mathbb{R} \quad E[e^{\lambda X}] \leq e^{K_5^2 \lambda^2}$ 。

定義 6.1.15 (sub-gaussian norm). 命題の条件を満たす確率変数 X を劣 Gauss であるといい、劣 Gauss ノルムを (4) を満たす最小の定数 K_4 、すなわち

$$\|X\|_{\psi_2} = \inf \left\{ t > 0 \mid E[e^{X^2/t^2}] \leq 2 \right\}$$

で定める。

例 6.1.16.

- (1) $X \sim N(0, \sigma^2)$ ならば、 $\|X\|_{\psi_2} \leq C\sigma$ 。
- (2) X が Rademacher ならば、 $\|X\|_{\psi_2} \leq \frac{1}{\sqrt{\log 2}} =: C$ 。
- (3) X が有界ならば、 $\|X\|_{\psi_2} \leq C\|X\|_{\infty}$ 。

一方で、Poisson 分布、指数分布、Pareto 分布、もちろん Cauchy 分布は裾が重く、劣 Gauss ではない。

6.1.6 Orlicz 空間

劣 Gauss 分布をさらに一般化すると、Orlicz 空間にいきつく。

6.1.7 一般化 Hoeffding 不等式

劣 Gauss ノルムの言葉を用いて、Hoeffding 不等式は一般の劣 Gauss 確率変数に一般化出来る。

6.1.8 劣指数分布

補題 6.1.17. X を確率変数とする。次の 2 条件は同値：

- (1) X は劣 Gauss である。
- (2) X^2 は劣指数である。

このとき、 $\|X^2\|_{\psi_1} = \|X\|_{\psi_2}^2$ 。

6.1.9 Bernstein の不等式

劣指数分布

定理 6.1.18. X_1, \dots, X_N を平均 0 の劣指数確率変数とする. このとき,

$$\exists c > 0 \quad \forall t \in \mathbb{R}_+ \quad P \left[\left| \sum_{i=1}^N X_i \right| \geq t \right] \leq 2 \exp \left(-c \min \left(\frac{t^2}{\sum_{i=1}^N \|X_i\|_{\psi_1}^2}, \frac{t}{\max_{i \in [N]} \|X_i\|_{\psi_1}} \right) \right).$$

第 7 章

分布の扱い

7.1 期待値作用素

一般の集合上の関数の期待値作用素の定義には, Lebesgue 積分を用いる. 経験分布論では, さらに拡張された線型作用素を用いることも考える.

7.1.1 積分の定義

命題 7.1.1. X を確率変数とする. $0 < p < q$ について, $|X|^q$ が可積分ならば, $|X|^p$ も可積分である.

[証明]. $\forall x \in \mathbb{R} \quad |x|^p \leq 1 + |x|^q$ である. これと, Lebesgue の優収束定理より. ■

命題 7.1.2 (Markov の不等式). 非負可測関数 X と任意の $p > 0, q \geq 0, \epsilon > 0$ について,

$$\int X^q 1_{\{X \geq \epsilon\}} d\mu \leq \epsilon^{-p} \int 1_{\{X \geq \epsilon\}} X^{p+q} d\mu \leq \epsilon^{-p} \int X^{p+q} d\mu.$$

[証明]. $\epsilon^p 1_{\{X \geq \epsilon\}} X^q \leq 1_{\{X \geq \epsilon\}} X^{p+q} \leq X^{p+q}$ と, 積分の単調性より. ■

7.1.2 期待値の定義

定義 7.1.3 (expectation / expected value / mean (value)). 確率変数 $X : \Omega \rightarrow \mathbb{R}$ が確率測度 P について可積分のとき, $E[X] := \int_{\Omega} X(\omega) P(d\omega)$ を X の期待値または平均 (値) という. $E_P[X]$ とも表す.

定義 7.1.4 (r -th moment, r -th central moment, r -th absolute moment). 確率変数 $X : \Omega \rightarrow \mathbb{R}$ について,

- (1) $\alpha_r := \mu'_r = E[X^r]$ を X の r 次の積率と呼ぶ.
- (2) $\mu_r := E[(X - E[X])^r]$ を X の r 次の中心積率と呼ぶ.
- (3) $\beta_r := E[|X|^r]$ を X の r 次の絶対積率と呼ぶ.
- (4) μ_2 を X の分散とよび, $\text{Var}[X]$ で表す.
- (5) $\sqrt{\text{Var}[X]}$ を標準偏差と呼ぶ.

命題 7.1.5 (分散の性質). 2 乗可積分な実確率変数 $X : \Omega \rightarrow \mathbb{R}$ について,

- (1) (分散公式) $\text{Var}[X] = E[(X - E[X])^2] = E[X^2] - (E[X])^2$.
- (2) (2 次斉次性) $\forall a, b \in \mathbb{R} \quad \text{Var}[aX + b] = a^2 \text{Var}[X]$.

7.1.3 期待値不等式

記法 7.1.6. 積分論の記号を、期待値に関しても流用する.

- (1) $p \in (0, \infty)$ について, $\|X\|_p = (E[|X|^p])^{1/p}$ と定める.
- (2) $\|X\|_\infty := \text{ess.sup}|X|$ とする.

定理 7.1.7 (測度論における結果). X, Y を確率変数とする.

- (1) (Hölder) $\forall p, q \in (1, \infty) \quad \frac{1}{p} + \frac{1}{q} = 1 \Rightarrow \|XY\|_1 \leq \|X\|_p \|Y\|_q$. 特に, $p = q = 2$ のとき Schwarz の不等式.
- (2) (Minkowski) $\forall p \in [1, \infty] \quad \|X + Y\|_p \leq \|X\|_p + \|Y\|_p$.
- (3) $\forall p, q \in (0, \infty] \quad p < q \Rightarrow \|X\|_p \leq \|X\|_q$.
- (4) (Markov) 任意の非減少可測関数 $\varphi: \mathbb{R}_+ \rightarrow \mathbb{R}_+$ について, $\varphi(A) > 0 \Rightarrow E[|X|1_{\{|Y| \geq A\}}] \leq \frac{E[|X|\varphi(|Y|)1_{\{|Y| \geq A\}}]}{\varphi(A)} \leq \frac{E[|X|\varphi(|Y|)]}{\varphi(A)}$.
特に, $P[|X - E[X]| \geq A] \leq \frac{\text{Var}[X]}{A^2}$ (Chebyshev).
- (5) (Jensen) 任意の开区間上の凸関数 $\psi: I \rightarrow \mathbb{R}$ について, $X, \psi(X)$ が可積分かつ $P[X \in I] = 1 \Rightarrow \psi(E[X]) \leq E[\psi(X)]$.

7.2 分布の特性値

測度論による確率の特徴量の理解

$(\mathbb{R}, \mathcal{G}_1)$ 上の分布について改めて特性値を定義すると, これは「確率変数の特性値」の一般化となっている. 確率変数の期待値は, それが誘導する分布の平均のことである.
積分は可測関数と測度についての2変数関数とするならば, これは後者を引数とするとより一般的になるという不思議な状況を物語ってはいないか? これが期待値作用素の限界ということか?

7.2.1 確率密度関数

定義 7.2.1 (probability density function). \mathbb{R} 上の分布 ν が Lebesgue 測度 dx に関して絶対連続であるとき^{†1}, その Radon-Nikodym 微分 f を **確率密度関数** とよび, ν を **(絶対) 連続分布** という.

注 7.2.2. 確率密度関数は Lebesgue 零集合の差を除いて一意に定まる.

補題 7.2.3. 任意の可測関数 $g: \mathbb{R} \rightarrow \mathbb{R}$ と絶対連続分布 ν について,

$$E[g(X)] = \int_{\mathbb{R}} g(x) \nu(dx) = \int_{\mathbb{R}} g(x) f(x) dx.$$

すなわち, 左辺または右辺が存在すればもう一方も存在し, 値が一致する.

7.2.2 平均値と積率

定義 7.2.4 (expectation). $(\mathbb{R}, \mathcal{G}_1)$ 上の確率測度 ν について, $\mu := \int_{\mathbb{R}} x \nu(dx)$ を, ν の **期待値** または **平均 (値)** という.

定義 7.2.5. $(\mathbb{R}, \mathcal{G}_1)$ 上の確率測度 ν について,

- (1) $\alpha_r := \mu'_r = \int_{\mathbb{R}} x^r \nu(dx)$ を ν の r 次の **積率** と呼ぶ.
- (2) $\mu_r := \int_{\mathbb{R}} (x - \mu)^r \nu(dx)$ を ν の r 次の **中心積率** と呼ぶ.

^{†1} Lebesgue 零集合上の確率が零であることが定義.

- (3) $\beta_r := \int_{\mathbb{R}} |x|^r \nu(dx)$ を ν の r 次の絶対積率と呼ぶ.
 (4) μ_2 を ν の分散と呼ぶ.
 (5) $\sqrt{\mu_2}$ を標準偏差と呼ぶ.

命題 7.2.6 (変数変換公式:well-definedness). $(\mathcal{G}, \mathcal{A})$ を可測空間とし, X を \mathcal{G} -値確率変数とする. このとき,

$$\forall g \in \text{Meas}(\mathcal{G}, \mathbb{R}) \quad \int_{\Omega} g(X(\omega)) P(d\omega) = \int_{\mathcal{G}} g(x) P^X(dx).$$

すなわち, 左辺または右辺のいずれかの積分が存在すればもう一方も存在し, 値が等しくなる.

系 7.2.7 (積率の well-definedness). $g(x) = x^r$ とすれば,

$$E[X^r] = \int_{\Omega} X(\omega)^r P(d\omega) = \int_{\mathbb{R}} x^r P^X(dx).$$

すなわち, $\alpha_r(X) = \alpha_r(P^X)$.

定義 7.2.8 (skewness, kurtosis). 位置母数でも尺度母数でもないものとして, 分布の形状を表すと考えられる次の母数がある.

- (1) $\mathfrak{s} = \gamma_1 := \frac{\mu_3}{\mu_2^{3/2}}$ を歪度と呼ぶ.
 (2) $\mathfrak{k} = \gamma_2 := \frac{\mu_4}{\mu_2^2}$ を尖度と呼ぶ.

7.2.3 共分散と相関

定義 7.2.9 (covariance, correlation coefficient).

- (1) X, Y, XY が P -可積分のとき,

$$\text{Cov}[X, Y] = E[(X - E[X])(Y - E[Y])]$$

を X, Y の共分散という.

- (2) $X, Y \in L^2$ で $\text{Var}[X]\text{Var}[Y] \neq 0$ のとき, $\rho(X, Y) = \frac{\text{Cov}[X, Y]}{\sqrt{\text{Var}[X]}\sqrt{\text{Var}[Y]}}$ を相関係数という.
 (3) $X = (X_i)_{i \in [r]}, Y = (Y_j)_{j \in [c]}$ が r, c 次元の 2 乗可積分確率変数とするととき, 共分散行列は

$$\text{Cov}[X, Y] = E[(X - E[X])(Y - E[Y])^\top] = (E[(X_i - E[X_i])(Y_j - E[Y_j])])_{(i,j) \in [r] \times [c]} = (\text{Cov}[X_i, Y_j])_{ij}$$

で定まる $r \times c$ 行列をいう. $\text{Cov}[X, Y] = \text{Cov}[Y, X]^\top$ が成り立つ.

- (4) $\text{Var}[X] := \text{Cov}[X, X]$ で定まる $r \times r$ 行列を, 分散共分散行列という.
 (5) $\text{Corr}[X] = (\rho(X_i, X_j))_{i,j \in [n]}$ で定まる $r \times r$ 行列を相関行列という. これは, 対角要素が 1 に基準化された無次元量だと考えられる.

要諦 7.2.10. $X, Y \in L^2$ は十分条件である.

命題 7.2.11. $X, Y, Z \in L^2$ について,

- (1) $\text{Cov}[X, Y] = \text{Cov}[Y, X]$.
 (2) $\text{Cov}[aX + bY, Z] = a\text{Cov}[X, Z] + b\text{Cov}[Y, Z]$.
 (3) $\text{Cov}[X, 1] = 0$. 特に, $\text{Cov}[aX + b, Y] = a\text{Cov}[X, Y]$.
 (4) (共分散公式) $\text{Cov}[X, Y] = E[XY] - E[X]E[Y]$.
 (5) $\text{Cov}[X, X] = \text{Var}[X] \geq 0$. 等号成立条件は $X = E[X]$ a.s.
 (6) (Schwarz の不等式) $|\text{Cov}[X, Y]| \leq \sqrt{\text{Var}[X]}\sqrt{\text{Var}[Y]}$.

命題 7.2.12 (Pearson の不等式). $X \in L^1$ について, $\text{Var}[X] > 0$ とする. このとき, $\mathfrak{s}^2(X) + 1 \leq \mathfrak{k}(X)$. 特に $\mathfrak{s}(X) = 0$ ならば, $\mathfrak{k}(X) \geq 1$.

命題 7.2.13 (共分散行列の双線型性).

(1) 可積分確率変数 $X_1, \dots, X_m, Y_1, \dots, Y_n$ の積 $X_i Y_j$ も可積分とする. このとき,

$$\forall_{a_1, \dots, a_m, b_1, \dots, b_n \in \mathbb{R}} \quad \text{Cov} \left(\sum_{i=1}^m a_i X_i, \sum_{j=1}^n b_j Y_j \right) = \sum_{i=1}^m \sum_{j=1}^n a_i b_j \text{Cov}(X_i, Y_j)$$

(2) 各 X_i ($i \in [m]$) を r_i 次元確率変数, 各 Y_j ($j \in [n]$) を c_j 次元確率変数とする. すべての $X_i, Y_j, X_i Y_j \in L^1$ のとき, 任意の $r \times r_i$ 定数行列 A_i と $c \times c_j$ 定数行列 B_j について

$$\text{Cov} \left(\sum_{i=1}^m A_i X_i, \sum_{j=1}^n B_j Y_j \right) = \sum_{i=1}^m \sum_{j=1}^n A_i \text{Cov}(X_i, Y_j) B_j^\top$$

注 7.2.14. 行列 M に関して, $|M| = (\text{Tr}(MM^\top))^{1/2}$ とすると, $|X_i \otimes Y_j| = |X_i| |Y_j|$ だから, $|X_i| |Y_j|$ が可積分であることと, $|X_i \otimes Y_j|$ が可積分であることと, X_i, Y_j の要素のペアの積がすべて可積分であることは同値になる.

命題 7.2.15 (和の分散). $X_1, \dots, X_n \in L^2$ について,

$$\text{Var} \left(\sum_{i=1}^n X_i \right) = \sum_{i=1}^n \text{Var}(X_i) + 2 \sum_{(i,j): 1 \leq i < j \leq n} \text{Cov}(X_i, Y_j).$$

命題 7.2.16 (相関係数の値域). $\mu_X = E[X], \mu_Y = E[Y], \sigma_X = \sqrt{\text{Var}[X]}, \sigma_Y = \sqrt{\text{Var}[Y]}$ とする.

$$|\rho(X, Y)| \leq 1$$

等号成立条件は, $Y = \pm \frac{\sigma_Y}{\sigma_X} (X - \mu_X) + \mu_Y$ a.s..

【証明】 . $\sigma_X \sigma_Y \neq 0$ のとき,

$$0 \leq E[(\sigma_X^{-1}(X - \mu_X) \pm \sigma_Y^{-1}(Y - \mu_Y))^2] = 2(1 \pm \rho(X, Y))$$

より. ■

命題 7.2.17 (ランダムな双線型形式の期待値). m 次元確率変数 X と n 次元確率変数 Y とについて, $[|X|, |Y|, |X||Y|]$ を可積分とする. このとき, $m \times n$ -定数行列 A について,

$$E(X^T A Y) = \text{Tr}(\text{Cov}(X, Y)^\top A) + E(X)^\top A E(Y)$$

7.2.4 分散共分散行列

分散共分散行列と半正定値行列は同一視出来る.^a

^a <https://ja.wikipedia.org/wiki/分散共分散行列>

補題 7.2.18. 分散共分散行列 $\text{Var}[X]$ は半正定値である.

【証明】 . $\forall_{u \in \mathbb{R}^d} \quad u^\top \text{Var}[X] u = E[(u \cdot (X - E[X]))^2]$ より. ■

注 7.2.19 (退化した多次元確率変数). $\text{Var}[X]$ が正定値でないとすると, $\exists_{u \in \mathbb{R}^d \setminus \{0\}} u^\top \text{Var}[X] u = E[(u^\top (X - E(X)))^2] = 0$ である. すなわち, X は確率1で超平面 $u^\top (X - E(X)) = 0$ 上に値を取る.

7.3 分布関数

分布関数には3つの同値な定義がある. これらが同値である理由は, Riemann-Stieltjes 積分による. 任意の単調増加関数 F に対して, 有界関数 f の積分が定まるが, 次の3条件を満たすことと, F が絶対連続な確率分布を定めることが同値になる.

7.3.1 定義と特徴付け

定義 7.3.1 (distribution function).

- (1) 次の3条件を満たす有界関数 $F: \mathbb{R} \rightarrow [0, 1]$ を**分布関数**という.
 - (i) 有界性: $\lim_{x \rightarrow -\infty} F(x) = 0, \lim_{x \rightarrow \infty} F(x) = 1$.
 - (ii) 右連続性.
 - (iii) 広義単調増加性.
- (2) 実確率変数 X に対して, $F^X(x) := P[X \leq x]$ により定まる関数 $F^X: \mathbb{R} \rightarrow [0, 1]$ は分布関数になる. これを X の**(累積) 分布関数**という.
- (3) $(\mathbb{R}, \mathcal{G}_1)$ 上の確率測度 ν に対して, $F_\nu(x) := \nu((-\infty, x]) = \int_{-\infty}^x f(y)dy$ により定まる関数 $F^X: \mathbb{R} \rightarrow [0, 1]$ は分布関数になる. これを ν の**(累積) 分布関数**という.

補題 7.3.2. $F: \mathbb{R} \rightarrow \mathbb{R}$ を有界関数とする. このとき, 次は同値:

- (1) F は分布関数である.
- (2) ある確率測度 $\nu \in P(\mathbb{R})$ が存在して, この累積分布関数である: $F = F_\nu$.

[証明].

- (1) \Rightarrow (2) 任意の Borel 集合 $(-\infty, x] \in \mathcal{G}_1$ について, $\nu((-\infty, x]) := F(x)$ とすると, $(-\infty, x]$ は任意の \mathbb{R} の開・閉区間を生成するので, \mathcal{G}_1 を生成することから, ν は \mathcal{G}_1 上の測度に延長する. さらに, $\nu(\mathbb{R}) = F(\infty) = 1$ だから, ν は確率測度である.
- (2) \Rightarrow (1) $F(x) = \nu((-\infty, x])$ であるから,
 - (i) 明らか.
 - (ii) 確率測度の連続性より.
 - (iii) 確率測度の正性より.

■

7.3.2 分布関数の構成

$D(\mathbb{R}; [0, 1])$ の中で, F は凸集合をなし, さらにある意味で稠密である.

命題 7.3.3. $\sum_{j \in \mathbb{N}} p_j = 1$ を満たす任意の非負実数列 (p_j) と分布関数の列 (F_j) について,

$$F(x) := \sum_{j \in \mathbb{N}} p_j F_j(x)$$

は分布関数である.

注 7.3.4. どうやら一様収束はしない.

7.3.3 分布の微分としての性質

一般に, 定数でない連続関数 $F: [a, b] \rightarrow \mathbb{R}$ が, 殆ど至る所で微分係数を持ち, かつそれが消えているとき, **特異**であるという. 特異な連続分布関数を持つような分布のみ, 確率密度関数や確率質量関数に当たるものを持たない.

定義 7.3.5 (singular continuous distribution). F を分布関数とし, $f(x) := F(x) - \lim_{y \nearrow x} F(y) \geq 0$ とする.

- (1) $f(x) \neq 0$ であるとき, $x \in \mathbb{R}$ を F の**不連続点**といい, $f(x)$ を**飛躍量**という.

(2) $\forall \epsilon > 0 \ F(x + \epsilon) > F(x - \epsilon)$ が成り立つとき、点 x は F の**増加点**であるという。不連続点ならば増加点である。

(3) 連続な分布関数 F の増加点全体の集合が Lebesgue 零集合であるとき、 F を**連続な特異**であるという。

定理 7.3.6 (Lebesgue 分解). 任意の分布関数 F は、絶対連続分布 F_a と離散分布 F_d と連続特異分布 F_s の凸結合として一意的に表せる。

7.3.4 一意性定理

命題 7.3.7 (一意性定理). $\nu_1 = \nu_2$ と $F_{\nu_1} = F_{\nu_2}$ は同値。

7.3.5 弱収束の特徴付け

そもそも分布関数は、連続点上での値が定まれば、大域的にも定まる。この点に注意すれば、弱収束は、分布関数の各点収束で特徴付けられる。

命題 7.3.8 (Prokhorov の定理の一部). \mathbb{R} 上の分布 $(\nu_n), \nu$ の分布関数を F_n, F とする。次の2条件は同値。

- (1) $\nu_n \xrightarrow{w} \nu$.
- (2) F の任意の連続点 $x \in \mathbb{R}$ について、 $F_n(x) \rightarrow F(x)$.

要諦 7.3.9. F も分布関数である（右連続である）という仮定を取るとどうなるか。分布関数列の各点収束極限 F は右連続とは限らないが、連続点上での値を変えない右連続化 F_0 は常に存在する。しかし最も肝心なのは、 $F(\pm\infty)$ の値が変わってしまう。

7.3.6 分布関数の弱収束

[11].

7.4 確率母関数

$\mathbb{Z}_+ := \mathbb{N}$ 上の離散分布を扱う際には、確率母関数もよく用いられ、ここから積率母関数も特性関数も求まる。 $\varphi(u) = g(e^{iu})$ なので、特性関数の微分と確率母関数の微分は本質的に等価で、便利な方を使えば良い。

7.4.1 特性関数と確率母関数

定義 7.4.1 (characteristic function, probability generating function).

- (1) 実数上の確率変数 $\varphi(u) := \sum_{x \in \mathcal{G}} e^{iux} p_x : \mathbb{R} \rightarrow \mathbb{C}$ を、確率関数 $\mu = (p_x)_{x \in \mathcal{G}}$ の**特性関数**または **Fourier 変換**という。
 $|e^{iux}| = 1$ より、これは必ず収束する。^{†2}
- (2) 特に $\mathcal{G} = \mathbb{N} \subset \mathbb{R}$ のとき、実数上の確率変数 $g(z) := \sum_{x \in \mathbb{N}} p_x z^x$ を**確率母関数**という。特性関数は、これに $z = e^{iu}$ と変数変換を合成した場合である： $\varphi(u) = g(e^{iu})$ 。^{†3}

補題 7.4.2 (fractional moment : 分散公式・積率は特性関数の微分・平均と分散は確率母関数の微分)。

^{†2} 理論解析の極みのような存在である。well-defined であり、一般性を持ち、また性質が理想的である。また、確率変数が確率密度関数を持つ場合、特性関数と密度関数は互いにもう一方のフーリエ変換になっているという意味で双対である。

^{†3} これは特性関数の自然数への特価である。e なぞ持ち出さなくても良い場合、 $\varphi(u) = g(e^{iu})$ という関係がある。

- (1) (分散公式) $\sigma^2 = \alpha_2 - \mu^2 = \sum_{x \in \mathcal{X}} x^2 p_x - \left(\sum_{x \in \mathcal{X}} x p_x \right)^2$.
- (2) $\beta_r < \infty$ のとき, $\alpha_r = i^{-r} \varphi^{(r)}(0)$.
- (3) g が $z = 1$ で項別微分可能であるとき, 階乗モーメントが $g^{(r)}(1) = \sum_{x=r}^{\infty} x(x-1)\cdots(x-r+1)p_x$ である.
- (4) 特に, 平均と分散について $\alpha_1 = g'(1), \mu_2 = g''(1) + g'(1) - (g'(1))^2$ が成り立つ.

[証明] .

(1)

$$\begin{aligned} \sigma^2 &= \sum_{x \in \mathcal{X}} (x - \mu)^2 p_x \\ &= \sum_{x \in \mathcal{X}} x^2 p_x - 2\mu \underbrace{\sum_{x \in \mathcal{X}} x p_x}_{=\mu} + \mu^2 \underbrace{\sum_{x \in \mathcal{X}} p_x}_{=1} \\ &= \alpha_2 - \mu^2. \end{aligned}$$

- (2) $\beta_r < \infty$ ならば, $\varphi^{(r)}(u) = \sum_{x \in \mathcal{X}} (ix)^r e^{iux} p_x$ は収束し (すなわち項別微分可能で), 関数 $\varphi^{(r)} : \mathbb{R} \rightarrow \mathbb{R}$ を定める. $u = 0$ とし, $\varphi^{(r)}(0) = i^r \sum_{x \in \mathcal{X}} x^r p_x = i^r \alpha_r$.

- (3) 一般に, 項別微分可能ならば $g^{(r)}(z) = \sum_{x=0}^{\infty} x(x-1)\cdots(x-r+1)p_x z^{x-r}$ であるが, いま $\mathcal{X} = \mathbb{Z}$ としているから, $z = 1$ のとき, $g^{(r)}(1) = \sum_{x=r}^{\infty} x(x-1)\cdots(x-r+1)p_x$ である. また, 特に $g'(1) = \mu$, $g''(1) = \sum_{x \in \mathcal{X}} x(x-1)p_x$ であるから, (1) より, $\sigma^2 = \underbrace{g''(1) + g'(1)}_{=\sum (x(x-1)+x)p_x} - (g'(1))^2$

■

7.4.2 分位点関数

定義 7.4.3 (quantile function).

- (1) 累積分布関数 F が連続かつ狭義単調増加であるとき, 逆関数 F^{-1} を**分位点関数**と定める.
- (2) 一般の場合, $F_L^{-1}(u) := \inf \{x \in \mathbb{R} \mid F(x) \geq u\}$, $F_R^{-1}(u) := \sup \{x \in \mathbb{R} \mid P(X \geq x) \geq 1 - u\}$ と定める.

補題 7.4.4.

- (1) F_L^{-1} は左連続である.
- (2) F_R^{-1} は右連続である.

定義 7.4.5. 分布関数 $F(x)$ において, $x \rightarrow \pm\infty$ としたときの収束の速さを**裾の重さ**という. 期待値や分散は積分で定義されるために, 裾の重さに影響を受けやすい.

7.4.3 母関数の概念の射程

母関数 (generating function) とは「数列の定める関数」である.^a 「数列を各項ごとに調べるよりも一度に扱った方が物事が見えてくることが多いので, 母関数を導入して, その性質を調べることは数学の常套手段です。」保型関数もその大成功例である. そこで, 確率分野でも Fourier 展開を考えると, その係数が積率である. 離散数学, 物理学, 統計学へ.

^a 母関数の「母」は, 関数を母親と見て数列の各項を子供と見立てて, そのように呼んでいます. (ちなみに, 英語では generating function という味わいのない呼び方をします.)

注 7.4.6 (generating function). 一般に母関数とは, Knuth の第一章に乗っているくらいに組合せ数学でよく使われる手法で, 今回の離散変数のような列 $(f_n)_{n \in \mathbb{N}}$ という対象に対して定義される, その $\text{rig } R$ 上の形式的冪級数の集合 $R[[z]]$ の元 $f(z) = \sum_{n=0}^{\infty} f_n z^n$ のことをいう. これにより, 数列が関数として生まれ変わったこととなり, こちらを解析することができる. また, 元の数列も微分の言葉で再現できる. $R = \mathbb{N}, \mathbb{Q}, \mathbb{R}, \mathbb{C}$ などが主に考えられ, 後2者については Taylor 展開の理論が, \mathbb{C} では解析接続の理論が模範としてあり, そこでは母関数とは解析関数のことをいう. 最初にこの方法を始めたのは一般線型回帰問題を解くために^{†4} A. de Moivre が創始し, James Stirling, Euler, Laplace が応用した.

例 7.4.7 (母関数の応用). 関手 $\text{Seq} \rightarrow \text{Fun}$ に他ならない. $G(z)$ が列 (a_n) の母関数で, $H(z)$ が列 (b_n) の母関数とする.

- (1) 加算: $\alpha G(z) + \beta H(z)$.
- (2) シフト: $z^m G(z)$.
- (3) 乗算: GH .

(1),(2) の組み合わせが, 漸化式を解くという行為である.

定義 7.4.8 (moment). 一般に, 関数 $f: \mathbb{R} \rightarrow \mathbb{R}$ の, $x = c$ を中心とす n 次の積率を

$$\mu_n^{(c)} = \int_{-\infty}^{\infty} (x - c)^n f(x) dx$$

と定める. f を密度関数とする測度の重心は $\mu = \frac{\mu_1^{(0)}}{\mu_0^{(0)}}$ と表せる. ほとんどの場合, 中心 c は重心=平均に取る.

7.5 特性関数

積分変換

期待値作用素が積分によって定義されるため, 「ある関数の平均を考える」こと, すなわち積分変換による分析手法が肝要になる. Fourier 変換により, 確率変数 $X \in \text{Meas}(\Omega, \mathbb{R})$ を, 関数 $\varphi: \mathbb{C} \rightarrow [\Delta]$ に $E[e^{iuX}] = E[\cos uX] + iE[\sin uX]$ により対応づけて考える.

逆転公式とは, 母関数から元の確率分布を復元する算譜である.

7.5.1 特性関数と Fourier 変換

特性関数と分布の対応は, 緩増加超関数の空間上の Fourier 逆変換 $\mathcal{F}^{-1}: \mathcal{S}'(\mathbb{R}) \xrightarrow{\sim} \mathcal{S}'(\mathbb{R})$ の $\mathcal{P}(\mathbb{R})$ への制限が与える. Fourier 解析的には, $u \in \mathbb{R}$ に対して, その指標 $e_u: \mathbb{R} \rightarrow \partial\Delta$ の積分を対応させる合成関数であるから, 「指標関数」が正しいかもしれない.

定義 7.5.1 (characteristic function). $(\mathbb{R}, \mathcal{B}_1)$ 上の確率測度 ν に対して,

$$\varphi(u) := \int e^{iux} \nu(dx) = \int \cos(ux) \nu(dx) + i \int \sin(ux) \nu(dx)$$

により定まる関数 $\varphi: \mathbb{R} \rightarrow \mathbb{C}$ を**特性関数**という. $|e^{iux}| = 1$ より, 特性関数は常に存在する.

命題 7.5.2 (確率変数の演算との対応). X の特性関数を φ とする.

- (1) $\frac{X - \mu}{\sigma^2}$ の特性関数は, $\varphi\left(\frac{u}{\sigma^2}\right) e^{-i\mu u / \sigma^2}$.
- (2) P^X が対称ならば, φ も対称な実数値関数となる.

^{†4} 数列とその母関数の対応は線型同型の代表例に他ならない.

補題 7.5.3 (inversion formula). 確率測度 ν とその特性関数 φ について, 区間 (a, b) で $\nu[\{a\}] = \nu[\{b\}] = 0$ ならば, すなわち, a, b が F の連続点ならば,

$$\nu[(a, b)] = F(b) - F(a) = \frac{1}{2\pi} \lim_{T \rightarrow \infty} \int_{-T}^T \frac{e^{-iua} - e^{-iub}}{iu} \varphi(u) du.$$

定理 7.5.4 (一意性定理). 特性関数の全体と確率測度の全体とに標準的な全単射が存在する. すなわち, 任意の $\mu_1, \mu_2 \in \mathcal{P}^d$ について, 次は同値.

- (1) $\mu_1 = \mu_2$.
- (2) $\varphi_{\mu_1} = \varphi_{\mu_2}$.

[証明]. $d = 1$ の場合について, 2通りの方法で示す.

反転公式による証明 $\varphi_\mu = \varphi_{\tilde{\mu}}$ とする. 反転公式 7.5.3 により, 任意の (端点が $F_\mu, F_{\tilde{\mu}}$ の連続点である) 开区間の測度は φ が一意に定める: $F_\mu(b) - F_\mu(a) = F_{\tilde{\mu}}(b) - F_{\tilde{\mu}}(a)$. $b \in \mathbb{R}$ が $F_\mu, F_{\tilde{\mu}}$ 両方の連続点であるとき, $F_\mu(b) = F_{\tilde{\mu}}(b)$. 分布関数は右連続で, 不連続点は高々可算個だから, これは $F_\mu = F_{\tilde{\mu}}$ を含意する. 分布関数の一意性より, $\mu = \tilde{\mu}$.

緩増加超関数の空間上の Fourier 変換による証明 まず, $P(\mathbb{R}) \subset S'(\mathbb{R})$ を示す. $\mu \in P(\mathbb{R})$ に対して, $\langle \mu, - \rangle : S(\mathbb{R}) \rightarrow \mathbb{R}$ は有界線型汎関数であることを示す. $|\langle \mu, f \rangle| \leq \left| \int_{\mathbb{R}} f(x) \mu(dx) \right| \leq \|f\|_\infty$. このとき, $\mu \in S'(\mathbb{R})$ の Fourier 逆変換が φ_μ である. $S'(\mathbb{R})$ 上の Fourier 変換は同型対応である. ■

系 7.5.5. L^2 -確率変数 $X \in \mathcal{L}^2$ がある $\alpha > 0$ について $\varphi_X(u) = \exp(-|u|^\alpha)$ ならば, $\alpha = 2$ で, $X \sim N(0, 2)$ である.

7.5.2 特性関数の特徴付け

命題 7.5.6. 関数 $\varphi : \mathbb{R} \rightarrow \mathbb{C}$ が特性関数であるならば, 次の3条件が成り立つ.

- (1) $\varphi(0) = 1$.
- (2) 一様連続である.
- (3) 正定値である: $\forall n \in \mathbb{N}, \xi_j \in \mathbb{R}, z_j \in \mathbb{C} \quad \sum_{j,k=1}^n \varphi(\xi_j - \xi_k) z_j \bar{z}_k \geq 0$.

定理 7.5.7 (Bochner). 関数 $\varphi : \mathbb{R} \rightarrow \mathbb{C}$ が次の3条件を満たすならば, ある一次元分布 $\mu \in \mathcal{P}(\mathbb{R})$ の特性関数である. 特に, 命題の3条件を満たすならば, 特性関数である.

- (1) $\xi = 0$ で連続.
- (2) $\varphi(0) = 1$.
- (3) 正定値である.

7.5.3 特性関数と分布の収束の対応

例 7.5.8.

$$\nu_n(A) := \sum_{j=1}^n \frac{1}{n} \delta_{\frac{j}{n}}(A) \quad (A \in \mathcal{B}(\mathbb{R}))$$

は一様分布 $U(0, 1)$ に弱収束する. 実際, 積分の定義より,

$$\int_{\mathbb{R}} g(x) \nu_n(dx) = \sum_{j=1}^n \frac{1}{n} g\left(\frac{j}{n}\right) \xrightarrow{n \rightarrow \infty} \int_0^1 g(x) dx.$$

定理 7.5.9. 確率測度 ν_n の特性関数を φ_n とする. (1) \Rightarrow (2) である. 各点収束極限 φ が原点で連続であるとき, (2) \Rightarrow (1) でもある.

- (1) ある確率測度 ν について, $\nu_n \Rightarrow \nu$ である.
- (2) φ_n が関数 φ に各点収束する.

系 7.5.10 (Glivenko). 確率測度 ν_n, ν の特性関数を φ_n, φ とする. このとき, 次の2条件は同値.

- (1) $\nu_n \rightarrow \nu$.
- (2) $\forall u \in \mathbb{R} \quad \varphi_n(u) \rightarrow \varphi(u)$.

[証明].

(1) \Rightarrow (2) 定義より自明.

(2) \Rightarrow (1) 定理による.

■

7.5.4 特性関数の滑らかさと積率の存在

特性関数は, 分布の滑らかさに関する情報を次のような形で保持している.

命題 7.5.11 (特性関数の導関数の表示). r 位の絶対積率が存在するとする: $\beta_r < \infty$. このとき, 特性関数 φ は C^r 級で, さらに $\varphi^{(r)}$ は一様連続でもあり,

$$\frac{d^r}{du^r} \varphi(u) = i^r \int e^{iux} x^r \nu(dx)$$

と表示できる. 特に, 積率 α_r について, $\varphi^{(r)}(0) = i^r \alpha_r$.

定理 7.5.12.

命題 7.5.13. $\nu \in \mathcal{P}^d$ とする. ある $m \in \mathbb{Z}_+$ に関して,

$$\int |u|^m |\varphi_F(u)| du < \infty$$

ならば, ν の確率密度関数

$$f(x) = \frac{1}{(2\pi)^d} \int e^{-iu \cdot x} \varphi_F(u) du$$

は C^m -級で, さらに $\forall k \leq m \quad f^{(k)} \in C_0(\mathbb{R}^d)$ が成り立つ.

命題 7.5.14 (特性関数の滑らかさが示唆する絶対積率の存在). 分布 ν の特性関数 φ が $u = 0$ において $2r$ 次までの微分を持つとする. このとき, $|\beta_{2r}| < \infty$.

7.5.5 特性関数の Taylor 展開

特性関数を Taylor 展開することで, 高次の積率 α_n も求めることが出来る.

前節の定理は Taylor の定理と併せれば, 次のようにも捉えられる.

系 7.5.15 (特性関数の Taylor 展開係数からの積率の計算). $\beta_r < \infty$ とする. このとき, φ は $u = 0$ の周りで展開

$$\varphi(u) = \sum_{n=0}^r \alpha_n \frac{(iu)^n}{n!} + o(u^r) \quad (u \rightarrow 0)$$

を持つ. すなわち, 中心積率は特性関数を用いて次のように表せる:

$$\alpha_n = \frac{1}{i^n} \frac{d^n \varphi(u)}{du^n} \Big|_{u=0}$$

系 7.5.16 (平均と分散の特性関数による特徴付け).

- (1) 平均 (1 次の積率) は $\alpha_1 = \frac{1}{i} \varphi'(0)$.
- (2) 分散 (2 次の中心積率) は $\mu_2 = -\varphi''(0) + (\varphi'(0))^2$.

7.6 キュムラント関数

特性関数の Taylor 展開係数には、積率 α_r が登場した。キュムラント関数の Taylor 展開係数を、キュムラントと言い、これが平均・分散の一般化となっている。

7.6.1 第2キュムラント母関数

キュムラントはキュムラント母関数＝積率母関数の対数の展開係数として得られるが、特性関数の対数からも、虚数単位 i に関する修正を施して得られる。その関係は、特性関数と積率の関係と並行である。この関数を、第2キュムラント母関数という。

命題 7.6.1 (キュムラント関数の Maclaurin 展開). $\beta_r < \infty$ とする。このとき、関数 $\psi(u) := \log \varphi(u)$ は $u = 0$ の近傍で定まり、次の形の展開を持つ：

$$\psi(u) = \sum_{j=1}^r \kappa_j \frac{(iu)^j}{j!} + o(u^r) \quad (|u| \rightarrow 0).$$

定義 7.6.2 (cumulant). 関数 $\psi(u) := \log \varphi(u)$ を第2キュムラント母関数またはキュムラント関数といい、この展開係数 $\kappa_n = \frac{1}{i^n} \frac{\partial^n}{\partial u^n} \psi(u) \Big|_{u=0}$ を、分布 ν の n 次のキュムラントと呼ぶ。この $n \in \mathbb{N}$ は、多重指数 $n \in \mathbb{N}^d$ と読み替えれば、多次元の場合にも通用する。分布の高次の形態を表す特性値である。

例 7.6.3 (キュムラントの例).

- (1) 1 次のキュムラント $(\kappa_n)_{|n|=1}$ とは、平均ベクトルである。
- (2) 2 次のキュムラント $(\kappa_n)_{|n|=2}$ とは、分散共分散行列である。

さらに高次のキュムラントはテンソルになる 7.9.15. 正規分布ではここは消える。これが平均と分散までが大事であることに繋がりますが、これは人類の認知負荷の限界と関係があるのか？

系 7.6.4 (キュムラントの積率・中心積率による表現). 可積分性を仮定する。

- (1) $\kappa_1 = \alpha_1$.
- (2) $\kappa_2 = \alpha_2 - \alpha_1^2 = \mu_2$.
- (3) $\kappa_3 = \alpha_3 - 3\alpha_1\alpha_2 + 2\alpha_1^3 = \mu_3$.
- (4) $\kappa_4 = \alpha_4 - 3\alpha_2^2 - 4\alpha_1\alpha_3 + 12\alpha_1^2\alpha_2 - 6\alpha_1^4 = \mu_4 - 3\mu_2^2$.

系 7.6.5 (積率・中心積率のキュムラントによる表現). 可積分性を仮定する。

- (1) $\alpha_2 = \kappa_2 + \kappa_1^2$, $\mu_2 = \kappa_2$.
- (2) $\alpha_3 = \kappa_3 + 3\kappa_1\kappa_2 + \kappa_1^3$, $\mu_3 = \kappa_3$.
- (3) $\alpha_4 = \kappa_4 + 3\kappa_2^2 + 4\kappa_1\kappa_3 + 6\kappa_1^3\kappa_2 + \kappa_1^4$, $\mu_4 = \kappa_4 + 3\kappa_2^2$.

7.7 積率母関数

7.7.1 Laplace 変換

\mathbb{R}_+ 上の分布に限っては、特性関数と同等に Laplace 変換も扱う。

記法 7.7.1.

$$\mathcal{P}_+ := \{\mu \in \mathcal{P}(\mathbb{R}) \mid \text{supp } \mu \subset [0, \infty)\}$$

と表す.

定義 7.7.2. $F \in \mathcal{P}_+$ に対して,

$$\mathcal{L}_F(u) := \int_0^\infty e^{-ux} F(dx)$$

で定まる関数 $\mathcal{L}_F: \mathbb{R}_+ \rightarrow \mathbb{R}_+$ を, F の **Laplace 変換** という.

定理 7.7.3 (一意性定理). $F, G \in \mathcal{P}_+$ について, 次の2条件は同値.

- (1) $F = G$.
- (2) $\mathcal{L}_F = \mathcal{L}_G$.

7.7.2 積率母関数

通常は Laplace 変換 $L(t) = E[e^{-tX}]$ ではなく, その逆 $M(t) := L(-t)$ が用いられ, これを統計学の観点からは積率母関数という. 積率母関数が $u = 0$ の近傍で定義されるとき, これにより確率分布が一意に決定される. 理論的な欠点は常に存在するとは限らないところで, 漸近展開などで用いられるのは特性関数である. 存在するならば特性関数に対して $\varphi(u) = \mathfrak{M}(e^{iu})$ なる関係があり, 解析接続を通じて一意性定理が述べられる. 積率母関数の対数をキュムラント母関数という. 一方で, 特性関数の対数は第2キュムラント母関数という.

定義 7.7.4 (moment generating function). $(\mathbb{R}, \mathcal{B}_1)$ 上の確率測度 ν に対して, $M_\nu(t) := \int_{\mathbb{R}} e^{tx} \nu(dx)$ により定まる関数 $\mathbb{R} \rightarrow \mathbb{R}$ を **積率母関数** という. 定義域を

$$D_\nu := \left\{ t \in \mathbb{R}^d \mid \int e^{t \cdot x} F(dx) < \infty \right\}$$

で表す.

補題 7.7.5 (マクローリン展開係数は積率である). \mathfrak{M}_ν が原点の近傍で存在するならば, そこで C^∞ 級であり, $\forall_{n \in \mathbb{Z}_+^d} \partial^n \mathfrak{M}_\nu(0) = \alpha_n$. 特に,

- (1) $\alpha_1 = \partial \mathfrak{M}_\nu(0) = \partial(\log \mathfrak{M}_\nu)(0) = \partial \mathfrak{C}_\nu(0)$.
- (2) $\mu_2 = \partial^2(\log \mathfrak{M}_\nu)(0) = \partial^2 \mathfrak{C}_\nu(0)$.

定理 7.7.6 (特性関数との関係と一意性定理).

- (1) $\nu \in \mathcal{P}^d$ とする. D_ν が $0 \in \mathbb{R}^d$ の近傍ならば, ある整数 ϵ が存在して, 積率母関数 \mathfrak{M}_ν は $\mathcal{R}_\epsilon := ((-\epsilon, \epsilon) \times i\mathbb{R})^d$ 上の解析関数 \mathfrak{M}_ν^\dagger に解析接続され, $\varphi_\nu(-) = \mathfrak{M}_\nu^\dagger(i-)$ が成り立つ.
- (2) 正則関数 \mathfrak{M}_ν^\dagger は, $z \in \mathcal{D}_\epsilon := \{\zeta \in \mathbb{C} \mid |\zeta| < \epsilon\}^d$ 上において, 絶対収束級数

$$\mathfrak{M}_\nu^\dagger(z) = \sum_{k=1}^{\infty} \frac{1}{k!} \int (z \cdot x)^k \nu(dx)$$

なる展開を持つ.

- (3) $\nu_1, \nu_2 \in \mathcal{P}^d$ のとき, 原点のある開近傍 $U \subset D_{\nu_1} \cap D_{\nu_2}$ 上で $\mathfrak{M}_{\nu_1} = \mathfrak{M}_{\nu_2}$ ならば, $\nu_1 = \nu_2$ が成り立つ.

注 7.7.7. なお, 積率母関数は, 確率母関数 $G(z) := E[z^X]$ に対して $G[e^t] = \mathfrak{M}_X(t)$ なる関係もある.

7.7.3 キュムラント母関数

積率母関数の対数の展開係数をキュムラントといい, この特徴量の列も分布を特徴付ける. キュムラントのことは, その性質を研究した Thorvald N. Thiele に因み, ティエレの半不変数 (semi-invariant) と呼ぶ.^a 積率との繋がりが深い.

^a 統計学の分野で尤度に関する初期の考察を行い, 保険数学の分野で Hafnia 保険会社を設立し, 数学部長を務め, デンマーク保険統計協会を設立し

た。

定義 7.7.8. $v \in \mathcal{G}^d$ に対して, $\mathfrak{C}_v(t) := \log \mathfrak{M}_F(t)$ で定まる D_v 上の関数を, F の**キュムラント母関数**という.

注 7.7.9 (affine 変換に対する半不変性). 半不変数というのは, 積率は $Y = \alpha X + \beta$ なる affine 変換に対して $E[Y^2] = \alpha^2 E[\alpha^2] + 2\alpha\beta E[X] + \beta^2$ なるように変換されるのに対して,

$$\kappa_1^Y = \alpha \kappa_1^X + \beta, \quad \kappa_n^Y = \alpha^n \kappa_n^X \quad (n = 2, 3, \dots)$$

というように殆ど形を変えないことにちなむ.

例 7.7.10 (キュムラント母関数は極めて少ししか変わらなくても, 密度関数は見かけ上全く異なる例).

7.7.4 積率問題

積率問題の解の存在は, Hahn-Banach の定理の応用である. ここでは確率的な文脈であるが, 物理的にも, 電荷密度 ρ に関する条件として読める.

問題 7.7.11 (moment problem). 実数列 $\alpha: \mathbb{N} \rightarrow \mathbb{R}$ に対して, これを積率の列に持つ分布が一意に定まるか?

命題 7.7.12. 有限個への制限 $\alpha|_{[N]}$ について, これを満たす積率問題の解は存在する.

定理 7.7.13 (存在の必要十分条件). 区間 $[a, b]$ 上の分布であって, 積率 α を持つものを考える.

(1) 積率問題は解を持つ.

$$(2) \exists c > 0 \quad \forall N \in \mathbb{N} \quad \forall a_k \in \mathbb{R} \quad \left| \sum_{k=0}^N a_k \alpha_k \right| \leq c \max_{a \leq x \leq b} \left| \sum_{k=0}^N a_k x^k \right|.$$

定理 7.7.14 (一意性の十分条件). $(\alpha_n)_{n \in \mathbb{N}}$ が $\exists t_0 > 0 \quad \sum_{n=1}^{\infty} \frac{|\alpha_n|}{n!} t_0^n < \infty$ を満たすならば, α を積率とする分布はただ一つである.

例 7.7.15. 3 次以上のキュムラントがすべて 0 になる確率分布は, 正規分布に限る.

7.7.5 多次元確率変数の特性関数

複素数値関数が特性関数になるためには Bochner の定理が十分条件を与える.

7.8 確率変数の独立性と期待値

有限個の確率変数 X_1, \dots, X_n の独立性とは, これが定める (X_1, \dots, X_n) の結合分布が, 各 X_i の分布 P^{X_i} が定める直積速度 $P^{X_1} \times \dots \times P^{X_n}$ に一致することをいう. 本質的に「直積」とみなせるものを独立性という.

7.8.1 独立な確率変数の積の期待値

記法 7.8.1. $X_j: (\Omega, \mathcal{F}, P) \rightarrow (\mathcal{X}_j, \mathcal{B}_j)$ を確率変数とする.

命題 7.8.2. $n \geq 2$ を整数とする. 可測関数 $f_j: \mathcal{X}_j \rightarrow \overline{\mathbb{R}}$ について, $f_j(X_j) \in \mathcal{L}^1(\Omega, \mathcal{F}, P)$ とする. このとき, X_1, \dots, X_n が独立

ならば, 積 $\prod_{i=1}^n f_i(X_i)$ も可積分で,

$$E \left[\prod_{i=1}^n f_i(X_i) \right] = \prod_{i=1}^n E[f_i(X_i)]$$

を満たす.

注 7.8.3. 複素数値可測関数にも一般化出来る.

系 7.8.4 (独立性の十分条件). 任意の有界可測関数 f_i について

$$E \left[\prod_{i=1}^n f_i(X_i) \right] = \prod_{i=1}^n E[f_i(X_i)]$$

が成り立つならば, X_1, \dots, X_n は独立である.

7.8.2 確率変数の独立性と共分散

命題 7.8.5. $X, Y \in \mathcal{L}^1(\Omega, \mathcal{F}, P)$ を独立とする. このとき, $\text{Cov}[X, Y] = 0$.

7.8.3 確率変数の独立性と特性関数

平均作用素 E の積に対する振る舞いによって, 独立性の十分条件を与えることが出来た. 特性関数によっても特徴付けることが出来る.

記法 7.8.6. 多変量確率変数 Y の特性関数を φ_Y と表す. X_j ($j \in [n]$) を d_j 次元確率変数とする. $X := (X_1, \dots, X_n)$ は $d := \sum_{j=1}^n d_j$ 次元確率変数である. X, X_j の特性関数は

$$\varphi_X(u) = E \left[e^{i \sum_{j=1}^n u_j \cdot X_j} \right] \quad (u \in \mathbb{R}^d), \quad \varphi_{X_j}(u_j) = E \left[e^{i u_j \cdot X_j} \right] \quad (u_j \in \mathbb{R}^{d_j})$$

となる.

定理 7.8.7 (Kac). 確率変数列 X_1, \dots, X_n について, 次の2条件は同値.

- (1) X_1, \dots, X_n は独立である.
- (2) $\varphi_X = \varphi_{X_1} \otimes \dots \otimes \varphi_{X_n} := \prod_{j=1}^n \varphi_{X_j}(u_j)$ である.

系 7.8.8. d 次元確率変数の列 X_1, \dots, X_n が独立ならば,

$$\varphi_{\sum_{j=1}^n X_j}(u) = \prod_{j=1}^n \varphi_{X_j}(u) \quad (u \in \mathbb{R}^d)$$

7.8.4 独立同分布に従う確率変数列

記法 7.8.9. X_1, \dots, X_n が \mathbb{R}^d に値を取る i.i.d. であって, $E[X_1] = \mu, \text{Var}[X_1] = \Sigma$ であることを, $X_1, \dots, X_n \sim \text{i.i.d.}(\mu, \Sigma)$ で表す.

7.8.5 独立確率変数の和と畳み込み

確率変数の和は, 分布の畳み込みに対応し, 特性関数のテンソル積に対応する.

系 7.8.10. d 次元確率変数 X_1, \dots, X_n が独立であれば, $X := X_1 + \dots + X_n$ について

$$\forall u \in \mathbb{R}^d \quad \varphi_X(u) = \prod_{j=1}^n \varphi_{X_j}(u).$$

例 7.8.11. Hermite 分布と Skellam 分布??.

記法 7.8.12. $A - x := \{y \in \mathbb{R}^d \mid y + x \in A\}$ と表す.

定義 7.8.13 (convolution). $\nu_1, \nu_2 \in \mathcal{P}(\mathbb{R}^d)$ に対して,

$$\nu(A) := \int_{\mathbb{R}^d} \nu_1(A - x) \nu_2(dx)$$

で定まる確率測度 ν を $\nu_1 * \nu_2$ で表す.

補題 7.8.14.

- (1) $\nu_1 * \nu_2(A) = \nu_2 * \nu_1(A) = \int_{\mathbb{R}^{2d}} 1_A(x_1 + x_2) \nu_1(dx_1) \nu_2(dx_2).$
- (2) 独立な確率変数 X_1, X_2 が $P^{X_1} = \nu_1, P^{X_2} = \nu$ を満たすとき, $P^{X_1+X_2} = \nu_1 * \nu_2.$
- (3) $\varphi_{\nu_1 * \nu_2} = \varphi_{\nu_1} \otimes \varphi_{\nu_2}.$

(3) は ν_1, ν_2 の独立性を特徴付けない点に注意.

補題 7.8.15. $P(\mathbb{R}^d)$ は $*$ を積として, 単位元 δ_0 を持つ可換な半群をなす.

定義 7.8.16 (reproducing property). ある分布族について, 畳み込みについて閉じていることを分布族の再生性という.

例 7.8.17.

- (1) $G(\alpha, \nu_1) * G(\alpha, \nu_2) = G(\alpha, \nu_1 + \nu_2).$
- (2) $N(\mu_1, \Sigma_1) * N(\mu_2, \Sigma_2) = N(\mu_1 + \mu_2, \Sigma_1 + \Sigma_2).$
- (3) $C(\mu_1, \sigma_1) * C(\mu_2, \sigma_2) = C(\mu_1 + \mu_2, \sigma_1 + \sigma_2).$
- (4) $B(n_1, p) * B(n_2, p) = B(n_1 + n_2, p).$
- (5) $\text{Pois}(\lambda_1) * \text{Pois}(\lambda_2) = \text{Pois}(\lambda_1 + \lambda_2).$

7.9 多次元分布の扱い

7.9.1 多次元確率変数の分布

離散確率分布を table にまとめた時, 分布表の中の部分が結合分布となり, 縁の部分 (合計欄) が周辺分布となる.

定義 7.9.1 (joint / simultaneous distribution, marginal distribution). $X = (X_1, \dots, X_d) : \Omega \rightarrow \mathbb{R}^d$ を確率変数とする.

- (1) $(\mathbb{R}^d, \mathcal{B}_d)$ 上の確率分布 P^X を X_1, \dots, X_d の結合分布または同時分布という.
- (2) 各 X_i の分布 P^{X_i} を周辺分布という. $P^{(X_{i_1}, \dots, X_{i_k})}$ も, $(X_{i_1}, \dots, X_{i_k})$ の周辺分布という.

例 7.9.2 (multinomial distribution). k 個の背反な事象 $\sum_{i=1}^k A_i = \Omega$ について, $P(A_i) = p_i$ とする. 各 A_i の起こる回数を X_i とすると, 確率ベクトル (X_1, \dots, X_k) の分布を k 項分布 $M(n; p_1, \dots, p_k)$ という. $k = 2$ の場合は二項分布に等しくなる. また, 各 X_i の周辺分布は 2 項分布 $B(n, p_i)$ である. 多項分布は必ず $\sum_{i=1}^k X_i = n$ という線型関係を満たすので, この意味で退化した分布である.

7.9.2 共分散

定義 7.9.3 (covariance, correlation coefficient). 2乗可積分実確率変数 X, Y について,

- (1) $\text{Cov}[X, Y] := E[(X - E[X])(Y - E[Y])]$ を共分散という.
- (2) $\rho(X, Y) := \frac{\text{Cov}[X, Y]}{\sqrt{\text{Var}[X]}\sqrt{\text{Var}[Y]}}$ を相関係数という.

命題 7.9.4. 2乗可積分実確率変数 X, Y, Z について,

- (1) $\text{Cov}[X, Y] = \text{Cov}[Y, X]$.
- (2) $\forall a, b \in \mathbb{R} \quad \text{Cov}[aX + bY, Z] = a\text{Cov}[X, Z] + b\text{Cov}[Y, Z]$.
- (3) $\text{Cov}[X, X] = \text{Var}[X] \geq 0$. 等号が成立するならば $X = E[X]$ a.s..
- (4) $\text{Cov}[X, 1] = 0$. $\forall a, b \in \mathbb{R} \quad \text{Cov}[aX + b, Y] = a\text{Cov}[X, Y]$.
- (5) $\text{Cov}[X, Y] = E[XY] - E[X]E[Y]$.

例 7.9.5 (多項分布の共分散). $X = (X_1, \dots, X_k) \sim M(n; p_1, \dots, p_k)$ とする.

- (1) $E[X_i] = np_i$.
- (2) $\text{Var}[X_i] = np_i(1 - p_i)$.
- (3) $\text{Cov}[X_{i_1}, X_{i_2}] = -np_{i_1}p_{i_2} \ (i_1 \neq i_2 \in [k])$.

[証明]. 多項定理より,

$$(e^{u_1}p_1 + \dots + e^{u_k}p_k)^n = \sum_{x_1, \dots, x_k} * P^X[\{(x_1, \dots, x_k)\}] e^{u_1x_1 + \dots + u_kx_k}.$$

ただし, $*$ は線形関係 $x_1 + \dots + x_k = n$ を満たす x_1, \dots, x_k についての和とする.

- (1) 両辺の $(u_1, \dots, u_k) = (0, \dots, 0)$ における u_i 偏微分係数より, $np_i = \sum_{x_1, \dots, x_k} * x_i P^X[\{(x_1, \dots, x_k)\}] = E[X_i]$.
- (2) 同様に u_i の2階微分を考えて, $E[X_i^2] = n(n-1)p_i^2 + np_i$ を得る. よって, $\text{Var}[X_i] = E[X_i^2] - (E[X_i])^2 = np_i(1 - p_i)$.
- (3) $i_1 \neq i_2$ に関して, 順に u_{i_1}, u_{i_2} での偏微分を考えることにより, $E[X_{i_1}X_{i_2}] = n(n-1)p_{i_1}p_{i_2}$. よって, 共分散公式 7.9.4 より,

$$\text{Cov}[X_{i_1}, X_{i_2}] = E[X_{i_1}X_{i_2}] - E[X_{i_1}]E[X_{i_2}] = -np_{i_1}p_{i_2}.$$

■

要諦 7.9.6. 証明が技巧的すぎる, 多項定理に指数関数を代入する.

7.9.3 共分散行列

定義 7.9.7 (covariance matrix, variance-covariance matrix). $X : \Omega \rightarrow \mathbb{R}^d$ を確率変数とする.

- (1) X が可積分のとき, 項別積分

$$E[X] = \begin{bmatrix} E[X_1] \\ \vdots \\ E[X_d] \end{bmatrix}$$

を X の平均ベクトルという.

- (2) X, Y が2乗可積分のとき,

$$\text{Cov}[X, Y] = \begin{bmatrix} \text{Cov}[X_1, Y_1] & \cdots & \text{Cov}[X_1, Y_s] \\ \vdots & \ddots & \vdots \\ \text{Cov}[X_d, Y_1] & \cdots & \text{Cov}[X_d, Y_s] \end{bmatrix}$$

を X, Y の共分散行列という.

- (3) $\text{Cov}[X, X]$ を X の分散共分散行列または分散行列と呼ぶ.

注 7.9.8. この共分散行列は、シンプルではあるが、非常に多岐にわたる分野でとても有用なツールである。分散共分散行列からは、データの相関を完全に失わせるような写像を作る変換行列を作ることができる。これは、違った見方をすれば、データを簡便に記述するのに最適な基底を取っていることになる。(分散共分散行列のその他の性質やその証明については、en:Rayleigh quotient を参照) これは、統計学では主成分分析 (PCA) と呼ばれており、画像処理の分野では、カルーネン・レーベ変換 (KL-transform) と呼ばれている。^{†5}

記法 7.9.9 (期待値作用素の拡張). 期待値作用素 E を行列値確率変数 $M = [M_{ij}] \in M_{ij}(\mathbb{R})$ 上に対しても $E : M_{ij}(\mathbb{R}) \rightarrow M_{ij}(\mathbb{R}); E[M] = [E[M_{ij}]]$ と拡張すると、平均ベクトルは $E[M]$ 、共分散行列は $\text{Cov}(X, Y) = E[(X - E[X])(Y - E[Y])^T]$ と表せる。

命題 7.9.10.

- (1) 可積分 d 次元確率変数 X , $m \times d$ 行列 A , $a \in \mathbb{R}^m$ に対して, $E[AX + a] = AE[X] + a$.
- (2) 2乗可積分 d 次元確率変数 X , 2乗可積分 s 次元確率変数 Y に対して, $\text{Cov}[X, Y] = \text{Cov}[Y, X]^T$. また, $\text{Cov}[X, Y] = E[XY^T] - E[X]E[Y]^T$.
- (3) 2乗可積分 d 次元確率変数 X, Y , 2乗可積分 s 次元確率変数 Z に対して, $\text{Cov}[X + Y, Z] = \text{Cov}[X, Z] + \text{Cov}[Y, Z]$.
- (4) 2乗可積分 d 次元確率変数 X , $m \times d$ 行列 A , $a \in \mathbb{R}^m$, 2乗可積分 s 次元確率変数 Y , $b \in \mathbb{R}^s$ に対して, $\text{Cov}[AX + a, BY + b] = A\text{Cov}[X, Y]B^T$.

命題 7.9.11 (確率ベクトルの2次形式の平均). X を d 次元2乗可積分確率変数, G を $d \times d$ 定数行列とする. このとき,

$$E[X^T G X] = \text{Tr}(G \text{Var}[X]) + E[X]^T G E[X].$$

7.9.4 積率の定義

積率の次元もベクトル値 $n \in \mathbb{N}^d$ で指定できる.

記法 7.9.12. $x = (x_1, \dots, x_d) \in \mathbb{R}^d$ に対して, $\partial_i := \frac{\partial}{\partial x_i}$ とし, $n := (n_1, \dots, n_d) \in \mathbb{Z}_+^d$ に対して,

$$\begin{aligned} |n| &:= n_1 + \dots + n_d, & n! &:= n_1! \dots n_d!, \\ x^n &:= x_1^{n_1} \dots x_d^{n_d}, & \partial^n &:= \partial_1^{n_1} \dots \partial_d^{n_d}. \end{aligned}$$

ただし, $x_j^0 = 1, \partial^0 = 1$ とよむ.

定義 7.9.13 (moment, central moment). d 次元確率変数 $X = (X_1, \dots, X_d)$ に対して, 可積分性の仮定の下で,

- (1) $\alpha_n := E[X^n]$ を n 次積率という.
- (2) $\mu_n := E[(X - E[X])^n]$ を n 次中心積率という.

定義 7.9.14. $(\mathbb{R}^d, \mathcal{B}_d)$ 上の確率測度 ν に対して, 可積分性の仮定の下で,

- (1) $\mu := \left(\int_{\mathbb{R}^d} x_i \nu(dx) \right) \in \mathbb{R}^d$ を平均 (ベクトル) という.
- (2) $\alpha_n := \int_{\mathbb{R}^d} x^n \nu(dx)$ を n 次の積率という.
- (3) $\nu_n := \int_{\mathbb{R}^d} (x - \mu)^n \nu(dx)$ を n 次の中心積率という.
- (4) 特に $(\mu_n)_{|n|=2}$ を ν の分散共分散行列という.

^{†5} <https://ja.wikipedia.org/wiki/分散共分散行列>

7.9.5 キュムラントの定義

定義 7.9.15. 第2キュムラント母関数によるキュムラントの定義

$$\psi(u) = \sum_{j=1}^r \kappa_j \frac{(iu)^j}{j!} + o(u^r) \quad (|u| \rightarrow 0).$$

は, n を多重指数 \mathbf{n} に読み替えることで, $\kappa_{\mathbf{n}} := i^{-|\mathbf{n}|} \partial^{\mathbf{n}} \psi(0)$ そのまま拡張される.

記法 7.9.16. $(\partial_{u_i})_0$ を, $u := (u_i) = 0$ における u_i -偏微分係数を表す.

議論 7.9.17 (キュムラントのテンソル表現). d 次元確率分布 ν について, $\alpha_1, \dots, \alpha_r \in [d]$ に対して

$$\lambda^{\alpha_1 \dots \alpha_r} := (-i)^r (\partial_{u_{\alpha_1}})_0 \dots (\partial_{u_{\alpha_r}})_0 \log \varphi(u)$$

と定める. これも ν の r 次のキュムラントといい, 行列 $(\lambda^{\alpha_1 \dots \alpha_r})_{\alpha_1, \dots, \alpha_r \in [d]}$ は対称テンソルを定める.

要諦 7.9.18. $\mathbf{r} := (r_1, \dots, r_d) \in \mathbb{Z}_+^d$ が $r_k := |\{j \in [r] \mid \alpha_j = k\}|$ を満たすとする. このとき,

$$\lambda^{\alpha_1 \dots \alpha_r} = \kappa_{\mathbf{r}}$$

7.10 コピュラ

相関係数は, 2つの確率変数に対して, 実数 $[-1, 1]$ を対応させるが, もっと表現力豊かに, 変量間の従属性を, 多次元分布によって直接的に表現することを考える.^a

これはなんだか, 周辺分布の張り合わせとして多次元分布を表現するホモトピー論のようである. 逆に, コピュラなく, 直積によって周辺分布を張り合わせた場合が, 独立性である.

^a この単語は元々音楽や言語学で使われていたが, 統計学の用語として用いたのは, 1959年にスクラー (Abe Sklar) がパリ大学統計学会誌 (the Statistical Institute of the University of Paris) で発表したのが最初である.

記法 7.10.1. $I := [0, 1]$ とする.

7.10.1 定義と例

定義 7.10.2 (copula). 次の条件を満たす関数 $C: I^2 \rightarrow I$ を接合関数という:

- (1) $C(-, 0) = C(0, -) = 0$.
- (2) $C(-, 1) = C(1, -) = \text{id}_I$.
- (3) $\forall u_1, u_2, v_1, v_2 \in I \quad u_1 \leq v_1, u_2 \leq v_2 \Rightarrow C(v_1, v_2) - C(u_1, v_2) - C(v_1, u_2) + C(u_1, u_2) \geq 0$.

例 7.10.3 (凸関数と product copula). C^2 級関数 C が $\partial_{u_1} \partial_{u_2} C(u_1, u_2) \geq 0$ をみたすとき, コピュラである. 特に, $C^{\Pi}(u_1, u_2) := u_1 u_2$ を積コピュラという.

例 7.10.4 (二次元の分布関数が定めるコピュラ).

- (1) 区間 $(0, 1)$ 上の一様分布に従う2つの確率変数 $X_1, X_2 \sim U((0, 1))$ の分布関数 F はコピュラである.
- (2)

7.10.2 Sklar の定理

多次元分布は、周辺分布関数とコピュラによって定まる。

定理 7.10.5 (2次元の場合 (Sklar 1959)). (X_1, X_2) の結合分布関数を F , それぞれの周辺分布関数を F_1, F_2 とする. このとき, コピュラ C が存在して,

$$\forall x_1, x_2 \in \mathbb{R} \quad F(x_1, x_2) = C(F_1(x_1), F_2(x_2))$$

と表せる. F_1, F_2 が連続のとき, C は一意である.

要諦 7.10.6. 逆関数 F_1^{-1}, F_2^{-1} が存在するときは, これを用いて $C(u_1, u_2) = F(F_1^{-1}(u_1), F_2^{-1}(u_2))$ とコピュラを構成できる.

7.10.3 Archimedes コピュラ

第 8 章

確率分布の例

離散分布というクラスは、極限構成について閉じていないという意味で、理論的な実用性がない。極限について議論するには、絶対連続分布と実数というところに行き着く。このクラスは「絶対連続」なる名前だが、確率が積分によって表される確率分布という意味である。分布の特性値は、確率分布が定める積分に、適切な積分核を挟んで得られるものであることが明確になる。

8.1 一次元離散分布の例

8.1.1 デルタ分布

Shannon のエントロピーとは自己情報量 $I(p) := -\log_2 p$ ($p \in \mathcal{C}$) が定める積分作用素 $H : \text{Meas}(\mathcal{C}, \mathbb{R}) \rightarrow [0, \log \alpha]$ であるが、これが最小になるときの確率分布である。

定義 8.1.1 (degenerated / delta distribution). ある一点のみで 1 をとる確率質量関数が定める確率分布を**退化分布**と呼ぶ。デルタ関数 δ_a ($a \in X$) がこの測度 $\epsilon_a(A) := 1_{\{B \in \mathcal{A} \mid a \in B\}}$ ($A \in \mathcal{A}$) を定める。これは自然な埋め込み $X \hookrightarrow \mathcal{M}(X)$ とも考えられる。^{t1}

8.1.2 経験分布

経験分布関数と順序統計量は一対一対応する。

定義 8.1.2 (order statistic, empirical distribution function, resampling from sample, bootstrap method). $X_1, \dots, X_n \sim F$, i.i.d. とする。

- (1) これらの確率変数の値を小さい順に並べ替えて得る列 $X_{(1)} \leq X_{(2)} \leq \dots \leq X_{(n)}$ を**順序統計量**という。
- (2) 順序統計量の第 i 成分 $X_{(i)}$ を**第 i 順序統計量**といい、第一順序統計量を**最小値**、第 n 順序統計量を**最大値**という。
- (3) 特定の値 $x \in \Omega$ に対して、 x 以下となる観測値の割合を返す関数 $F_n(x) := \frac{1}{n} |\{i \in [n] \mid X_i \leq x\}|$ を**経験分布関数**という。^{t2}
- (4) すでに得られた標本から再び標本抽出を行うことを**標本からのリサンプリング**とよぶが、これは経験分布 F_n に従う確率変数を観測することにあたる。
- (5) すでに得られた標本 $(x_i)_{i \in [n]}$ の経験分布 F_n からリサンプリングを繰り返し、 F_n を代用して仮想的な標本の取り直しを行う方法を**ブートストラップ法**という。

注 8.1.3. 大数の強法則によって、 $P \left[\lim_{n \rightarrow \infty} |F_n(x) - F(x)| = 0 \right] = 1$ が従うが、より強い「一様大数の法則」ともいえるべき結果がある。

^{t1} 例えば弱位相について、この埋め込みの像の凸包は稠密である。

^{t2} 点 $x_i \in \Omega$ に確率 $1/n$ を持つような離散確率分布の累積分布関数となっているので、記法も寄せている。

定理 8.1.4 (Glivenko-Cantelli (1933)).

$$P \left[\lim_{n \rightarrow \infty} \sup_{x \in \mathbb{R}} |F_n(x) - F(x)| = 0 \right] = 1.$$

8.1.3 Rademacher 分布

機械学習研究者の十八番. Rademacher 過程は, 幅 1 のランダムウォークと考えられる.

定義 8.1.5 (Rademacher distribution, Rademacher / Steinhaus / symmetric Bernoulli variable).

(1) \mathbb{Z} 上の確率質量関数

$$f(k) = \frac{1}{2}(\delta(k-1) + \delta(k+1))$$

によって定まる離散分布を, **Rademacher 分布**という.

(2) Rademacher 確率分布に従う独立同分布な確率変数列 $\epsilon_1, \dots, \epsilon_n$ に対して, $X := \sum_{i=1}^n \epsilon_i$ と定めた $X: \mathbb{R}^n \rightarrow \mathbb{R}$ を

Rademacher 過程という.

(3) 複素数値 Rademacher 変数は Steinhaus 変数とも呼ばれ, $P(a < \arg(\epsilon) < b) = \frac{1}{2\pi}(b-a)$ で定まる.

注 8.1.6. X が Rademacher 分布に従う確率変数ならば, $\frac{X+1}{2} \sim B(1/2)$.

命題 8.1.7 (Van Zuijlen's bound).

$$P \left(\left| \frac{\sum_{i=1}^n X_i}{\sqrt{n}} \right| \leq 1 \right) \geq \frac{1}{2}.$$

8.1.4 離散一様分布

整数 $1, 2, \dots, N$ から k 個の標本が非復元抽出され、離散一様分布と同様に、標本の抽出のされ方に整数による差はないとする。ここで未知の最大値 N を推定する問題が生じる。このような問題を一般に German tank problem (ドイツ戦車問題) と呼び、第二次世界大戦中のドイツでの戦車生産数の最大値を推定するという問題に由来する。

定義 8.1.8 (discrete uniform distribution). $0 < |\mathcal{X}| < \infty$ を満たす有限集合上の, 定値関数 $p = \frac{1}{|\mathcal{X}|}$ を確率関数として定まる測度 $U: \text{FinSet} \rightarrow \mathcal{M}(\mathcal{X})$ を **離散一様分布**という.

要諦 8.1.9. Shannon のエントロピーとは自己情報量 $I(p) := -\log_2 p$ ($p \in \mathcal{X}$) が定める積分作用素 $H: \text{Meas}(\mathcal{X}, \mathbb{R}) \rightarrow [0, \log \alpha]$ であるが, これが最大になるときの確率分布である.

8.1.5 二項分布

600 人の中で 1 年を 365 日として, 今日誕生日の人が x 人である確率は, $b\left(x; 600, \frac{1}{365}\right)$ となる.

定義 8.1.10 (binomial distribution). 可測空間 $(n+1, P(n+1))$ 上のパラメータ x, p の二項分布 $B(n, p): \mathbb{N} \times [0, 1] \rightarrow \mathcal{M}(n+1)$ は, 成功確率が p で一定な試行 (Bernoulli 試行という) を独立に n 回続けるという確率空間 2^n における確率分布であり, 確率変数を成功回数 $x \in n+1$ とすると, 確率質量関数 $b: n+1 \rightarrow [0, 1]$ は $b(x; n, p) = \binom{n}{x} p^x q^{n-x}$ と表される. $\text{Bernoulli}(1, p) := B(1, p)$ を Bernoulli 分布という.

命題 8.1.11 (二項分布の平均と分散).

(1) 平均について, $\alpha_1(b(n, p)) = np$.

(2) 分散について, $\mu_2(b(n, p)) = npq$.

[証明] .

(1)

$$\begin{aligned}
 \mu &= \sum_{x=0}^n x \binom{n}{x} p^x q^{n-x} \\
 &= \sum_{x=0}^n x \frac{n!}{x!(n-x)!} p^x q^{n-x} \\
 &= np \sum_{x=1}^n \frac{(n-1)!}{(x-1)!(n-x)!} p^{x-1} q^{n-x} \\
 &= np \sum_{y=0}^{n-1} \frac{(n-1)!}{y!(n-1-y)!} p^y q^{n-1-y} & y := x-1 \\
 &= np \sum_{y=0}^{n-1} b(n-1, p) = np.
 \end{aligned}$$

(2) 確率関数 $(b(x; n, p))_{x \in \mathbb{N}}$ が定める母関数 $g: \mathbb{R} \rightarrow \mathbb{R}$ は

$$\begin{aligned}
 g(z) &= \sum_{x=0}^n b(x; n, p) z^x \\
 &= \sum_{x=0}^n \binom{n}{x} p^x q^{n-x} z^x = (pz + q)^n
 \end{aligned}$$

と表せる. $g'(z) = np(pz + q)^{n-1}$, $g''(z) = n(n-1)p^2(pz + q)^{n-2}$ より, 分散公式 7.4.2 から,

$$\sigma^2 = g''(1) + g'(1) - (g'(1))^2 = n(n-1)p^2 + np - n^2p^2 = npq.$$

■

要諦 8.1.12. 確率母関数が, 二項展開の式に一致することから, ここに予想だにしなかった抜け道がある.

8.1.6 Poisson 分布

極限分布のお手本

所与の時間間隔で, 確率が線型に減衰する現象の観測回数を確率変数としたモデルである. 放射線物質から一定期間に放射される粒子の数の経時変化は Poisson 過程であり, 一定期間に起こる事故の数など. 逆に発生間隔は指数分布となる.

8.1.6.1 定義

定義 8.1.13 (Poisson distribution (1838)). 可測空間 $(\mathbb{N}, P(\mathbb{N}))$ 上の **Poisson 分布** $\text{Pois}(\lambda): (0, \infty) \rightarrow \mathcal{M}(\mathbb{N})$ とは, 確率質量関数 $p(x; \lambda) = \frac{\lambda^x}{x!} e^{-\lambda}: \mathbb{N} \rightarrow [0, 1]$ が定める確率分布である. 母数 λ は, 単位時間当たりの事象の平均発生回数などの割合と見なされる場合は, **到着率**と呼ばれる. 平均も分散も λ に一致する.

8.1.6.2 極限分布としての Poisson 分布

命題 8.1.14 (Poisson's limit theorem). 減衰する確率 $p(n) := \frac{\lambda}{n}$ についての二項分布 $B(n, p(n))$ は, $\lim_{n \rightarrow \infty} b(x; n, p) = \frac{\lambda^x}{x!} e^{-\lambda} (\forall x \in \mathbb{N})$ を満たす.

[証明] .

$$b\left(x; n, \frac{\lambda}{n}\right) = \binom{n}{x} \left(\frac{\lambda}{n}\right)^x \left(1 - \frac{\lambda}{n}\right)^{n-x}$$

$$\begin{aligned}
&= \frac{n(n-1)\cdots(n-x+1)}{x!} \left(\frac{\lambda}{n}\right)^x \left(1 - \frac{\lambda}{n}\right)^{n-x} \\
&= \frac{\lambda^x}{x!} \left(1 - \frac{1}{n}\right) \cdots \left(1 - \frac{x-1}{n}\right) \left(1 + \frac{-\lambda}{n}\right)^{n/(-\lambda) \cdot (-\lambda)} \left(1 - \frac{\lambda}{n}\right)^{-x} \\
&\xrightarrow{n \rightarrow \infty} \frac{\lambda^x}{x!} e^{-\lambda}
\end{aligned}$$

この収束は一様収束である。 ■

命題 8.1.15 (Poisson 分布の確率母関数). Poisson 分布 $\text{Pois}(\lambda)$ の定める確率母関数は $g(z) = e^{\lambda(z-1)}$ である。

〔証明〕. 確率変数列 $(p(x; \lambda))_{x \in \mathbb{N}} = \left(\frac{\lambda^x}{x!} e^{-\lambda}\right)_{x \in \mathbb{N}}$ が定める母関数は,

$$\begin{aligned}
g(z) &= \sum_{x=0}^{\infty} \left(\frac{\lambda^x}{x!} e^{-\lambda}\right) z^x \\
&= e^{-\lambda} \sum_{x=0}^{\infty} \frac{(\lambda z)^x}{x!} = e^{-\lambda} e^{\lambda z} = e^{\lambda(z-1)}.
\end{aligned}$$

■

歴史 8.1.16. 歴史的に有名な事例としては、ロシア生まれでドイツで活躍した経済学者、統計学者のボルトケヴィッチによる「プロイセン陸軍で馬に蹴られて死亡した兵士数」の例が知られている。ボルトケヴィッチは著書 "Das Gesetz der kleinen Zahlen" (The Law of Small Numbers)[4] において、プロイセン陸軍の 14 の騎兵連隊の中で、1875 年から 1894 年にかけての 20 年間で馬に蹴られて死亡する兵士の数について調査しており、1 年間当たりに換算した当該事案の発生件数の分布が母数 0.61 のポアソン分布によく従うことを示している。

8.1.6.3 ポアソン過程

Poisson 点過程 / Poisson 点場において、ある有界領域内の点の数は Poisson 分布に従う確率変数となる。このことから名付けられたのが Poisson 点過程で、Poisson 自体はこれについて研究していない。

定義 8.1.17 (Poisson process). $\lambda > 0$ を定数として、次の 3 条件を満たす確率過程 $(P_k(t))_{k \in \mathbb{N}}$ を **Poisson 過程** という：時間 $(0, t]$ に点事象が起こる回数が k 回である確率を $P_k(t)$ とし、

- (1) 区間 $(t, t + \Delta t]$ に 1 回だけ事象が起こる確率は $\Delta t \searrow 0$ のとき $\lambda \Delta t + o(\Delta t)$ である。
- (2) 区間 $(t, t + \Delta t]$ に 2 回以上事象が起こる確率は $o(\Delta t)$ である。
- (3) 区間 $(t, t + \Delta t]$ に点事象が起こる回数は $(0, t]$ で起こる回数とその起こり方に「独立」である。^{†3}

補題 8.1.18. Poisson 過程は存在する。

命題 8.1.19. Poisson 過程 $(P_k(t))_{k \in \mathbb{N}}$ は \mathbb{N} 上の Poisson 分布 $\text{Pois}(\lambda t)$ である。

〔証明〕.

関係式の導出 区間 $(t, t + \Delta t]$ で点事象が 1 回起こる確率が $\lambda \Delta t + o(\Delta t)$ 、2 回以上起こる確率が $o(\Delta t)$ より、0 回起こる確率が $1 - \lambda \Delta t - o(\Delta t)$ だから、

$$P_k(t + \Delta t) = P_k(t)(1 - \lambda \Delta t - o(\Delta t)) + P_{k-1}(t)(\lambda \Delta t - o(\Delta t)) + o(\Delta t)$$

となる。ただし、 $k \in \mathbb{N}, P_{-1}(t) = 0$ とした。 $\Delta t \searrow 0$ を考えることで、微分方程式

$$P'_k(t) = \lambda(P_{k-1}(t) - P_k(t)), \quad P_{-1}(t) = 0$$

を得る。

^{†3} 確率過程の独立はまだ定義していない。

分布の導出 まず $k = 0$ とすると,

$$P'_0(t) = -\lambda P_0(t), \quad P_0(0) = 1$$

より, $P_0(t) = e^{-\lambda t}$. 次に $k = 1$ とすると,

$$P'_1(t) = \lambda(e^{-\lambda t}) - P_1(t), \quad P_1(0) = 0$$

より, $P_1(t) = \lambda t e^{-\lambda t}$. $k = 2$ とすると,

$$P'_2(t) = \lambda(\lambda t e^{-\lambda t} - P_2(t)), \quad P_2(0) = 0$$

より, $P_2(t) = \frac{(\lambda t)^2}{2} e^{-\lambda t}$. 以下帰納的に, $P_k(t) = \frac{(\lambda t)^k}{k!} e^{-\lambda t}$ を得る.

■
[別証明] . 過程 $(P_k(t))_{k \in \mathbb{N}}$ の定める確率母関数 $g(z, t) = \sum_{k=0}^{\infty} P_k(t) z^k$ が, Poisson 分布 $\text{Pois}(\lambda t)$ の確率母関数 $e^{\lambda t(z-1)}$ に一致することを示しても良い. ■

8.1.6.4 正規近似

正規分布よりも裾が重いことが分かる.

定理 8.1.20. $X \sim \text{Pois}(\lambda)$ とする. このとき, $\frac{X - \lambda}{\sqrt{\lambda}} \xrightarrow{d} N(0, 1)$.

8.1.7 負の二項分布

定義 8.1.21 (negative binomial distribution, geometric distribution).

- (1) 成功の確率が p の試行を独立に繰り返す Bernoulli 試行 3.5.12 に於て, k 回成功するまでに必要な失敗の回数 x が測度空間 $(\mathbb{N}, P(\mathbb{N}))$ 上に定める分布を負の二項分布 $\text{NB}(k, p) : \mathbb{Z}_+ \times [0, 1] \rightarrow \mathcal{M}(\mathbb{N})$ という. その確率関数は $p(x; k, p) = \binom{x+k-1}{x} p^k q^x$ ($x \in \mathbb{Z}_+$) と表せる.
- (2) 特に $k = 1$ の場合を幾何分布 $G(p) := \text{NB}(1, p)$ といい, 確率関数は $p(x; 1, p) = p q^x$ ($x \in \mathbb{Z}_+$) と表せる.
- (3) 負の二項分布 $\text{NB}(k, p)$ は $k \in (0, \infty)$ 上に延長できる.

命題 8.1.22 (負の二項分布の確率母関数・平均・分散).

- (1) 負の二項分布 $\text{NB}(b, p)$ の確率母関数は $g(z) = p^k (1 - qz)^{-k} = \left(\frac{p}{1 - qz} \right)^k$ で表せる.
- (2) 負の二項分布 $\text{NB}(b, p)$ の平均は $\alpha_1 = \frac{kq}{p}$, 分散は $\mu_2 = \frac{kq}{p^2}$ である.

[証明] .

- (1) $|zq| < 1$ すなわち $|z| < \frac{1}{q}$ のとき, $(1 - qz)^{-k}$ の $z = 0$ における Taylor 展開を考えると

$$\begin{aligned} (1 - qz)^{-k} &= 1 + k(qz) + \frac{k(k+1)}{2!}(qz)^2 + \cdots = \sum_{x=0}^{\infty} \frac{(-k)(-k-1) \cdots (-k-x+1)}{x!} (-qz)^x \\ &= \sum_{x=0}^{\infty} \frac{(x+k-1)(x+k-2) \cdots (k+1)k}{x!} (qz)^x \\ &= \sum_{x=0}^{\infty} \binom{x+k-1}{x} (qz)^x. \end{aligned}$$

$\left. \frac{(-k)(-k-1)\cdots(-k-x+1)}{x!} \right|_{x=0} = 1$ としたことに注意. よって, $NB(k, p)$ の確率母関数は $g(z) = p^k(1 - qz)^{-k}$.
 (2) 確率母関数と平均・分散の関係 7.4.2(3) より,

$$\begin{aligned} g'(z) &= kp^k q(1 - qz)^{-k-1}, & \mu &= g'(1) = \frac{kp^k q}{p^{k+1}} = \frac{kq}{p}, \\ g''(z) &= k(k+1)p^k q^2(1 - qz)^{-k-2}, & \sigma^2 &= g''(1) + g'(1) - (g'(1))^2 \\ & & &= \frac{k(k+1)q^2}{p^2} + \frac{kq}{p} - \frac{k^2 q^2}{p^2} \\ & & &= \frac{kq(p+q)}{p^2} = \frac{kq}{p^2}. \end{aligned}$$

命題 8.1.23 (Poisson 近似). 平均 $\lambda := \frac{kq}{p} \in (0, \infty)$ を一定にして, 成功数を表す母数を $k \rightarrow \infty$ とすると (このとき失敗率 q は極めて小さくなる), Poisson 分布 $\text{Pois}(\lambda)$ に収束する: $NB(k, p) \rightarrow \text{Pois}(\lambda) \ (k \rightarrow \infty)$.

【証明】. 確率関数が $\tilde{p}(x) = \frac{\lambda^x}{x!} e^{-\lambda}$ に収束することを見れば良い.

$$\begin{aligned} p(x; k, p) &= \binom{x+k-1}{x} p^k q^x \\ &= \frac{(x+k-1)\cdots(k+1)k}{x!} p^k q^x \\ &= \frac{(x+k-1)\cdots(k+1)k}{k^x} x! \left(\frac{kq}{p}\right)^x p^{k+x} \\ &\xrightarrow[\lambda=\text{const.}]{k \rightarrow \infty} 1 \cdot \frac{\lambda^x}{x!} e^{-\lambda}. \end{aligned}$$

実際,

$$p^{k+x} = \left(\frac{p}{p+q}\right)^{k+x} = \left(1 + \frac{\lambda}{k}\right)^{-(k+x)} \xrightarrow{k \rightarrow \infty} e^{-\lambda}.$$

注 8.1.24 (幾何分布の無記憶性). $X \sim G(\theta)$ とするとき,

$$P(X \geq m+n | X \geq m) = P(X \geq n) \quad (m, n \in \mathbb{N})$$

が成り立つ. これは, 時刻 m までに成功していないことはその後の成功までの待ち時間の分布に影響しないことを意味しているとみなせる.

8.1.8 Katz 族

定義 8.1.25 (Katz family). \mathbb{N} 上の離散分布の族であって, $a, b \in \mathbb{R}$ を用いた漸化式

$$p_0 > 0, \quad p_x = \left(a + \frac{b}{x}\right) p_{x-1}, \quad x \in \mathbb{N}$$

を満たす族を **Katz 族** という. この漸化式を満たすことを, $(a, b, 0)$ -クラスの分布であるという.

例 8.1.26.

- (1) $\delta_0 : a + b = 0, p_0 = 1$ のとき.
- (2) $B(n, \theta) : a = -\frac{\theta}{1-\theta}, \quad b = \frac{(n+1)\theta}{1-\theta}, \quad p_0 = (1-\theta)^n$.
- (3) $\text{Pois}(\lambda) : a = 0, b = \lambda, p_0 = e^{-\lambda}$.
- (4) $NB(k, \theta) : a = 1-\theta, b = (k-1)(1-\theta), p_0 = \theta^k$.

命題 8.1.27 (実際の母数はかなり狭い). \mathbb{N} 上の確率分布 $p = (p_x)_{x \in \mathbb{N}}$ が Katz 族であるとする. このとき, p は上の例の 4 つの場合に限られる.

- (1) $a + b = 0$ ならば, $p = \delta_0$.
- (2) $a = 0, b > 0$ ならば, $p = \text{Pois}(b)$.
- (3) $a + b > 0, a \in (0, 1)$ ならば, $p = NB((a + b)/a, 1 - a)$.
- (4) $a + b > 0, a \in (-\infty, 0)$ ならば, $\exists_{n \in \mathbb{N}} a(n + 1) + b = 0, p = B(n, -a/(1 - a))$.

特に, p がデルタ測度 δ_0 でなければ, $a + b > 0$ かつ $a < 1$ であり, 確率母関数は

$$g(z) = \begin{cases} \left(\frac{1 - az}{1 - a} \right)^{-\frac{a+b}{a}}, & a \neq 0, \\ \exp(b(z - 1)), & a = 0. \end{cases}$$

と表せる.

8.1.9 超幾何分布

二項分布を2からの復元抽出だと思えば, これを非復元抽出にするとより複雑な関数形が得られる. これは主に個体群生態学で使用される標識再捕獲法などで使われる.

定義 8.1.28 (hypergeometric distribution). 成功 n 個, 失敗 $N - n$ 個が入った多重集合から r 個玉を取り出したときにそのう

ち成功が x 個である確率 $p(x; N, n, r) = \frac{\binom{n}{x} \binom{N-n}{r-x}}{\binom{N}{r}}$ が, $X := \{x \in \mathbb{N} \mid \max\{0, r - N + n\} \leq x \leq \min\{r, n\}\}$ として可測

空間 $(X, P(X))$ 上に定める確率分布 $H(N, n, r)$ を**超幾何分布**という.

命題 8.1.29.

- (1) 平均は $\alpha_1 = r \frac{n}{N}$.
- (2) 分散は $\mu_2 = r \left(\frac{N-r}{N-1} \right) \left(\frac{n}{N} \right) \left(1 - \frac{n}{N} \right)$.

例 8.1.30 (mark and recapture method における Lincoln-Peterson 推定量). 個体数 N を推定するために, n 匹を捕まえて, 標識をつけて再放流する. 十分な時間経過後に sampling し, 標識がついているものが r 匹だった場合, $\tilde{N} := \frac{nr}{x}$ によって N が推定できる. これは, 確率 $p(x; N, n, r)$ が最大になるような N の選び方で, 最尤法の考え方である.

8.1.10 負の超幾何分布

8.1.11 対数分布

定義 8.1.31. \mathbb{N} 上の分布・対数分布 $\text{Log}(\theta) := (p_x)_{x \in \mathbb{N}} (\theta \in (0, 1))$ とは, 確率関数

$$p_x = \begin{cases} 0 & x = 0, \\ \frac{-1}{\log(1 - \theta)} \frac{\theta^x}{x} & x \in \mathbb{N}_{>0}, \end{cases}$$

で定まる分布をいう.

命題 8.1.32. $\text{Log}(\theta)$ の確率母関数は $g(z) = \frac{\log(1 - \theta z)}{\log(1 - \theta)}$ である.

8.1.12 Ord 族

定義 8.1.33 (Ord family). \mathbb{Z} 上の分布であって, 確率関数が差分方程式

$$p_x - p_{x-1} = \frac{(a - x)p_x}{(a + b_0) + (b_1 - 1)x + b_2 x(x - 1)}$$

を満たすものの全体を **Ord 族** という.

例 8.1.34. Katz 族と, 超幾何分布, 負の超幾何分布は Ord 族である.

8.2 多次元離散分布の例

8.2.1 確率変数の積

定義 8.2.1 (marginal distribution, joint / simultaneous distribution). $I := \{1, \dots, d\}$ について, 確率変数 $X_j : \Omega \rightarrow \mathcal{X}_j$ ($j \in I$) の積 $X := (X_j)_{j \in I} : \Omega \rightarrow \mathcal{X} := \prod_{j=1}^d \mathcal{X}_j$ は d 次元確率変数である.

- (1) $J \subsetneq I$ について, 分布 $(p_J(x_j))_{x_j \in \mathcal{X}_j}$ を X_I の **周辺分布** と呼ぶ.
- (2) これに対して X の分布自体のことを, 区別して **結合分布** または **同時分布** という.

定義 8.2.2 (covariance, correlation coefficient). 2つの実確率変数 $X : \Omega \rightarrow \mathcal{X}, Y : \Omega \rightarrow \mathcal{Y}$ について,

- (1) $\text{Cov}[X, Y] := \mathcal{E}[(X - \mathcal{E}[X])(Y - \mathcal{E}[Y])]$ を **共分散** と呼ぶ.
- (2) $\rho(X, Y) := \frac{\text{Cov}[X, Y]}{\sqrt{\text{Var}[X]}\sqrt{\text{Var}[Y]}}$ を **相関係数** と呼ぶ.

補題 8.2.3.

- (1) $E[X^2] < \infty, E[Y^2] < \infty$ のとき, または, $E[|X|] < \infty, E[|Y|] < \infty$ かつ X, Y が独立のとき, 共分散は存在する.
- (2) $E[X^2] < \infty, E[Y^2] < \infty, \text{Var}(X), \text{Var}(Y) > 0$ のとき, 相関係数は存在し, $\text{Im } \rho \subset [-1, 1]$ を満たす.

8.2.2 多項分布

二項分布は多項分布の周辺分布であった.

定義 8.2.4 (multinomial distribution). $I = \{E_1, \dots, E_k\}$ とし,

$$T_I := \left\{ x_I = (x_j)_{j \in I} \in \mathbb{N}^k \mid \sum_{j=1}^k x_j = n \right\}$$

とする. 1回の試行で E_1, \dots, E_k のいずれかが起こるとし, それぞれの生起確率を p_1, \dots, p_k , $\sum_{j=1}^k p_j = 1$ とする. このとき, E_1, \dots, E_k が起きた回数が x_1, \dots, x_k 回である確率は

$$f_I(x_I; p) = \frac{n!}{x_1! \cdots x_k!} \prod_{j=1}^k p_j^{x_j} \quad (x_I = (x_j)_{j \in I} \in T_I)$$

である. これを確率関数とする T_I 上の離散分布を, パラメータ $(n, p) \in \mathbb{N} \times [0, 1]^k$ の **多項分布** $\text{Mult}(n, p)$ という.

命題 8.2.5. $g_I(z_I; p) = (p_1 z_1 + \cdots + p_k z_k)^n$ が確率母関数である.

[証明] . 多項定理より. ■

$$\text{命題 8.2.6. } \text{Cov}[X_i, X_j] = \begin{cases} np_i(1 - p_i) & i = j \\ -np_i p_j & i \neq j \end{cases}$$

8.2.3 2変量 Poisson 分布

定義 8.2.7 (bivariate Poisson distribution). 確率変数 U_1, U_2, U_3 が独立で $U_i \sim \text{Pois}(\lambda_i)$ を満たすとする. このとき, $X_1 = U_1 + U_3, X_2 = U_2 + U_3$ で定まる確率変数 $(X_1, X_2) : \Omega \rightarrow \mathbb{N}^2$ が定める分布を **2変量 Poisson 分布** といい, $\text{BPois}(\lambda_1, \lambda_2, \lambda_3)$ で

表す。周辺分布は $X_1 \sim \text{Pois}(\lambda_1 + \lambda_3)$, $X_2 \sim \text{Pois}(\lambda_2 + \lambda_3)$ である。

命題 8.2.8 (分散や混合積率は確率母関数の項別微分で求める)。

- (1) 確率母関数は $g(z_1, z_2) = \exp(\lambda_1(z_1 - 1) + \lambda_2(z_2 - 1) + \lambda_3(z_1 z_2 - 1))$.
- (2) $\text{Cov}[X_1, X_2] = \lambda_3$.

8.2.4 負の多項分布

負の二項分布 $NB(k, p)$ の確率母関数は、 $\hat{q} := 1/p$, $\hat{p} := q/p = (1-p)/p$ とすると、

$$g(z) = p^k (1 - qz)^{-k} = (\hat{q} - \hat{p}z)^{-k}$$

と表わせ、この形での一般化を考える。

定義 8.2.9. $k > 0, P_i > 0$ をパラメータとする**負の多項分布** $NM(k, (P_1, \dots, P_d))$ とは、 $Q := 1 + \sum_{i=1}^d P_i$ とするとき、確率母関数

$$g(z_1, \dots, z_d) = \left(Q - \sum_{i=1}^d P_i z_i \right)^{-k}$$

が定める \mathbb{N}^d 上の分布を言う。

命題 8.2.10 (確率母関数の微分からわかること)。

$$(1) \text{Cov}[X_i, X_j] = \begin{cases} kP_i(1 + P_i) & i = j \\ kP_iP_j & i \neq j \end{cases}$$

8.3 一次元連続分布の例

8.3.1 一様分布

定義 8.3.1 (uniform distribution). $(\mathcal{X}, \mathcal{B}_1)$ 上の**一様分布** $U(a, b)$ ($a < b \in \mathbb{R}$) とは、確率密度関数 f

$$f(x) := \frac{1}{b-a} 1_{(a,b)} = \begin{cases} \frac{1}{b-a}, & a < x < b, \\ 0, & \text{otherwise.} \end{cases} \quad v[A] := \int_A f(x) dx \quad (A \in \mathcal{B}_1)$$

が定める確率分布をいう。

命題 8.3.2.

- (1) 特性関数は $\varphi(u) = \frac{e^{ibu} - e^{iau}}{(b-a)iu}$. ただし $\varphi(0) = 1$ とする.
- (2) $\alpha_1 = \frac{a+b}{2}$.
- (3) $\mu_2 = \frac{(b-a)^2}{12}$.
- (4) $\gamma_1 = 0, \gamma_2 = \frac{9}{5}$.

[証明] .

$$(1) E[e^{iux}] = \int_a^b e^{iux} \frac{1}{b-a} dx \text{ なので.}$$

■

8.3.2 Gamma 分布・指数分布・カイ2乗分布

8.3.2.1 Gamma 分布の性質

定義 8.3.3 (gamma distribution). $(\mathcal{C}, \mathcal{B}_1)$ 上の **Gamma 分布** $G(\alpha, \nu)$ ($\alpha, \nu \in \mathbb{R}_{>0}$) とは, 確率密度関数

$$f(x) = g(x; \alpha, \nu) := \frac{1}{\Gamma(\nu)} \alpha^\nu x^{\nu-1} e^{-\alpha x} 1_{x>0}$$

が定める分布をいう. ただし, Gamma 関数とは, $\Gamma(\nu) = \int_0^\infty t^{\nu-1} e^{-t} dt$.

命題 8.3.4.

- (1) $\varphi(u) = \frac{1}{(1 - \frac{i u}{\alpha})^\nu}$.
- (2) $\alpha_1 = \frac{\nu}{\alpha}$.
- (3) $\mu_2 = \frac{\alpha^2}{2}$.
- (4) $\gamma_1 = \frac{2}{\sqrt{\nu}}, \gamma_2 = 3 + \frac{6}{\nu}$.

[証明].

(1)

$$\begin{aligned} \varphi(u) &= \int_0^\infty e^{i u x} \frac{1}{\Gamma(\nu)} \alpha^\nu x^{\nu-1} e^{-\alpha x} dx \\ &= \int_0^\infty \frac{1}{\Gamma(\nu)} \alpha^\nu x^{\nu-1} e^{-\alpha(1 - \frac{i u}{\alpha})x} dx \end{aligned}$$

でこの後 path を考えるらしい.

■

8.3.2.2 指数分布

カイ2乗分布は線型理論の騎手で, Pearson による.

定義 8.3.5 (exponential distribution, chi-square distribution).

- (1) $\text{Exp}(\gamma) := G(\gamma, 1)$ を母数 γ の**指数分布**という.
- (2) $\chi^2(k) := G\left(\frac{1}{2}, \frac{k}{2}\right)$ を自由度 k の**カイ2乗分布**という.^{†4}

補題 8.3.6 (確率密度関数).

- (1) 指数分布の確率密度関数は,

$$g(x; \gamma, 1) = \frac{1}{\Gamma(1)} \gamma^1 x^0 e^{-\gamma x} 1_{x>0} = \frac{\gamma}{e^{\gamma x}} 1_{x>0}.$$

(2)

補題 8.3.7. 指数分布 X_λ の特性関数は

$$E[e^{i u X_\lambda}] = \frac{\lambda}{\lambda - i u}.$$

^{†4} 統計推測で重要なクラスである.

8.3.3 正規分布

定義 8.3.8 (normal distribution). $(\mathcal{X}, \mathcal{G}_1)$ 上の**正規分布** $N(\mu, \sigma^2)$ ($\mu \in \mathbb{R}, \sigma > 0$) とは, 確率密度関数

$$\phi(x; \mu, \sigma^2) := \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x - \mu)^2}{2\sigma^2}\right)$$

が定める分布をいう.

命題 8.3.9 (分布の特性値).

- (1) well-definedness: $\int_{\mathbb{R}} \phi(x; \mu, \sigma^2) dx = 1$.
- (2) 特性関数: $\varphi(u) = \exp\left(i\mu u - \frac{1}{2}\sigma^2 u^2\right)$.
- (3) 平均と分散: $\alpha_1 = \mu, \mu_2 = \sigma^2$.
- (4) 歪度と尖度: $\gamma_1 = 0, \gamma_2 = 3$.
- (5) 中心積率: $\mu_{2r+1} = 0, \mu_{2r} = \frac{(2r)!}{2^r r!} \sigma^{2r} = (2r-1)!!(\sigma^2)^r$. ただし, $(2r-1)!! = (2r-1)(2r-3)\cdots 3 \cdot 1$ である.
- (6) 積率母関数: $\mathfrak{M}(t) = \exp\left(\mu t + \frac{\sigma^2 t^2}{2}\right)$.
- (7) キュムラントは $\kappa_1 = \mu, \kappa_2 = \sigma^2, \kappa_r = 0$ ($r \geq 3$).^{†5}

[証明].

- (1) gamma 積分に変換するとわかる.
- (2)
- (3) 特性関数より 7.5.16,

$$\begin{aligned}\alpha_1 &= \frac{1}{i} \varphi'(0) = \frac{1}{i} (i\mu) = \mu, \\ \mu_2 &= -\varphi''(0) + (\varphi'(0))^2 = \sigma^2 - (i\mu)^2 + (i\mu)^2 = \sigma^2.\end{aligned}$$

■

定義 8.3.10 (standard normal distribution). $N(0, 1)$ を**標準正規分布**という.

補題 8.3.11 (scaling).

$$X \sim N(\mu, \sigma^2) \Leftrightarrow \frac{X - \mu}{\sigma} \sim N(0, 1)$$

[証明].

$$\begin{aligned}P\left(\frac{X - \mu}{\sigma} \leq Z\right) &= P(X \leq \mu + \sigma Z^{\dagger 6}) \\ &= \int_{-\infty}^{\mu + \sigma Z} \phi(x; \mu, \sigma^2) dx.\end{aligned}$$

■

注 8.3.12. この操作を基準化という. ある種の affine 変換だという. ある意味での等質性を表す.

8.3.4 Beta 分布

定義 8.3.13 (beta distribution). $(\mathcal{X}, \mathcal{G}_1)$ 上の**(第1種) ベータ分布** $\text{Beta}(\alpha, \beta) = B_E(\alpha, \beta)$ ($\alpha, \beta \in \mathbb{R}_{>0}$) とは, 確率密度関数

$$f(x) := \frac{1}{B(\alpha, \beta)} x^{\alpha-1} (1-x)^{\beta-1} \mathbf{1}_{(0,1)}(x)$$

が定める確率分布をいう. ただし, $B(\alpha, \beta) = \int_0^1 x^{\alpha-1} (1-x)^{\beta-1} dx$.

^{†5} この3次以上のキュムラントが消えることが正規分布の特徴で, 積率による中心極限定理の証明に利用される.

命題 8.3.14.

$$\begin{aligned}
(1) \quad \alpha_1 &= \frac{\alpha}{\alpha + \beta}. \\
(2) \quad \mu_2 &= \frac{\alpha\beta}{(\alpha + \beta)^2(\alpha + \beta + 1)}. \\
(3) \quad \gamma_1 &= \frac{2(\beta - \alpha)\sqrt{\alpha + \beta + 1}}{(\alpha + \beta + 2)\sqrt{\alpha\beta}}. \\
(4) \quad \gamma_2 &= \frac{3(\alpha + \beta + 1)(\alpha^2\beta + \alpha\beta^2 + 2\alpha^2 - 2\alpha\beta + 2\beta^2)}{\alpha\beta(\alpha + \beta + 2)(\alpha + \beta + 3)}.
\end{aligned}$$

[証明] .

(1)

$$\begin{aligned}
\alpha_1 &= \int_0^1 x \frac{1}{B(\alpha, \beta)} x^{\alpha-1} (1-x)^{\beta-1} dx \\
&= \frac{B(\alpha+1, \beta)}{B(\alpha, \beta)} \underbrace{\int_0^1 \frac{1}{B(\alpha+1, \beta)} x^{\alpha} (1-x)^{\beta-1} dx}_{=1} \\
&= \frac{\Gamma(\alpha+1)\Gamma(\beta)}{\Gamma(\alpha+1+\beta)} \frac{\Gamma(\alpha+\beta)}{\Gamma(\alpha)\Gamma(\beta)} = \frac{\alpha}{\alpha + \beta}.
\end{aligned}$$

注 8.3.15. beta 分布は種々の分布が表現できるので便利, R で遊ぶと良い.

8.3.5 Cauchy 分布

定義 8.3.16 (Cauchy distribution). $(\mathcal{X}, \mathcal{G}_1)$ 上の **Cauchy 分布** $C(\mu, \sigma)$ ($\mu \in \mathbb{R}, \sigma \in \mathbb{R}_{>0}$) とは, 確率密度関数

$$f(x) = \frac{1}{\pi\sigma \left(1 + \left(\frac{x-\mu}{\sigma}\right)^2\right)}$$

が定める分布をいう. μ は位置母数, σ は尺度母数と解釈される.

命題 8.3.17.

- (1) 裾が重く ($1/x^2$ のオーダー), 平均と分散は存在しない.
(2) $\varphi(u) = \exp(i\mu u - \sigma|u|)$. 明らかに $u = 0$ で微分可能でない.

歴史 8.3.18. Cauchy(1853) によると考えられていたが, Poisson が 1824 年にすでに注目していた.

8.3.6 Weibull 分布

Weibull 分布は寿命分布として用いられ, また極値分布としても現れる.

定義 8.3.19 (Weibull distribution). $(\mathcal{X}, \mathcal{G}_1)$ 上の **Weibull 分布** $W(v, \alpha)$ ($v, \alpha \in \mathbb{R}_{>0}$) とは, 確率密度関数

$$f(x) = \frac{v}{\alpha} \left(\frac{x}{\alpha}\right)^{v-1} \exp\left(-\left(\frac{x}{\alpha}\right)^v\right) 1_{x>0} = \int_{-\infty}^x f(y) dy$$

が定める分布である. α が尺度母数, v が形状母数と解釈される.

命題 8.3.20.

- (1) 分布関数は $F(x) = \left\{1 - \exp\left(-\left(\frac{x}{\alpha}\right)^v\right)\right\} 1_{x>0}$.
(2) $\alpha_1 = \alpha \Gamma\left(\frac{v+1}{v}\right)$.

$$(3) \mu_2 = \alpha^2 \left\{ \Gamma\left(\frac{\nu+2}{\nu}\right) - \Gamma\left(\frac{\nu+1}{\nu}\right)^2 \right\}.$$

命題 8.3.21. $X \sim \text{Exp}\left(\frac{1}{\alpha^\nu}\right)$ ならば, $X^{\frac{1}{\nu}} \sim W(\nu, \alpha)$.

8.3.7 対数正規分布

定義 8.3.22 (log-normal distribution). $(\mathcal{X}, \mathcal{B}_1)$ 上の対数正規分布 $L_N(\nu, \sigma)$ ($\nu \in \mathbb{R}, \sigma \in \mathbb{R}_{>0}$) とは, 確率密度関数

$$f(x) = \frac{1}{\sqrt{2\pi\sigma^2}} \frac{1}{x} \exp\left\{-\frac{(\log x - \mu)^2}{2\sigma^2}\right\} 1_{x>0}$$

が定める分布である.

命題 8.3.23.

$$\log X \sim N(\mu, \sigma^2) \Leftrightarrow X \sim L_N(\mu, \sigma)$$

命題 8.3.24.

- (1) $\alpha_1 = \exp\left(\mu + \frac{\sigma^2}{2}\right)$.
- (2) $\mu_2 = (e^{\sigma^2} - 1) \exp(2\mu + \sigma^2)$.
- (3) $\gamma_1 = (\omega + 2)\sqrt{\omega - 1}$. ただし, $\omega := \exp(\sigma^2)$ とした.
- (4) $\gamma_2 = \omega^4 + 2\omega^3 + 3\omega^2 - 3$.

8.3.8 logistic 分布

定義 8.3.25 (logistic distribution). $(\mathcal{X}, \mathcal{B}_1)$ 上のロジスティック分布 $\text{Log}(\mu, \sigma)$ ($\mu \in \mathbb{R}, \sigma \in \mathbb{R}_{>0}$) とは, 分布関数

$$F(x) = \frac{1}{1 + \exp\left(-\frac{x-\mu}{\sigma}\right)}$$

で, 確率密度関数

$$f(x) = \frac{1}{\sigma} \frac{\exp\left(\frac{x-\mu}{\sigma}\right)}{\left\{1 + \exp\left(\frac{x-\mu}{\sigma}\right)\right\}^2}$$

が与える分布をいう. よって, 分布は $x = \mu$ に関して対称である.

補題 8.3.26.

$$I(r) := \int_0^\infty x^r \frac{e^{-x}}{(1+e^{-x})^2} dx = (1 - 2^{-(r+1)})\Gamma(r+1)\zeta(r) \quad (r > 1)$$

[証明].

$$\begin{aligned} I(r) &= \int_0^\infty x^r \frac{e^{-x}}{(1+e^{-x})^2} dx = \int_0^\infty \frac{rx^{r-1}}{1+e^x} dx \\ &= \int_0^\infty rx^{r-1} e^{-x} \sum_{j=0}^\infty (-1)^j e^{-jx} dx \\ &= \Gamma(r+1) \sum_{n=1}^\infty (-1)^{n-1} \frac{1}{n^r} \quad (r > 0) \end{aligned}$$

ここで, $\zeta(r) = \sum_{n=1}^\infty \frac{1}{n^r}$ ($r > 1$) について

$$(1 - 2^{-(r+1)})\zeta(r) = \sum_{n=1}^\infty (-1)^{n-1} n^{-r}$$

が成り立つから, 最後の変形を得る. ■

命題 8.3.27.

(1) 中心積率は、奇数について $\mu_r = 0$, 2以上の偶数について

$$\mu_r = 2\sigma^r \Gamma(r+1) \sum_{n=1}^{\infty} (-1)^{n-1} \frac{1}{n^r} = 2\sigma^r (1 - 2^{-(r-1)}) \Gamma(r+1) \zeta(r).$$

$$(2) \alpha_1 = \mu, m_2 = \frac{\pi^2 \sigma^2}{3}, \mu_4 = \frac{7\pi^4 \sigma^4}{15}.$$

$$(3) \gamma_1 = 0, \gamma_2 = 4.2.$$

$$(4) \varphi(u) = e^{i\mu u} \frac{\pi \sigma u}{\sinh(\pi \sigma u)}.$$

[証明] .

(1) 奇数の時は対称性より.

$$(2) \zeta(2) = \frac{\pi^2}{6}, \zeta(4) = \frac{\pi^4}{90} \text{ より.}$$

(3) $-R, R, -R + 2\pi i, R + 2\pi i$ を頂点にもつ長方形についての留数計算より.

■

8.3.9 Pareto 分布

パレート分布は所得の分布に当てはまるという.

定義 8.3.28. $(\mathcal{X}, \mathcal{G}_1)$ 上のパレート分布 $P_A(b, a)$ ($a, b \in \mathbb{R}_{>0}$) とは, 分布関数を

$$F(x) = 1 - \left(\frac{b}{x}\right)^a 1_{x \geq b}$$

確率密度関数を

$$f(x) := ab^a x^{-(a+1)} 1_{x \geq b}$$

とする分布をいう.

命題 8.3.29.

$$(1) \alpha_1 = ab(a-1)^{-1} \quad (a > 1).$$

$$(2) \mu_2 = ab^2(a-1)^{-2}(a-2)^{-1} \quad (a > 2).$$

$$(3) \gamma_1 = 2 \frac{a+1}{a-3} \sqrt{\frac{a-2}{a}} \quad (a > 3).$$

$$(4) \gamma_2 = \frac{3(a-2)(3a^2+a+2)}{a(a-3)(a-4)} \quad (a > 4).$$

8.3.10 逆正規分布

ドリフト付きの Brown 運動の到達時間の分布として現れる. キュムラント母関数 $\log M$ が, 正規分布のキュムラント母関数の逆数になっていることから.

定義 8.3.30 (inverse Gaussian distribution / Wald distribution). 確率密度関数

$$f(x; \delta, \gamma) = 1_{(0, \infty)}(x) \frac{\delta e^{\gamma \delta}}{\sqrt{2\pi}} x^{-3/2} \exp\left(-\frac{1}{2} \left(\gamma^2 x + \frac{\delta^2}{x}\right)\right)$$

で定まる確率分布 $\text{IG}(\delta, \gamma) : \mathbb{R}_{>0} \times \mathbb{R}_{\geq 0} \rightarrow P(\mathbb{R})$ を逆正規分布または Wald 分布という.

補題 8.3.31.

(1) $\gamma > 0$ のとき, 確率密度関数は

$$f(x) = 1_{(0,\infty)}(x) \left(\frac{\delta^2}{2\pi} \right)^{1/2} x^{-3/2} \exp \left(-\frac{\delta^2(x - \delta\gamma^{-1})^2}{2(\delta\gamma^{-1})^2 x} \right)$$

とも表せる.

(2) $\gamma = 0$ のとき, 確率密度関数は, $c := \delta^2$ と定めて,

$$f(x; c) = 1_{(0,\infty)}(x) \sqrt{\frac{c}{2\pi}} x^{-3/2} \exp \left(-\frac{c}{2x} \right)$$

と表せる. これが定める分布を **Levy 分布** といい, $\text{Levy}(c) := \text{IG}(c^{1/2}, 0)$ と表す.

(3) $\text{IG}(\delta, \gamma)$ の積率母関数は,

$$\begin{aligned} M(s) &= \int_0^\infty e^{sx} f(x) dx \\ &= \exp \left(\delta \left(\gamma - \sqrt{\gamma^2 - 2s} \right) \right) & s \leq \frac{\gamma^2}{2}, \gamma \geq 0 \\ &= \exp \left(\gamma \delta \left(1 - \sqrt{1 - \frac{2s}{\gamma^2}} \right) \right) & s \leq \frac{\gamma^2}{2}, \gamma > 0. \end{aligned}$$

(4) $\text{IG}(\delta, \gamma)$ の特性関数は $\varphi(u) = \exp \left(\gamma \delta \left(1 - \sqrt{1 - \frac{2iu}{\gamma^2}} \right) \right)$ となる.

(5) キュムラント母関数は $\log \varphi(u) = \frac{\delta}{\gamma} iu + \sum_{r=2}^\infty (2r-3)(2r-5) \cdots 1 \cdot \frac{\delta}{\gamma^{2r-1}} \cdot \frac{(iu)^r}{r!}$ で, キュムラントは

$$\kappa_1 = \alpha_1 = \frac{\delta}{\gamma}, \quad \kappa_r = (2r-3)(2r-5) \cdots 1 \cdot \frac{\delta}{\gamma^{2r-1}}$$

(6) Levy 分布 $\text{Levy}(c)$ の Laplace 変換は

$$\int_0^\infty e^{-\lambda x} f(x) dx = e^{-\sqrt{c\lambda}} \quad (\lambda \in \mathbb{R}_+)$$

である.

8.3.11 逆 Gamma 分布

命題 8.3.32. $X \sim \Gamma(n/2, n/2)$ ($n \in \mathbb{N}$) とし, 確率変数 $Y := 1/X$ を考えると, この確率密度関数は

$$\begin{aligned} f_Y(y) &= f_X(1/y) y^{-2} \\ &= \frac{(n/2)^{n/2}}{\Gamma(n/2)} (1/y)^{n/2-1} \exp \left(-\frac{n/2}{y} \right) y^{-2} \\ &= \frac{(n/2)^{n/2}}{\Gamma(n/2)} y^{-n/2-1} \exp \left(-\frac{n/2}{y} \right) & y > 0 \end{aligned}$$

と表せる.

[証明] . $y > 0$ のとき $P[Y \leq y] = P[X \geq 1/y]$ である. ■

8.3.12 Laplace 分布

定義 8.3.33. 密度関数

$$f(x) = \frac{1}{2} e^{-|x|}$$

が定める分布を **標準 Laplace 分布 (両側指数分布)** という.

補題 8.3.34. (1) 特性関数は $\varphi(u) = (1 + u^2)^{-1}$.

(2) X, Y, X', Y' が独立に標準正規分布 $N(0, 1)$ に従うとする. このとき, $V := XY + X'Y'$ は密度 f を持つ Laplace 分布に従う.

8.3.13 Marcenko-Pastur 分布

MP($\lambda, 1$) 分布は Wishart 行列の固有値の標本スペクトル分布の漸近分布として導出された。

定義 8.3.35. パラメータ $(\lambda, \sigma^2) \in \mathbb{R}_{\geq 0}^2$ が定める定数 $a := \sigma^2(1 - \sqrt{\lambda})^2, b := \sigma^2(1 + \sqrt{\lambda})^2$ について、確率密度関数

$$f(x; \lambda, \sigma^2) := \frac{1}{2\pi\sigma^2} \frac{\sqrt{(b-x)(x-a)}}{\lambda x} 1_{[a,b]}(x) + 1_{[1,\infty)}(\lambda) \left(1 - \frac{1}{\lambda}\right) \delta_0(x)$$

が定める分布 $\text{MP}(\lambda, \sigma^2) : \mathbb{R}_{\geq 0}^2 \rightarrow P(\mathbb{R})$ を **Marcenko-Pastur 分布** という。

補題 8.3.36. $X \sim \text{MP}(\lambda, \sigma^2)$ ならば, $\sigma^{-2}X \sim \text{MP}(\lambda) := \text{MP}(\lambda, 1)$.

命題 8.3.37. $X_{ij} \sim \text{i.i.d.} N(0, 1)$ ($i \in [d], j \in [n]$) を成分とする $d \times n$ ランダム行列 X に対し, $n^{-1}XX^\top$ の固有値を $0 \leq \lambda_1 \leq \dots \leq \lambda_d$ とする。

- (1) 標本スペクトル分布は $\mu_{d,n}(dx) := \frac{1}{d} \sum_{i=1}^d \delta_{\lambda_i}(dx)$ で与えられる。
- (2) $d = d_n$ が $\frac{d_n}{n} \rightarrow \lambda \in (0, \infty)$ を満たすとき, $\mu_{d_n,n} \xrightarrow{d} \text{MP}(\lambda)$ を満たす。

8.3.14 Pearson 系

定義 8.3.38. \mathbb{R} 上の確率密度関数 p であって、微分方程式

$$\frac{d}{dx} \log p(x) = \frac{(x - \lambda) - a}{b_2(x - \lambda)^2 + b_1(x - \lambda) + b_0}$$

を満たす

$$p(x) = C \exp \left(\int \frac{(x - \lambda) - a}{b_0 + b_1(x - \lambda) + b_2(x - \lambda)^2} dx \right)$$

の形をした分布を **Pearson 系** という。以降, $\lambda = 0$ とする。

- (1) I 型分布とは, $p(x) = C \left(1 - \frac{x}{a_1}\right)^{m_1} \left(1 - \frac{x}{a_2}\right)^{m_2}$ ($x \in (a_1, a_2)$) の形のものをいう。ただし, $a_1 < 0 < a_2, m_1, m_2 > -1$ 。

例 8.3.39.

- (1) Beta 分布は I 型 Pearson 分布である。
- (2)

8.3.15 Poisson 分布確率変数の和差

定義 8.3.40. 独立な $Y \sim \text{Pois}(\alpha), Z \sim \text{Pois}(\beta)$ に対して,

- (1) $X = Y + 2Z$ の分布を, パラメータ $(\alpha, \beta) \in \mathbb{R}_{\geq 0}^2$ の **Hermite 分布** とよび, $\text{Hermite}(\alpha, \beta)$ で表す。
- (2) $X = Y - Z$ の分布を, パラメータ $(\alpha, \beta) \in \mathbb{R}_{\geq 0}^2$ の **Skellam 分布** とよび, $\text{Skellam}(\alpha, \beta)$ で表す。

補題 8.3.41.

- (1) Hermite 分布の特性関数は, $\varphi(u) = \exp(\alpha(e^{iu} - 1) + \beta(e^{2iu} - 1))$ 。
- (2) Hermite 分布の確率母関数は $g(z) = \exp(\alpha(z - 1) + \beta(z^2 - 1))$ 。
- (3) Skellam 関数の特性関数は $\varphi(u) = \exp(\alpha(e^{iu} - 1) + \beta(e^{-iu} - 1))$ 。

8.4 多次元連続分布の例

1次元の絶対連続分布の概念を容易に d 次元に拡張できる.

8.4.1 多次元の確率密度関数

Radon-Nikodym の定理より, \mathbb{R}^d 上の絶対連続分布と確率密度関数は一対一対応する.

記法 8.4.1. \mathbb{R}^d の矩形 $\prod_{i=1}^d (a_i, b_i]$ の全体を \mathcal{G}^d と表す.

定義 8.4.2. \mathbb{R}^d 上の確率分布 ν が絶対連続分布であるとは, 積分可能な関数 $f: \mathbb{R} \rightarrow \mathbb{R}_+$ が存在して

$$\forall A \in \mathcal{G}^d \quad \nu(A) = \int_A f(x) dx$$

と表せることをいう. f を ν の確率密度関数という.

8.4.2 確率密度関数と独立性

独立性と特性関数について成り立つ Kac の定理 7.8.7 と同様の状況が, 確率密度関数についても成り立つ.

命題 8.4.3 (独立性の確率密度関数による特徴付け). P^X が確率密度関数 p を持つとする. このとき, 次の2条件は同値.

- (1) X_1, \dots, X_n は独立.
- (2) $p = \bigotimes_{i=1}^n p_i$ a.e. .

ただし, p_i は X_i の周辺密度関数とした.

8.4.3 畳み込み

絶対連続分布の畳み込みは, その確率密度関数の畳み込みに対応する.

8.4.4 変数変換と確率密度関数

例 8.4.4 (独立正規分布の比は Cauchy 分布). $Y_1, Y_2 \sim N(0, 1)$ を独立とする. $X := \frac{Y_1}{Y_2}$ は Cauchy 分布にしたがう.

例 8.4.5 (Box-Muller transform). $Y_1, Y_2 \sim U(0, 1)$ を独立とする.

$$\begin{cases} X_1 = \sqrt{-2 \log Y_1} \cos(2\pi Y_2) \\ X_2 = \sqrt{-2 \log Y_2} \sin(2\pi Y_2) \end{cases}$$

と定めると, これは独立な標準正規確率変数となる.

8.4.5 多変量正規分布

8.4.5.1 定義と特性値

定義 8.4.6. $\mu \in \mathbb{R}^d$, $\Sigma \in \text{GL}_d(\mathbb{R})$ を正定値実対称行列として, $(\mathbb{R}^d, \mathcal{B}(\mathbb{R}^d))$ 上の測度

$$\mu_{\mu, \Sigma}(dx) = \phi(x; \mu, \Sigma) = \frac{1}{(2\pi)^{d/2}(\det \Sigma)^{1/2}} \exp\left(-\frac{1}{2}(x - \mu)^\top \cdot \Sigma^{-1}(x - \mu)\right) dx$$

を, 平均値 μ , 共分散行列 Σ に関する d 次元正規分布といい, $N_d(0, \Sigma)$ で表す.

命題 8.4.7. d 次元正規分布 $N_d(0, \Sigma)$ の特性関数は

$$\varphi(u) = \exp\left(i\mu \cdot u - \frac{1}{2}u^\top \Sigma u\right)$$

系 8.4.8. キュムラント母関数は $\psi(u) = \log \varphi(u) = i\mu \cdot u - \frac{1}{2}u^\top \Sigma u$ である. 特に, 平均ベクトルは μ , 分散共分散行列が Σ で, 3 次以上のキュムラントはすべて消えている.

8.4.5.2 成分間の独立性の特徴付け

命題 8.4.9 (多次元正規確率変数の成分間の独立性). $Y_1 := (X_1, \dots, X_{k_1})^\top, \dots, Y_l := (X_{k_{l-1}+1}, \dots, X_d)^\top$ ($l \geq 2$) のように, X を l 個の確率変数 Y_1, \dots, Y_l に分ける. この分割に対して, Σ のブロック $\Sigma_{a,b} := \text{Cov}[Y_a, Y_b]$ ($a, b \in [l]$) を考える.

- (1) Y_1, \dots, Y_l は独立.
- (2) $\forall a, b \in [l] \ a \neq b \Rightarrow \Sigma_{a,b} = O$.

8.4.5.3 半正定値行列への拡張

任意の半正定値行列は分散共分散行列とみなすことが出来る. だから, それに対応した正規分布が存在するはずである. しかし, 確率密度行列の言葉では, $\det \Sigma = 0$ になる関係上, 定義できない. 実際, 確率密度行列は連続にはならない. そこで, 特性関数を用いて定義する.

定義 8.4.10. $\Sigma \in M_d(\mathbb{R})$ を半正定値行列とする (特に, 非退化の可能性はある). 列 (Σ_n) を $\Sigma_n := \Sigma + n^{-1}I_n$ で定めるとこれは正定値行列の列で, $\Sigma_n \xrightarrow{n \rightarrow \infty} \Sigma$. 対応する正規分布 $v_n := N_d(\mu, \Sigma_n)$ の特性関数の列は

$$\varphi_{v_n}(u) = \exp\left(iu^\top \mu - \frac{1}{2}u^\top \Sigma_n u\right) \xrightarrow{n \rightarrow \infty} \varphi(u) = \exp\left(iu^\top \mu - \frac{1}{2}u^\top \Sigma u\right)$$

と各点収束し, 原点で連続である. よって, Bochner の定理 7.5.7 より, これはある確率分布 v の特性関数である. この分布を, d 変量正規分布 $N_d(\mu, \Sigma)$ と呼ぶ.

8.4.5.4 正規分布に従うことの特徴付け

命題 8.4.11. $X : \Omega \rightarrow \mathbb{R}^d$ を確率変数, $\mu \in \mathbb{R}^d$ を平均ベクトル, $\Sigma \in M_d(\mathbb{R})$ を半正定値行列とする. このとき, 次の 3 条件は同値.

- (1) $X \sim N_d(\mu, \Sigma)$.
- (2) $\forall u \in \mathbb{R}^d \ u^\top X \sim N(u^\top \mu, u^\top \Sigma u)$.
- (3) $\forall A \in M_{nd}(\mathbb{R}), b \in \mathbb{R}^n \ AX + b \sim N_n(A\mu + b, A\Sigma A^\top)$.

系 8.4.12 (ユニタリ変換は成分の独立性を変えない). $X \sim N_d(\mu, \sigma^2 I_d), U \in M_d(\mathbb{R})$ を直交行列とする. このとき, $UX \sim N_d(U\mu, \sigma^2 I_d)$ である. 特に, UX の成分は再び独立である.

8.4.6 Dirichlet 分布

ベータ分布の高次元化である。

定義 8.4.13. $\Delta_p := \left\{ (x_1, \dots, x_p) \in \mathbb{R}_{\geq 0}^p \mid \sum_{i=1}^p x_i < 1 \right\}$ ($p \in \mathbb{N}$) について,

$$f(x_1, \dots, x_p) = \frac{\Gamma(v)}{\prod_{i=1}^{p+1} \Gamma(v_i)} \left(\prod_{i=1}^p x_i^{v_i-1} \right) \left(1 - \sum_{i=1}^p x_i \right)^{v_{p+1}-1} 1_{\Delta_p}(x_1, \dots, x_p) \quad v_i > 0, v := \sum_{i=1}^{p+1} v_i$$

が定める分布を **Dirichlet 分布** $\text{Dirichlet}(v_1, \dots, v_{p+1}) : \mathbb{R}_{\geq 0}^{p+1} \rightarrow P(\mathbb{R}^p)$ という。

補題 8.4.14. $(X_1, \dots, X_p) \sim \text{Dirichlet}(v_1, \dots, v_{p+1})$ とする。

$$\forall_{j \in [p]} X_j \sim \text{Beta} \left(v_j, \sum_{i \neq j} v_i \right)$$

8.5 指数型分布族

ここから、分布の性質の議論から、分布族の性質を考えることへ、視点を移し、「確率分布へのパラメータの入り方」を議論する。

8.5.1 定義と例

指数型分布族は、有限個の x の関数 $T_i \in \text{Meas}(\mathcal{X}, \mathbb{R})$ の 1 次式の指数関数の $\text{Meas}(\mathcal{X}, \mathbb{R})$ -倍で表せる Radon-Nikodym 微分を持つクラスである。このクラスに対しては、

定義 8.5.1. $\mathcal{P} = \{P_\theta\}_{\theta \in \Theta} \subset P(\mathcal{X})$ を参照測度 ν に対する絶対連続確率分布の族とし、 p_θ をその Radon-Nikodym 微分とする。

$$p_\theta(x) = g(x) \exp \left(\sum_{i=1}^m a_i(\theta) T_i(x) - \psi(\theta) \right)$$

と表せるとき、 \mathcal{P} を **指数型分布族** という。

8.5.2 標準指数型分布族

定義 8.5.2 (密度関数による指数型分布族の生成). 参照測度 ν に関する密度関数 g を考える : $g \geq 0, \int g(x) \nu(dx) = 1$.

$$\Theta_0(g) := \left\{ \theta \in \mathbb{R}^p \mid \int e^{\theta \cdot x} g(x) \nu(dx) < \infty \right\}$$

とおくと、 $\{0\} \in \Theta_0(g) \neq \emptyset$ である。 g のキュムラント母関数を $\psi(\theta) := \log \left(\int e^{\theta \cdot x} g(x) \nu(dx) \right)$ と表すとき、密度関数

$$f(x|\theta) := g(x) \exp(x \cdot \theta - \psi(\theta)) \quad \theta \in \Theta_0(g)$$

を、 $g(x) \nu(dx)$ で生成される p 次の自然指数型分布族という。

補題 8.5.3. $\Theta_0(g)$ は凸集合である。これを **自然パラメータ空間** という。

8.5.3 共役事前分布

Howard Raiffa と Robert Schlaifer によるベジアン決定理論で作られた概念である。共役というのは、事後分布が、事前分布の代数的な閉式で表せることを指している（したがって、数値積分が必要なく、解析的に計算可能）。

定理 8.5.4 (Bayes の定理 (密度版)). 確率変数 (θ, X) は、参照測度 $\mu(dx)\nu(d\theta)$ に関する同時密度関数 $f(x, \theta)\mu(dx)\nu(d\theta)$ をもつとし、 $f_X(x), \pi(\theta), f(x|\theta)$ をそれぞれ、 X, θ の周辺密度と、 θ を与えた下での x の条件付き密度とする。このとき、 x を与えた下での θ の条件付き密度は、

$$\forall x \in \mathcal{X} \quad f_X(x) > 0 \Rightarrow f(\theta|x) = \frac{\pi(\theta)f(x|\theta)}{\int_{\Theta} \pi(\theta)f(x|\theta)\nu(d\theta)} \quad \nu\text{-a.e.}$$

と表せる。このことを、 $f(\theta|x) \propto \pi(\theta)f(x|\theta)$ と表す。

定義 8.5.5 (conjugate prior). 事後分布 $g(-|x)$ が事前分布 $\pi(-)$ と同じ分布型であるとき、 π を θ の**共役事前分布**といい、 $f(x|\theta)$ をその尤度関数という。

8.6 指数分散モデル

8.6.1 構成

記法 8.6.1. 一次元確率分布 $\mu(dx)$ が生成する 1 次元自然指数型分布族

$$\exp(x\theta - \psi(\theta))\mu(dx), \quad \theta \in \Theta_0$$

を考える。ただし、 ψ は μ の (第 2) キュムラント母関数とした。

$$\Theta_0 := \left\{ \theta \in \mathbb{R} \mid \int e^{\theta x} \nu(dx) < \infty \right\}$$

は $\Theta_0^\circ \neq \emptyset$ を満たすとする。 μ の積率母関数 \mathfrak{M} が存在するとし、集合

$$\Lambda := \{ \lambda > 0 \mid \mathfrak{M}(\theta)^\lambda \text{ はある確率分布 } \mu_\lambda \text{ の積率母関数} \}$$

を考える。

補題 8.6.2 (exponential dispersion model).

- (1) 任意の $\lambda \in \Lambda$ について、 $\lambda\psi(\theta)$ はある分布 μ_λ のキュムラント母関数であり、 $\exp(x\theta - \lambda\psi(\theta))\mu_\lambda(dx)$ ($\theta \in \Theta_0$) は分布を定める。
- (2) (1) の分布に従う確率変数 X について、 $Y := \lambda^{-1}X$ の分布は $\tilde{\mu}_\lambda := (\lambda^{-1})_*\mu_\lambda$ について次を満たす：

$$\forall B \in \mathcal{B}^1 \quad P^Y(B) = \int_B \exp(\lambda(y\theta - \psi(\theta)))\tilde{\mu}_\lambda(dy), \quad \theta \in \Theta_0, \lambda \in \Lambda.$$

(2) が定める分布 $(P^Y)_{\lambda \in \Lambda}$ を μ または ψ が定める**指数分散モデル**といい、 $\text{EDM}(\theta, \lambda)$ で表す。

注 8.6.3. 定義から $\mathbb{N} \subset \Lambda$ である。

補題 8.6.4. $Y \sim \text{EDM}(\theta, \lambda)$ とする。

- (1) Y のキュムラント母関数は $\kappa_Y(u) = \lambda \left(\psi \left(\theta + \frac{u}{\lambda} \right) - \psi(\theta) \right)$ である。特に、 $E[Y] = \psi'(\theta)$, $\text{Var}[Y] = \lambda^{-1}\psi''(\theta)$ 。
- (2) 平均値関数を $\tau(\theta) := \psi'(\theta) : \Theta^\circ \rightarrow \mathbb{R}$ で、その値域を $D := \tau(\Theta^\circ)$ で表す。このとき、 τ は単射である。
- (3) $V(\mu) := \tau'(\tau^{-1}(\mu)) : D \rightarrow \mathbb{R}_+$ について、 $\text{Var}[Y] = \lambda^{-1}V(\mu)$ と表せる。

この $V(\mu)$ を**単位分散関数**という。

注 8.6.5. $\lambda = 1$ でない限り、 $V(\mu)$ そのものは分散ではない。これより、 $\text{EDM}(\theta, \lambda)$ を $\text{EDM}(\mu, \lambda)$ で表す。

補題 8.6.6. 定数 $w_i \geq 0, w := \sum_{i=1}^n w_i > 0$ と, 独立確率変数列 $Y_i \sim \text{EDM}(\mu, \lambda w_i)$ について,

$$\frac{1}{w} \sum_{i=1}^n w_i Y_i \sim \text{EDM}(\mu, \lambda w)$$

8.6.2 Tweedie 分布族

定義 8.6.7. $\text{EDM}(\mu, \lambda)$ のうち, 単位分散関数が $V(\mu) = \mu^p$ ($p \in \mathbb{R} \setminus (0, 1)$) と表せる分布族を, **Tweedie 分布族**といい, 記号 $\text{Tw}_p(\mu, \lambda)$ で表す.

例 8.6.8. $p = 0$ ならば正規分布族, $p = 1$ ならば Poisson 分布, $p = 2$ ならば Gamma 分布, $p = 3$ ならば逆正規分布となる.

命題 8.6.9. $\text{EDM}(\mu, \lambda)$ について, $1 \in D, V(1) = 1$ とし, さらにある関数 $s: (0, \infty) \times \Lambda^{-1} \rightarrow \Lambda^{-1}$ で以下を満たすものが存在すると仮定する: $Y \sim \text{EDM}(\mu, \lambda) \Rightarrow [\forall c > 0 \ cY \sim \text{EDM}(c\mu, 1/s(c, \lambda))]$. このとき, 以下が成り立つ.

- (1) $\exists_{p \in \mathbb{R}} Y \sim \text{Tw}_p(\mu, \lambda)$.
- (2) $s(c, \lambda) = c^{2-p}/\lambda$. すなわち, $c\text{Tw}_p(\mu, \lambda) = \text{Tw}_p(c\mu, \lambda/c^{2-p})$.
- (3) $p = 0$ ならば $D = \mathbb{R}$. また, $p \neq 0$ ならば $D = (0, \infty)$. 特に, $\mathcal{L}(Y)$ は無限分解可能である.

参考文献

- [1] Vladimir Voevodsky "Notes on categorical probability"
- [2] "Convergence of Probability Measures"
- [3] "Weak Convergence of Measures"
- [4] 伊藤清 『確率論』
- [5] Kolmogorov 『確率論の基礎概念』
- [6] 吉田朋広 『数理統計学』 (朝倉書店, 2006)
- [7] 竹村彰道 『現代数理統計学』 (学術図書, 2020)
- [8] 久保川達也 『現代数理統計学の基礎』 (共立出版, 2017)
- [9] 西山陽一 『マルチンゲール理論による統計解析』 (近代科学社, 2011)
- [10] 丸山徹 - 確率測度の*弱収束 <https://core.ac.uk/download/pdf/145720102.pdf>
- [11] 清水良一. (1976). 中心極限定理.
- [12] Adams, W. J. (1974). *The Life and Times of the Central Limit Theorem*.
- [13] Gnedenko, B. V., and Kolmogorov A. N. (1954). *Limit Distribution for Sums of Independent Random Variables*